

Analyses statistiques de données

Isabelle Quidu ✉
Gilles Le Chenadec

ENSTA
IP PARIS

Plan du cours

PART 1: Introduction

PART 2: Éléments d'analyse statistique descriptive

PART 3: Éléments de statistique inférentielle

Plan du cours

PART 1: Introduction

PART 2: Éléments d'analyse statistique descriptive

PART 3: Éléments de statistique inférentielle

Introduction

- Objectifs et séquencement
- Exemple d'introduction
- Analyse statistique
- Vocabulaire statistique

Objectifs et séquencement
Introduction

Objectifs du cours

J'ai un problème pour lequel j'ai récupéré des données...qu'est-ce que je peux faire, dire, conclure? :-(

- Passer du problème, des données à un modèle mathématique qu'on exploitera pour faire parler les données!
- Passer de l'intuition (impression subjective) à des données objectives
- A partir de ces données, établir une stratégie pour votre étude, votre entreprise (aide à la décision)

Séquencement du cours

6 séances de 4h: CM + TD + TP Python

- Statistiques descriptives univariées
- Statistiques descriptives bivariées
- Intervalles de confiance à partir d'un échantillon
- Tests statistiques d'hypothèses pour un échantillon (séance 1)
- Tests statistiques d'hypothèses pour un échantillon (séance 2)
- Inférences statistiques pour deux échantillons

Exam

- **Révision** des exams précédents (**2h TD**)
- **Exam** (**1h**, sans documents, **1 feuille recto-verso**, calculatrice)

Exemple d'introduction

Introduction

Étudions l'hélicoptère en papier

- Mettre au point un hélicoptère en papier qui, lancé d'une certaine hauteur, atteint le sol en un temps de vol maximal.
- Cet hélicoptère est
  - construit à partir d'une demi-feuille A4, découpée et pliée selon le schéma ci-dessous
  - Cet hélicoptère est caractérisé par ses dimensions Ha, Hc, Hp, La et Lp
  - ainsi que par d'autres paramètres possibles: L'épaisseur et le grainage du papier, la présence d'un stabilisateur en bas du pied (un trombone), le sens de la pliure des ailes, la coupe éventuelle des coins du corps pour augmenter l'aérodynamisme.

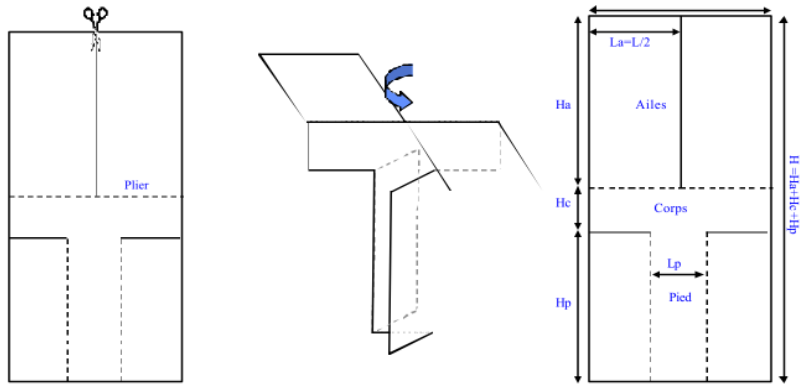


Figure: (Université Catholique de Louvain, 2010)

Analyse statistique
Introduction

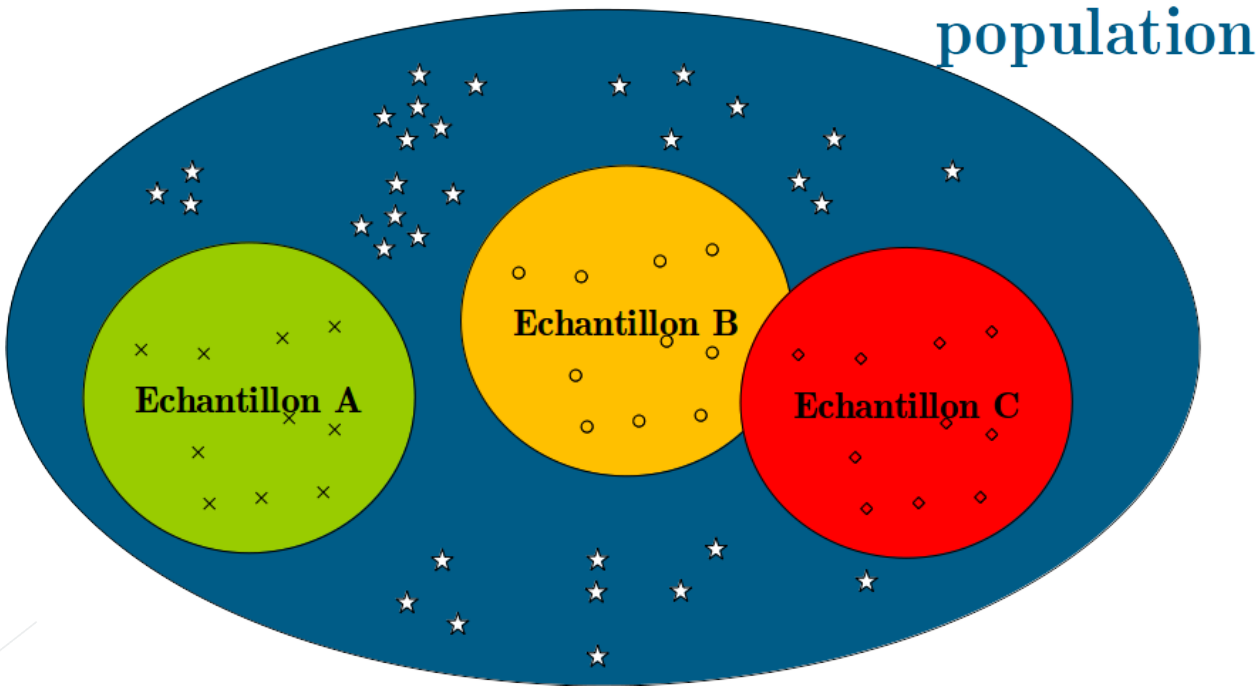
C'est quoi l'analyse statistique?

- **Je construis**
  - 10 hélicoptères en papier, je mesure un temps de vol moyen de 8.3 s.
  - 100 hélicoptères en papier, je mesure un temps de vol moyen de 8.7 s.
  - 10 hélicoptères en papier, avec un trombone accroché au pied, je mesure un temps de vol moyen de 8.1 s.
  - 10 autres hélicoptères en papier, avec un corps de 4 cm, je mesure un temps de vol moyen de 9 s.
- **Questions posées par le statisticien**
  - Peut-on comparer le temps des expériences?
  - Est-ce que je peux dire que les temps de vol sont identiques ?
  - Quand la différence de temps de vol devient significative?
  - A partir de combien d'essais?
  - Quand est-ce que je peux généraliser à toute la population des hélicos en papier?
  - Quel est le risque que je prends de me tromper?

Vocabulaire statistique
Introduction

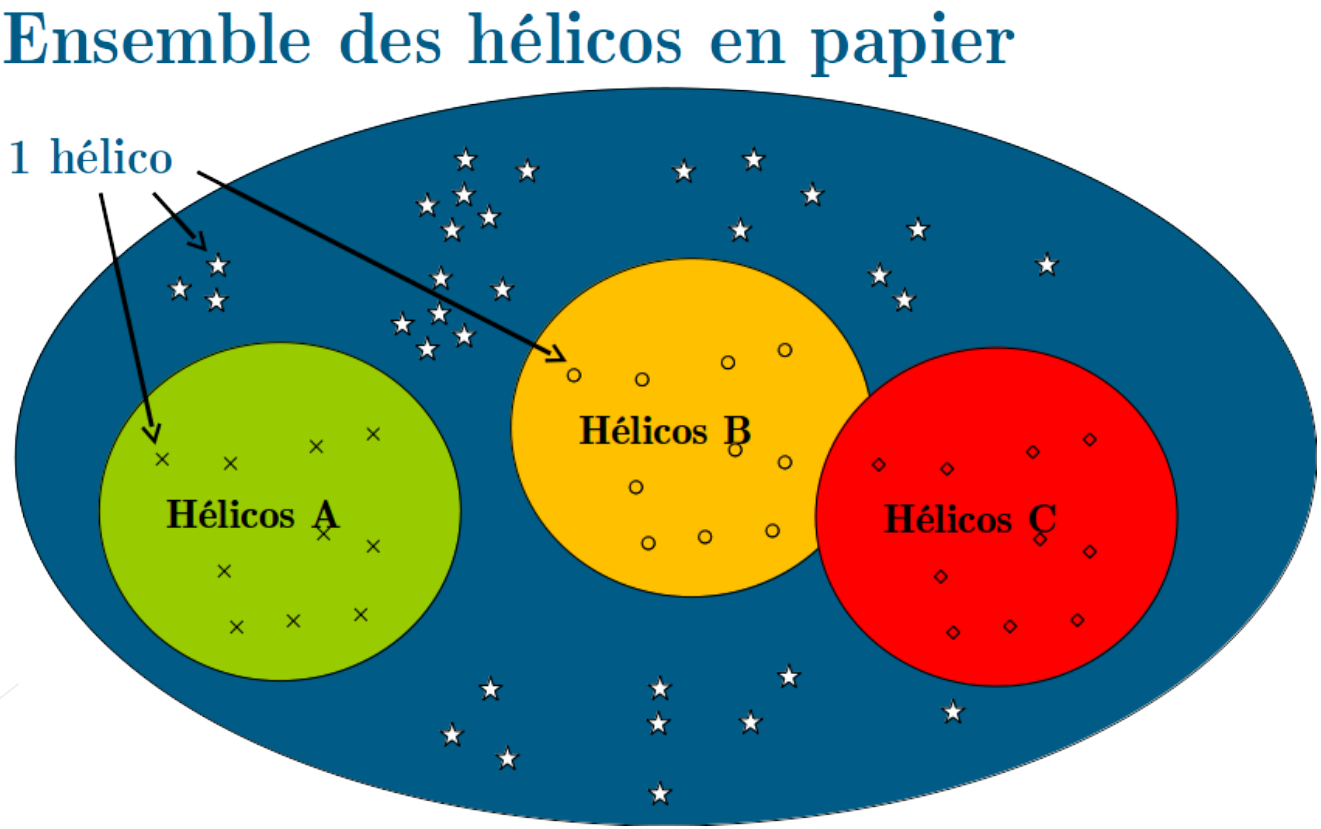
La population et l'échantillon

- Un des concepts de base en statistiques est l'échantillonnage (sampling)
- Dans la plupart des problèmes statistiques, un ensemble de mesures ou données appelé l'**échantillon** est tiré d'un beaucoup plus grand (voire infini) ensemble de mesures ou données appelé la **population**.



La population et l'échantillon

- Pour le problème de l'hélico en papier, nous espérons que les mesures prises correspondent à tous les hélicos du monde!
- Parmi la population et l'échantillon, qu'est-ce qui est le plus intéressant?



La population et l'échantillon

Parmi la population et l'échantillon, qu'est-ce qui est le plus intéressant?

- Dans la plupart des cas, nous nous intéresserons principalement à la population.
- mais comme il est difficile d'enregistrer le temps de vol de tous les hélicoptères possibles, nous tenterons de **décrire ou prédire** le comportement de la population sur la base des informations obtenues à partir de cet échantillon (*représentatif de la population*!)

Statistiques descriptives et inférentielles

Quand on est face à un ensemble de mesures (échantillon ou population), le statisticien procède

- en le décrivant,
- en représentant
- et en le résumant.

La branche des statistiques qui permet de réaliser cela est appelé **statistiques descriptives**. Il s'agit alors d'**exploiter un échantillon de cette population et de tenter de répondre aux questions posées sur la population**.

Definitions

- Les **statistiques descriptives** représentent un ensemble de techniques utilisées pour résumer et décrire les importantes caractéristiques d'un ensemble de mesures.
- Les **statistiques inférentielles** représentent un ensemble de techniques utilisées pour réaliser des inférences (i.e. tirer des conclusions) sur les caractéristiques d'une population à partir des informations contenues dans un échantillon tiré de cette population.

Plan du cours

PART 1: Introduction

PART 2: Éléments d'analyse statistique descriptive

PART 3: Éléments de statistique inférentielle

Éléments d'analyse statistique univariée

- Introduction et vocabulaire
- Représentations d'une variable qualitative/catégorielle
- Représentations d'une variable quantitative
- Décrire des données quantitatives avec des mesures numériques

Introduction et vocabulaire

Éléments d'analyse statistique univariée

Variables et données

Une fois que vous avez des données, comment peut-on les afficher, les mettre en valeur dans une forme claire et compréhensible ? On doit d'abord définir les différents types de données ou variables qu'on rencontre dans la vie courante.

Def : Echantillon

L'**échantillon** est un ensemble d'individus d'une population.

Def : Individu ou unité statistique

L'**individu ou unité statistique** est un élément de l'échantillon ou de la population.

Def : Variable

On appelle **variable** toute valeur attachée aux individus de la population ou d'un échantillon.

Def : Série statistique

On appelle **série statistique** liste de valeurs (d'une variable) d'une même population, dans laquelle l'ordre des termes n'est pas significatif.

Variables et données: exemples

Série statistique de 32 mesures du temps de vol d'hélicoptères (paramètres de l'hélicoptère définis planche 9)

Numéro du lancer	Helico	H	L	H_a	H_c	H_p	L_a	L_p	Coupé	Temps
1	A	29,7	10,5	7	2,7	12	5,25	3,5	NON	1,97
2	A	29,7	10,5	7	2,7	12	5,25	3,5	NON	2,03
3	A	29,7	10,5	7	2,7	12	5,25	3,5	NON	2,1
4	A	29,7	10,5	7	2,7	12	5,25	3,5	NON	1,86
5	A	29,7	10,5	7	2,7	12	5,25	3,5	NON	2
6	A	29,7	10,5	7	2,7	12	5,25	3,5	NON	2,14
7	A	29,7	10,5	7	2,7	12	5,25	3,5	NON	2,07
8	A	29,7	10,5	7	2,7	12	5,25	3,5	NON	2,19
9	B	29,7	10,5	15	2,7	12	5,25	3,5	NON	2,52
10	B	29,7	10,5	15	2,7	12	5,25	3,5	NON	3,01
11	B	29,7	10,5	15	2,7	12	5,25	3,5	NON	2,69
12	B	29,7	10,5	15	2,7	12	5,25	3,5	NON	2,71
13	B	29,7	10,5	15	2,7	12	5,25	3,5	NON	2,93
14	B	29,7	10,5	15	2,7	12	5,25	3,5	NON	2,83
15	B	29,7	10,5	15	2,7	12	5,25	3,5	NON	2,7
16	B	29,7	10,5	15	2,7	12	5,25	3,5	NON	3,11
17	C	29,7	10,5	7	2,7	2	5,25	3,5	NON	2,52
18	C	29,7	10,5	7	2,7	2	5,25	3,5	NON	2,25
19	C	29,7	10,5	7	2,7	2	5,25	3,5	NON	2,47
20	C	29,7	10,5	7	2,7	2	5,25	3,5	NON	2,44
21	C	29,7	10,5	7	2,7	2	5,25	3,5	NON	2,44
22	C	29,7	10,5	7	2,7	2	5,25	3,5	NON	2,45
23	C	29,7	10,5	7	2,7	2	5,25	3,5	NON	2,36
24	C	29,7	10,5	7	2,7	2	5,25	3,5	NON	2,27
25	D	29,7	10,5	7	2,7	12	5,25	3,5	OUI	1,87
26	D	29,7	10,5	7	2,7	12	5,25	3,5	OUI	2,12
27	D	29,7	10,5	7	2,7	12	5,25	3,5	OUI	1,84
28	D	29,7	10,5	7	2,7	12	5,25	3,5	OUI	2,08
29	D	29,7	10,5	7	2,7	12	5,25	3,5	OUI	1,98
30	D	29,7	10,5	7	2,7	12	5,25	3,5	OUI	1,98
31	D	29,7	10,5	7	2,7	12	5,25	3,5	OUI	1,78
32	D	29,7	10,5	7	2,7	12	5,25	3,5	OUI	1,88

Figure: Mesures du temps de vol d'un hélico

Données univariées, bivariées, multivariées

Def : Données univariées

Les **données univariées** sont composées d'**une seule variable** pour chaque individu statistique de l'échantillon ou de la population.

Def : Données multivariées

Les **données bivariées** sont composées de **deux variables** pour chaque individu statistique de l'échantillon ou de la population.
Les **données multivariées** sont composées de **plus de deux variables** pour chaque individu statistique de l'échantillon ou de la population.

Types de variables: qualitatives vs quantitatives

Les variables peuvent être classées en deux types: qualitatives ou quantitatives.

Def : Qualitatives ou catégorielles

Les **variables qualitatives ou catégorielles** mesurent l'appartenance à une catégorie donnée. Elles peuvent être **nominales** ou **ordinales**

Exemples: sexe, catégories socio-professionnelles, âge = moins de 20 ans; de 20 ans à 39 ans; de 40 ans à 59 ans, 60 ans et plus

Def : Variables quantitatives

Les **variables quantitatives** mesurent une quantité numérique. Elles peuvent être **discrètes** ou **continues**.

Exemples: prix, taille, note/20, etc.

Analyses statistiques descriptives univariées

Après la collecte de données, elles peuvent être exploitées et résumées pour révéler les informations suivantes:

- Quelles valeurs des variables ont été mesurées?
- Combien de fois chaque valeur a été observée?

Dans cette optique, une table statistique peut être construite afin de représenter graphiquement les données. On parle de **distribution des données** (sous entendu en fonction des valeurs qu'elles prennent!).

Le type de graphique utilisé dépend du type de variable mesurée....

Représentations d'une variable qualitative/catégorielle

Éléments d'analyse statistique univariée

Exemple

Soit le tableau de données suivant:

Lancer	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20	21	22	23	24	25	26	27	28	29	30	31	32
Hélico	A	A	A	A	A	A	A	A	B	B	B	B	B	B	B	B	C	C	C	C	C	C	C	C	D	D	D	D	D	D	D	D

Considérons la variable Hélico:

- Quel est son type?
- Qu'est-ce qu'on peut dire?
- Comment la représenter?

Construction de la table des effectifs

Exemple

Données brutes

Lancer	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20	21	22	23	24	25	26	27	28	29	30	31	32
Hélico	A	A	A	A	A	A	A	A	B	B	B	B	B	B	B	B	C	C	C	C	C	C	C	C	D	D	D	D	D	D	D	D

Table statistique ou table des effectifs

Modalités du type d'hélico x_k	A	B	C	D
Effectifs n_k	8	8	8	8
Fréquences f_k	$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{4}$

Effectif, Fréquence, Pourcentage

Quand la variable est qualitative ou catégorielle, la **table des effectifs** est une liste de K catégories à laquelle on associe une mesure de "combien de fois la catégorie" a été rencontrée.
Trois mesures différentes existent :

Def : Effectif, fréquence, pourcentage

- l'**effectif** n_k: le nombre de mesures de chaque catégorie k
- la **fréquence** f_k: la proportion de mesures de chaque catégorie k
- le **pourcentage** de mesures de chaque catégorie k

Soit $n = \sum_{k=1}^{K} n_k$ le nombre total de mesures dans un ensemble,

$$\text{frequence} = f_k = \frac{\text{Effectif}}{n} = \frac{n_k}{n} \qquad \text{Pourcentage} = 100 \times \text{frequence}$$

Effectif, Fréquence, Pourcentage

Remarques

- La somme des :
  - effectifs est n
  - fréquences est 1
  - pourcentages est 100 %
- Les catégories doivent être choisies de telle sorte que
  - une mesure appartiendra à une et une seule catégorie
  - chaque mesure peut être assignée à une catégorie

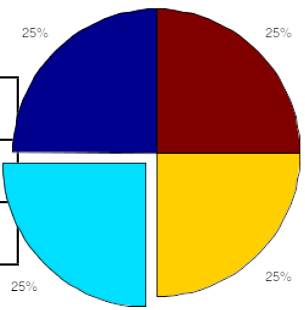
Représentation en secteurs, en bâtons

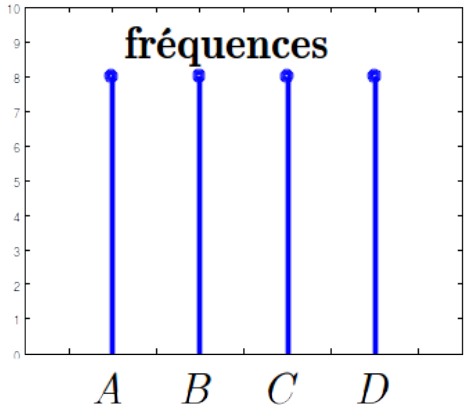
Une fois que les données ont été catégorisées et résumées dans une table des effectifs, on peut utiliser soit la représentation en bâtons ou en secteurs.

Def : Représentation en secteurs, en bâtons

- La **représentation en secteurs** est le graphique circulaire ou camembert des pourcentages.
- La **représentation en bâtons** est la représentation où l'axe des abscisses représente les catégories et l'axe des ordonnées la mesure de combien de fois la catégorie est mesurée.

Catégorie k	A	B	C	D
Effectifs n_k	8	8	8	8
Fréquences f_k	$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{4}$





Représentation en secteurs, en bâtons: remarque

L'impact visuel des deux représentations n'est pas le même

- La **représentation en secteurs** est utilisée pour représenter les relations des différentes catégories
- La **représentation en bâtons** est utilisée pour mettre en avant la valeur de chaque catégorie.

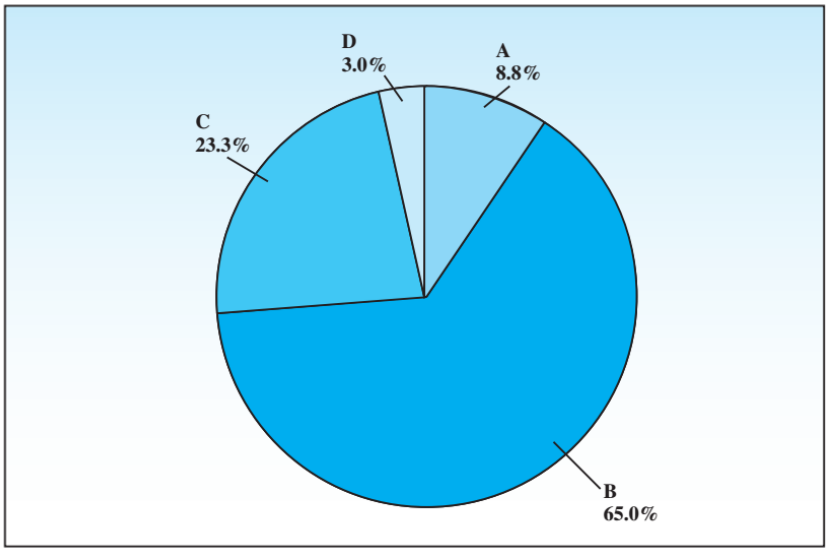


Figure: extrait de Mendenhall et al, 2010

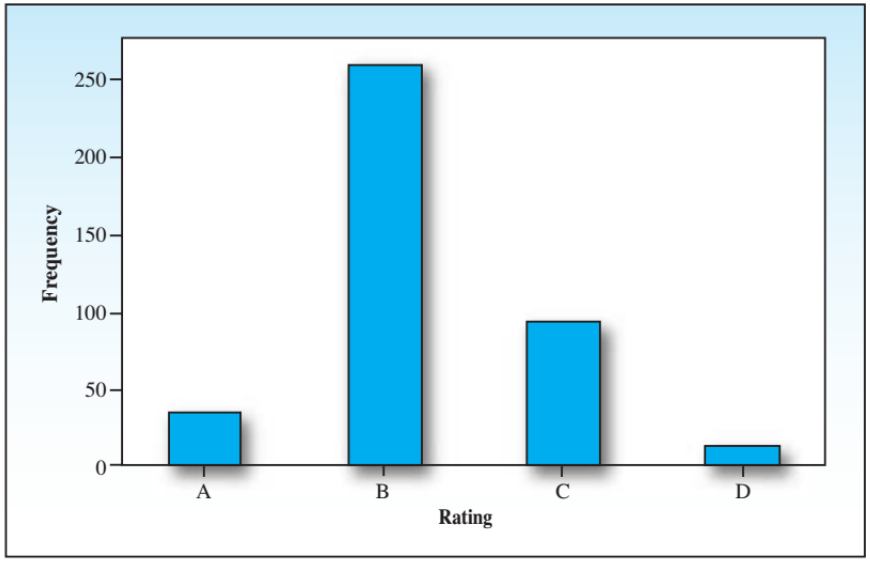


Figure: extrait de Mendenhall et al, 2010

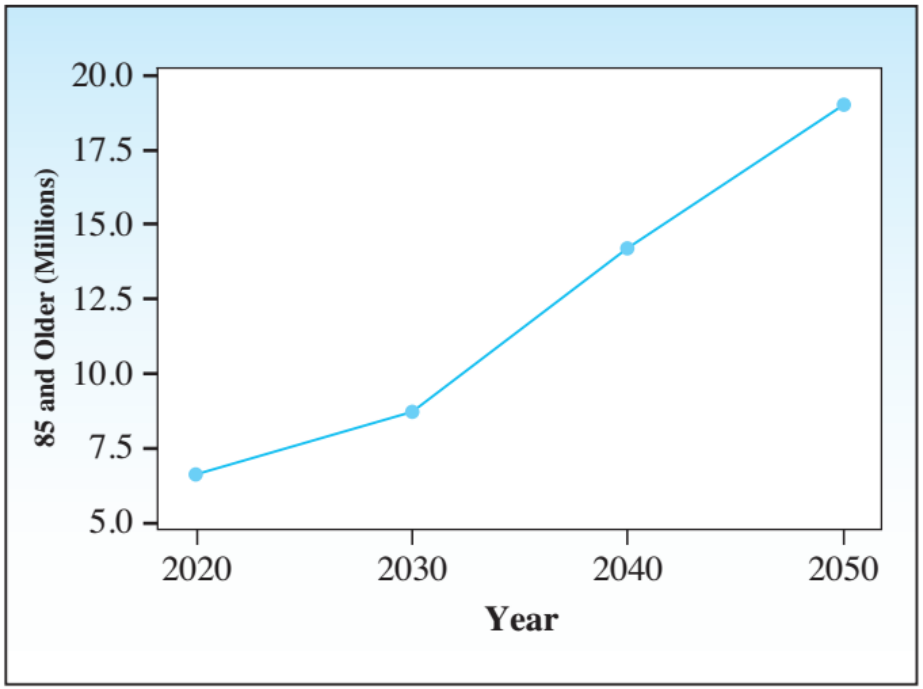
Représentations d'une variable quantitative

Éléments d'analyse statistique univariée

Série temporelle

Avant d'aborder les outils statistiques, il convient de faire une préanalyse dans le cas d'une dépendance temporelle.

Quand la variable quantitative a été collectée en fonction du temps, les données constituent **une série temporelle *i.e.* un signal**. On peut alors représenter cette série en fonction du temps pour discerner un **motif ou une tendance particulière.**



Exemple

i	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20	21	22	23	24	25	26	27	28	29	30	31	32	33	34	35	36	37
temps	1.97	2.25	2.09	1.89	1.92	2.04	1.96	1.83	1.8	2.16	2.07	1.87	1.96	2.23	2.14	1.92	1.89	2.03	2.09	1.66	2.1	1.87	1.94	2.04	1.81	2.09	2	2.28	1.94	2.05	2.16	2.03	2.32	2.29	1.79	1.9	2.01

Considérons la variable Temps de vol:

- Quel est son type?
- Qu'est-ce qu'on peut dire?
- Comment la représenter?

Histogramme des effectifs, des fréquences

Def : Histogramme des effectifs, des fréquences

- L'**histogramme des effectifs** pour une variable quantitative est une représentation en barres pour laquelle la hauteur représente "combien de fois" les mesures tombent dans un intervalle de données. Les intervalles sont tracés sur l'axe horizontal. Ce processus aboutit à la création d'une **table des effectifs** (comme pour une variable qualitative!).
- L'**histogramme des fréquences** remplace les effectifs par les fréquences.

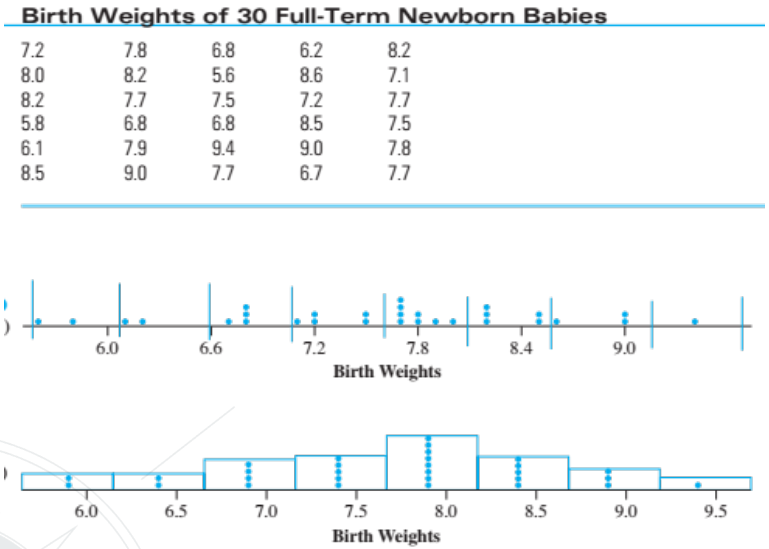


Figure: Construction de l'histogramme (poids donné en livre anglaise lb)

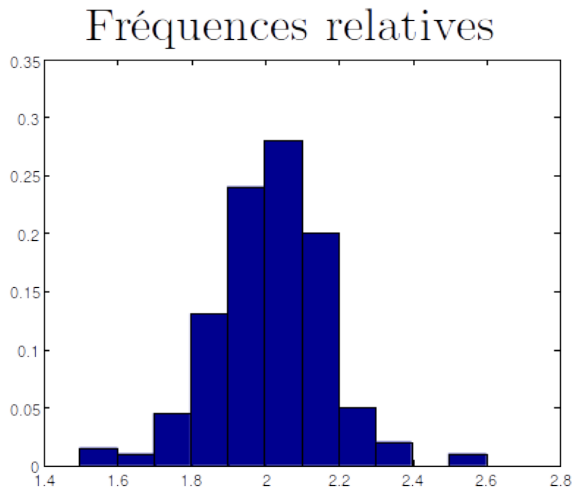


Figure: Temps de vol des hélicos

Histogramme des effectifs, des fréquences

Procédure de construction des intervalles:

- Fixer le nombre d'intervalles
- Déterminer l'amplitude des intervalles ((max - min)/nb d'intervalles)
- Affecter les valeurs à chaque intervalle en utilisant la règle de l'inclusion par la gauche *i.e.* [x0,x1[

Remarque sur le nombre d'intervalles

- certains auteurs préconisent entre 5 et 12
- plus on a de données, plus le nombre d'intervalles doit être important
- compromis entre le nombre de données et la qualité de la forme de l'histogramme
- des règles empiriques existent:
  - Sturge: $1 + 3.3 \log_{10}(n)$ avec n le nombre de données
  - Yule: $2.5 \sqrt[4]{n}$

Histogramme des fréquences cumulées

Def : Effectifs/Fréquences cumulé(e)s

- Effectifs cumulés de X avec i le numéro d'intervalle: $N_i = \sum_{k=1}^{i} n_k$
- Fréquences cumulées de X: $F_i = \sum_{k=1}^{i} f_k = \frac{N_i}{n}$

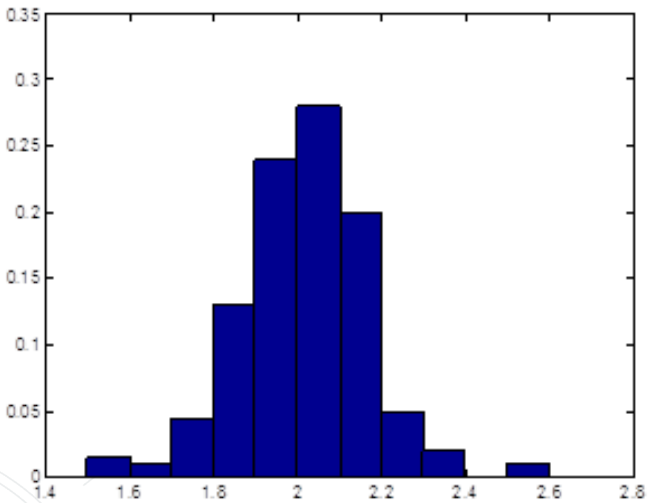


Figure: Histogramme des fréquences

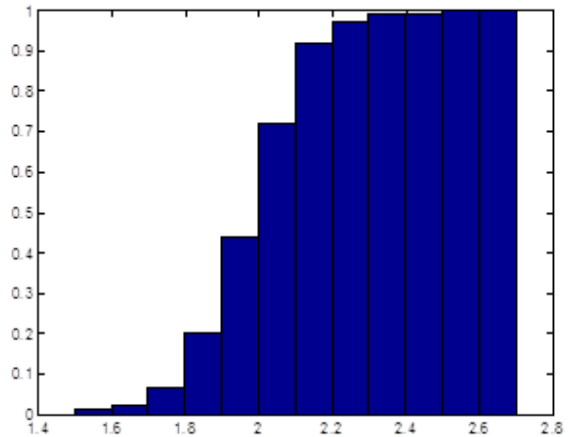


Figure: idem en cumulées

Interpréter une distribution ou un histogramme avec un œil critique

Vous avez produit un graphique, qu'est ce que vous devez faire pour essayer de décrire les données?

Point méthodo

- Vérifiez l'axe horizontal et l'axe vertical pour être certain de ce qui a été mesuré et affiché.
- Examinez la localisation de la distribution des données. Où sur l'axe horizontal est le centre de la distribution? Si vous comparez deux distributions, ont-elles le même centre?
- Examinez la forme de la distribution. Est-ce que la distribution a un pic? Si oui, il s'agit de la catégorie/intervalle le/la plus fréquent(e). Y-a-t-il plus d'un pic? Y-a-t-il approximativement un nombre égal de mesures du côté gauche ou droit d'un pic?
- Recherchez des mesures extrêmes (outliers). C'est à dire y-a-t-il des mesures beaucoup plus grandes ou petites que toutes les autres? De quoi ces valeurs sont-elles représentatives?

Interpréter une distribution ou un histogramme avec un œil critique

Les distributions sont très souvent décrites par leur position et par leur forme.

Def : Caractéristiques d'une distribution

Une distribution est:

- **centrée** si son espérance/sa moyenne est nulle
- **symétrique** si les côtés gauche et droit de la distribution forment deux images mirroirs
- **asymétrique à gauche (à droite)** si une plus grande proportion des données se situe à gauche (à droite).
- **unimodale** si elle n'a qu'un pic
- **bimodale** si elle en a deux, révélant le mélange de deux populations dans les données (une autre variable peut expliquer ces deux pics, laquelle?)

Décrire des données quantitatives avec des mesures numériques

Éléments d'analyse statistique univariée

Décrire des données avec des mesures numériques

Rem:Variables concernées

Dans cette partie, les variables sont supposées être **quantitatives**!

- Les distributions sont très souvent décrites par leur forme mais les définitions vues précédemment sont subjectives (*i.e.* cette distribution est plus asymétrique que l'autre...)
- Pour résoudre ce problème, on calcule des valeurs numériques caractérisant la distribution: son centre (sa position), sa variabilité autour de son centre (sa dispersion) et sa forme.

Mesures de la position: moyenne

Il s'agit de la mesure $\bar{x}_n$ qui positionne le centre de la distribution sur l'axe horizontal.

Def : Moyenne

Soit n est le nombre de données dans l'échantillon, la **moyenne arithmétique (empirique)** de l'échantillon est définie par:

$$\bar{x}_n = \frac{1}{n}\sum_{i=1}^{n} x_i$$

Remarques

- la **moyenne de la population**, ou **moyenne théorique**, est généralement notée μ
- dans le cas d'une variable quantitative dans une table des effectifs (x_k valeur discrète/centre d'intervalle et n_k effectif) la moyenne de l'échantillon devient:

$$\bar{x}_n = \frac{1}{n}\sum_{k=1}^{K} n_k x_k$$

Position: médiane d'un échantillon

Def : Médiane

La médiane m est un nombre tel qu'au moins la moitié de l'effectif de la série X soit inférieure ou égale à m et au moins la moitié de l'effectif de la série soit supérieure ou égale à m.

Prop: Calcul de la médiane de l'échantillon

- Trier les n données X par ordre croissant, soit X_{tri} la nouvelle série statistique
- Déterminer m en fonction de la parité de n:
  - Si n impair, alors $m = X_{tri}(.5(n+1)))$
  - Si n pair, $n = 2p$, toute valeur de l'intervalle $[X_{tri}(p), X_{tri}(p+1)[$ est une médiane. Il existe différentes conventions soit on garde l'intervalle soit une seule valeur que ce soit la borne inf ou la moyenne. **Dans ce cours, on garde l'intervalle entier.**

trouver la médiane de l'échantillon

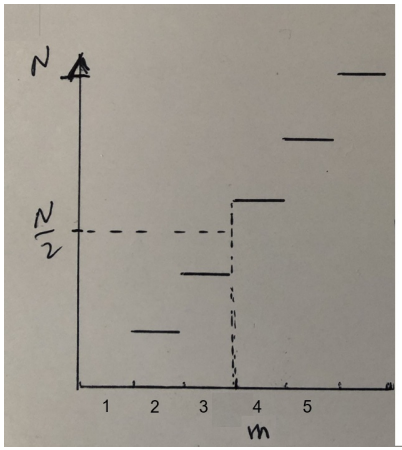
- 2, 9, 11, 5, 6
- 2, 9, 11, 5, 6, 27

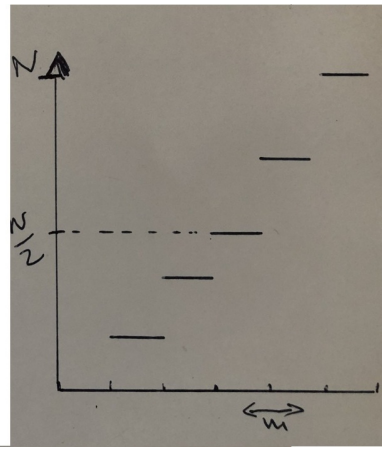
Position: médiane à partir d'une table des effectifs

Si pour une raison ou pour une autre, on a une table d'effectifs, ...

Prop: Calcul de la médiane pour une table des effectifs

- calculer les effectifs cumulés
- Trouver la valeur qui correspond à l'effectif médian (qui correspond à l'effectif cumulé $n/2$)
- *i.e.* Tracer l'évolution des effectifs cumulés, deux cas de figure:





trouver la médiane de la table des effectifs

Valeurs	0	1	2	3	4	5	6	7	8	9	10	11	12
Effectifs	0	0	1	0	0	1	1	0	0	1	0	1	1
Effectifs cumulés	0	0	1	1	1	2	3	3	3	4	4	5	6

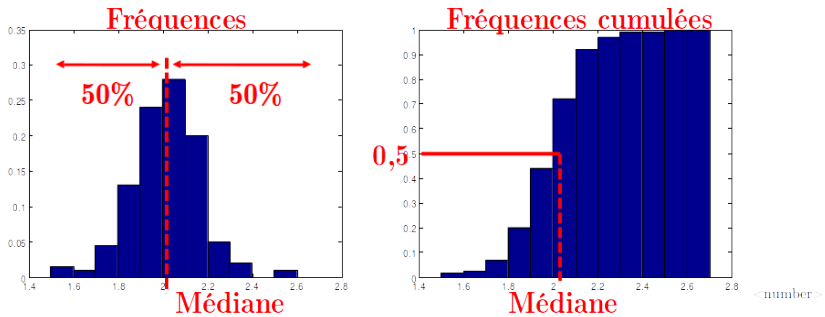
Position: médiane d'une var. quant. groupée par intervalles

Soit X continue regroupée en K classes selon une subdivision $(x_0, ..., x_p)$ de $[\min(X), \max(X)[$, $I_i = [x_{i-1}, x_i[$ le i-ième intervalle de la subdivision (ou i-ème classe) de centre $c_i = \frac{(x_{i-1}+x_i)}{2}$

Médiane des $n = 200$ temps de vol

Intervalle I_i	[1.5,1.6[	[1.6,1.7[	[1.7,1.8[	[1.8,1.9[	[1.9,2.0[	[2.0,2.1[	[2.1,2.2[	[2.2,2.3[	[2.3,2.4[	[2.4,2.5[	[2.5,2.6[
Centre c_i	1.55	1.65	1.75	1.85	1.95	2.05	2.15	2.25	2.35	2.45	2.55
Effectifs n_i	3	2	9	26	48	56	40	10	4	1	1
Effectifs cumulés N_i	3	5	14	40	88	144	184	194	198	199	200
Fréquences f_i	0.015	0.010	0.045	0.130	0.240	0.280	0.200	0.050	0.020	0.005	0.005
Fréquences cumulées F_i	0.015	0.025	0.070	0.200	0.440	0.720	0.920	0.970	0.990	0.995	1.000

On a vu que la représentation adaptée est l'histogramme des effectifs ou des fréquences associées au tableau des fréquences et des fréquence cumulées:



La médiane est alors un intervalle de valeur! Un algorithme d'interpolation est alors nécessaire pour être plus précis.

Position: médiane d'une var. quant. groupée par intervalles

Soit X continue regroupée en K classes selon une subdivision $(x_0, ..., x_p)$ de $[\min(X), \max(X)]$, $I_i = [x_{i-1}, x_i[$ le i-ième intervalle de la subdivision (ou i-ème classe) d'effectif cumulé N_i. $N = N_K$ est l'effectif total précédemment noté n.

Prop:Procédure

- Construire le tableau des effectifs cumulés $N_i = \sum_{k=1}^{i} n_k$
- Déterminer l'intervalle $I_m = [x_{m-1}, x_m[$ tel que l'effectif cumulé N_m contienne l'individu médian $n/2$
- n_m, a_m: effectif et amplitude de I_m
- N_{m-1}: effectif cumulé de I_{m-1}

La médiane m d'une variable continue X satisfait à l'égalité suivante:

$$m = x_{m-1} + \frac{\frac{n}{2} - N_{m-1}}{n_m} a_m$$

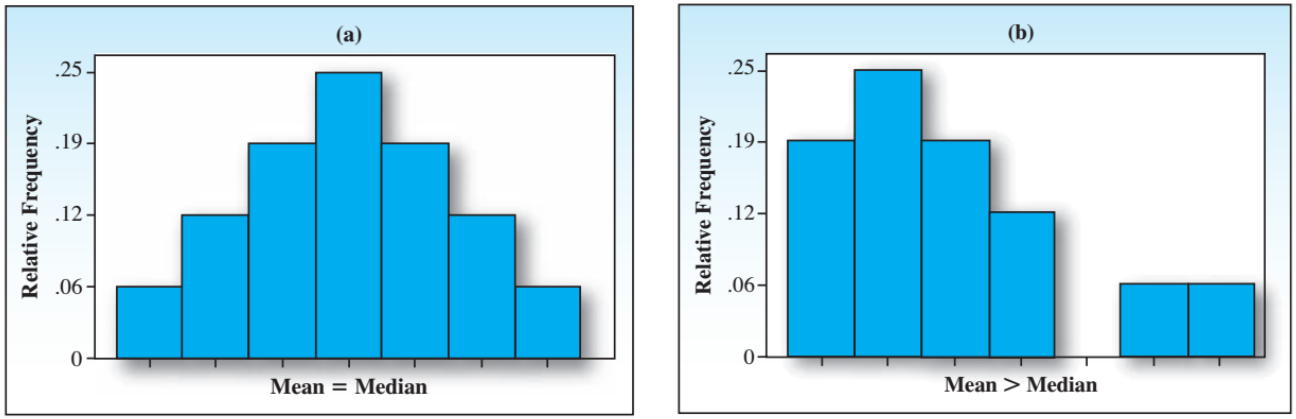
Position: médiane d'une var. quant. groupée par intervalles

Médiane des $n = 200$ temps de vol

Intervalle I_i	[1.5,1.6[	[1.6,1.7[	[1.7,1.8[	[1.8,1.9[	[1.9,2.0[	[2.0,2.1[	[2.1,2.2[	[2.2,2.3[	[2.3,2.4[	[2.4,2.5[	[2.5,2.6[
Centre c_i	1.55	1.65	1.75	1.85	1.95	2.05	2.15	2.25	2.35	2.45	2.55
Effectifs n_i	3	2	9	26	48	56	40	10	4	1	1
Effectifs cumulés N_i	3	5	14	40	88	144	184	194	198	199	200
Fréquences f_i	0.015	0.010	0.045	0.130	0.240	0.280	0.200	0.050	0.020	0.005	0.005
Fréquences cumulées F_i	0.015	0.025	0.070	0.200	0.440	0.720	0.920	0.970	0.990	0.995	1.000

- individu médian $n/2 = 100$
- Intervalle $I_m = [2.0, 2.1[$
- $n_m = 56$; $a_m = 0.1$
- $N_{m-1} = 88$
- $m = 2.0 + 0.1\frac{100-88}{56} = 2.02$

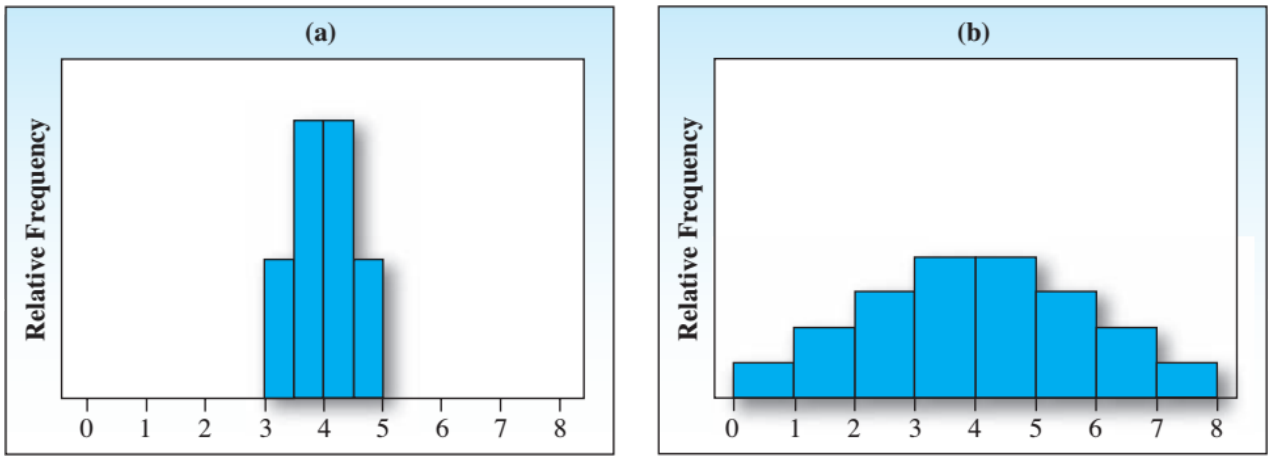
Position: Différence entre moyenne et médiane



- Equivalence en cas de distribution symétrique (comme une gaussienne par ex.)
- la moyenne est très sensible aux données extrêmes

Mesures de variabilité/dispersion : introduction

Deux ensembles de données peuvent avoir le même centre mais avoir des représentations différentes car elles se dispersent différemment par rapport à leur centre.



- Même centre
- (gauche) mesure de 3 à 5 (droite) de 0 à 8

La variabilité ou la dispersion est une caractéristique importante des données.

Mesures de variabilité/dispersion : variance

Def : Variance

La **variance (empirique)** d'un échantillon de n mesures est donnée par:

$$s_n^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x}_n)^2 = \left(\frac{1}{n}\sum_{i=1}^{n} x_i^2\right) - \bar{x}_n^2$$

Remarques

- La variance (théorique) d'une population sera notée σ^2
- Dans le cas d'un calcul à partir d'une table des effectifs avec K intervalles:

$$s_n^2 = \frac{1}{n}\sum_{k=1}^{K} n_k\,(x_k - \bar{x}_n)^2 = \left(\frac{1}{n}\sum_{k=1}^{K} n_k x_k^2\right) - \bar{x}_n^2$$

Variabilité/dispersion: écart-type

Def : Ecart-type

L'**écart-type** est la racine carrée de la variance:

$$s_n = \sqrt{s_n^2}$$

Variabilité/dispersion: quantiles

Def : Quantiles

Les q-**quantiles** découpent l'ensemble des observations en sous-ensembles d'effectifs n/q.
Si $q = 100$, on parle de **percentiles** ou **centiles**
Si $q = 4$, on parle de **quartiles**
Si $q = 10$, on parle de **déciles**

Def : Quantiles d'ordre k d'une variable aléatoire continue X

- un quantile x_k d'ordre k est la plus petite valeur telle qu'au moins une proportion k des réalisations de X lui soient inférieures ou égales, soit pour une variable aléatoire continue:

$$F_X(k) = \mathbb{P}(X \leq x_k) = k$$

- ainsi le quantile d'ordre 0,25 est le premier quartile, ou encore le quantile d'ordre 0,95 est le 95e percentile (ou centile).

Variabilité/dispersion: quantiles / quartiles

Def : Quartiles ou 4-quantiles

- Le **premier quartile** $Q1$, est la valeur de X qui est plus grande que $1/4$ des mesures et est plus petite que les $3/4$ des données restantes.
- Le **second quartile** est la **médiane** m.
- Le **troisième quartile** $Q3$, est la valeur de X qui est plus grande que $3/4$ des mesures et est plus petite que le $1/4$ des données restantes.

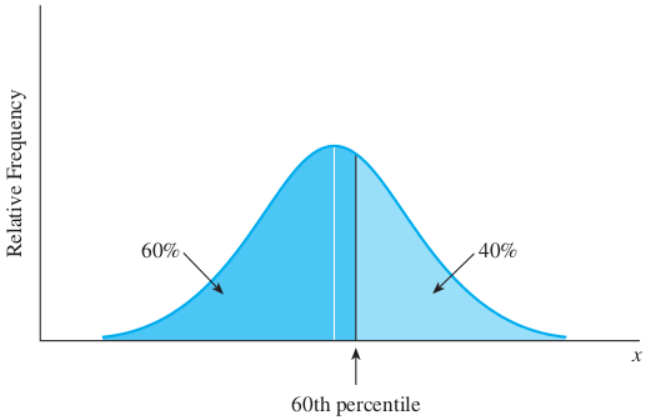


Figure: Quantile [Mendenhall]

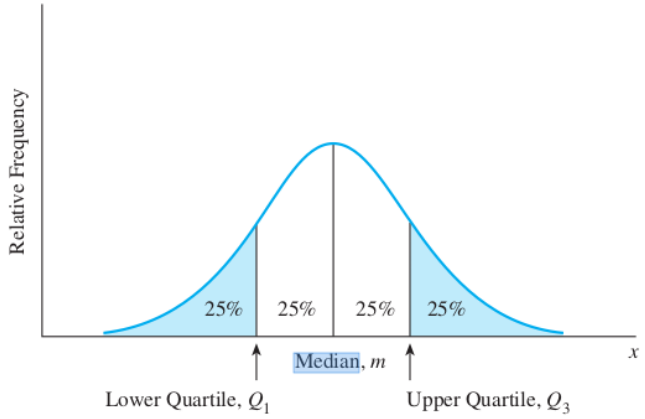


Figure: Quartile [Mendenhall]

Quartiles pour un échantillon

Prop:Procédure de calcul des quartiles

- A partir de la série triée, Q_1 est la valeur de x à la position $.25(n+1)$, et Q_3 est la valeur de x à la position $.75(n+1)$.
- Si $.25(n+1)$ et $.75(n+1)$ ne sont pas des entiers, chaque quartile peut être un intervalle donné par les entiers arrondis à l'inférieur et au supérieur

Trouver les deux quartiles pour cette série de données

- Tri: 4, 8, 9, 11, 11, 13, 16, 18, 20, 25
- $pos_{Q_1} = .25(n+1) = 2.75$ et $pos_{Q_3} = .75(n+1) = 8.25$
- Q_1 et Q_3 sont des intervalles

Quantiles pour une variable continue groupée par intervalles

Soit X continue regroupée en K classes selon une subdivision $(x_0, ..., x_p)$ de $[\min(X), \max(X)]$, $I_i = [x_{i-1}, x_i[$ le i-ième intervalle de la subdivision (ou i-ème classe) d'effectif cumulé N_i. $N = N_K$ est l'effectif total précédemment noté n.

Prop: Procédure d'interpolation pour le calcul du quantile j/q, avec j entier strictement positif et strictement inférieur à q

- Construire le tableau des effectifs cumulés $N_i = \sum_{k=1}^{i} n_k$
- Déterminer l'intervalle $I_q = [x_{q-1}, x_q[$ tel que l'effectif cumulé N_q contienne l'individu jN/q
- n_q, a_q: effectif et amplitude de I_q
- N_{q-1}: effectif cumulé de I_{q-1}

Le quantile j/q d'une variable continue X satisfait à l'égalité suivante:

$$x_{q-1} + \frac{\frac{jN}{q} - N_{q-1}}{n_q} a_q$$

Quartiles pour une variable continue groupée par intervalles

Médiane des $n = 200$ temps de vol, Q_1? Q_3?

Intervalle I_j	[1.5,1.6[	[1.6,1.7[	[1.7,1.8[	[1.8,1.9[	[1.9,2.0[	[2.0,2.1[	[2.1,2.2[	[2.2,2.3[	[2.3,2.4[	[2.4,2.5[	[2.5,2.6[
Centre c_j	1.55	1.65	1.75	1.85	1.95	2.05	2.15	2.25	2.35	2.45	2.55
Effectifs n_j	3	2	9	26	48	56	40	10	4	1	1
Effectifs cumulés N_i	3	5	14	40	88	144	184	194	198	199	200
Fréquences fi	0.015	0.010	0.045	0.130	0.240	0.280	0.200	0.050	0.020	0.005	0.005
Fréquences cumulées	0.015	0.025	0.070	0.200	0.440	0.720	0.920	0.970	0.990	0.995	1.000

- $j = 1$; $q = 4$
- individu 50;
- Intervalle $I_q = [1.9, 2.0[$;
- $n_q = 48$; $a_q = 0.1$;
- $N_{q-1} = 40$;
- $Q1 = 1.9 + 0.1\frac{50-40}{48} = 1.92$

- $j = 3$; $q = 4$
- individu 150;
- Intervalle $I_q = [2.1, 2.2[$
- $n_q = 40$; $a_q = 0.1$;
- $N_{q-1} = 144$
- $Q3 = 2.1 + 0.1\frac{150-144}{40} = 2.115$

Mesures complémentaires de variabilité/dispersion

Def : Mesures complémentaires de variabilité/dispersion

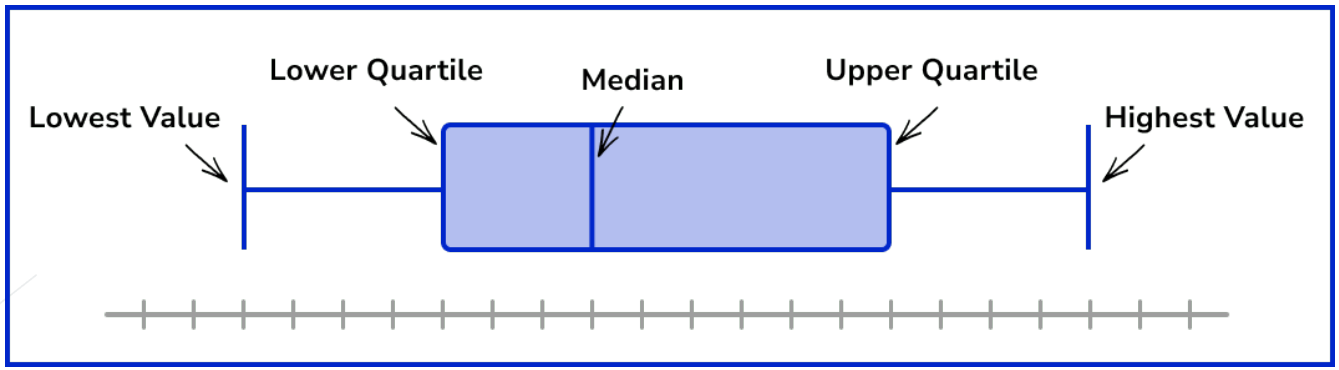
- L'**étendue** est définie par $X(max) - X(min)$
- L'**écart interquartile** est défini par $Q3 - Q1$

Représentation par une boîte à moustaches

Def : Boîte à moustaches/boxplot

La **boîte à moustaches** (box plot en anglais) est une représentation graphique de certains des paramètres de position et de dispersion. Elle permet de visualiser sommairement la répartition des données de la série statistique et les données "extrêmes" (outliers). Elle est constituée :

- d'un diagramme en boîte : un rectangle de bornes Q_1, Q_3 coupé au niveau de la médiane m et éventuellement également au niveau de la moyenne $\bar{x}_n$;
- de moustaches : deux segments joignant Q_1 à $Xmin$ pour l'un et Q_3 à $Xmax$ pour l'autre.



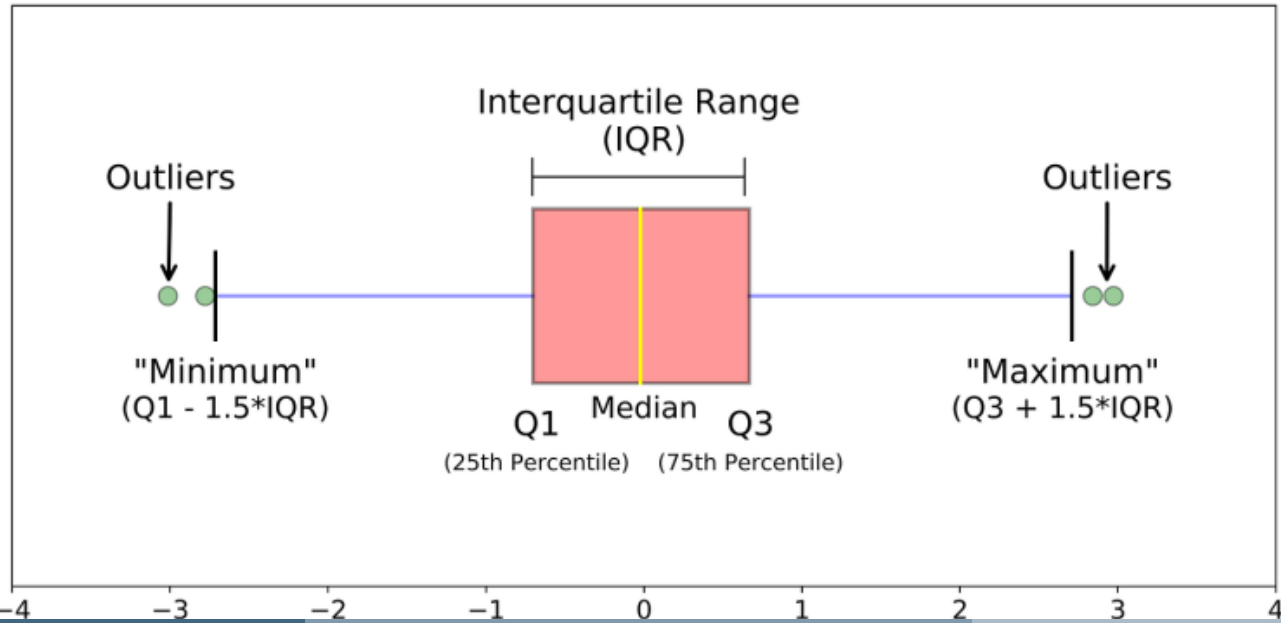
Représentation par une boîte à moustaches

Remarque

Des variantes sur les bornes des moustaches existent. Plutôt que de les faire aller jusqu'à $Xmin, Xmax$, on peut:

- les faire aller jusqu'aux premier et neuvième décile; ou aux cinquième et 95-ième centiles; ou aux premier et 99-ième centiles, etc.
- ou $Q_1 - 1.5.(Q_3 - Q_1)$ et à $Q_3 + 1.5.(Q_3 - Q_1)$ où $Q_3 - Q_1 = IQR$ est l'écart interquartile

On appelle alors **données extrêmes ou outliers** les données à l'extérieur des moustaches.



Mesures liées à la forme de la distribution: asymétrie

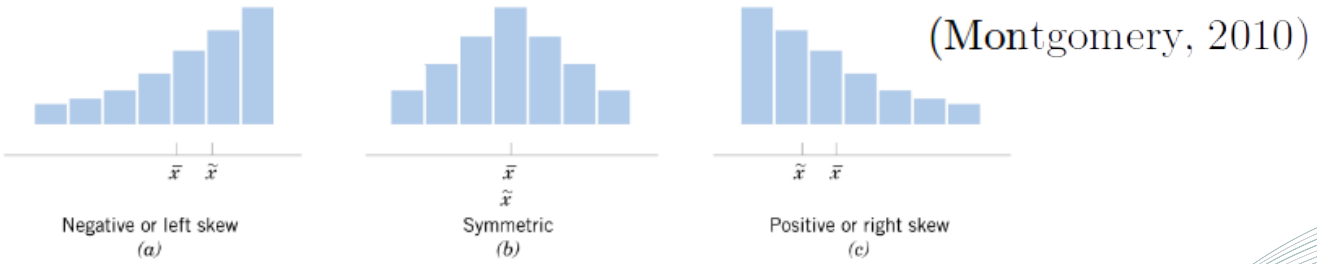
Def : Asymétrie

Le coefficient d'asymétrie de Fisher est la quantité suivante :

$$\gamma_1 = \frac{\sum_{i=1}^{n} (x_i - \bar{x}_n)^3}{n s_n^3}$$

Ce coefficient peut prendre des valeurs positives, négatives ou nulles :

- si la distribution est symétrique, il est nul,
- si la distribution est allongée à gauche (les grandes valeurs sont plus fréquentes que les petites), il est négatif,
- si la distribution est allongée à droite (les petites valeurs sont plus fréquentes que les grandes), il est positif.



(Montgomery, 2010)

Mesures liées à la forme de la distribution: aplatissement

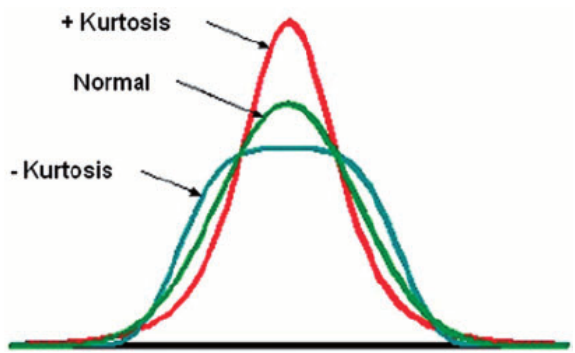
Def : Aplatissement

Le coefficient d'aplatissement de Fisher ou coefficient de Yule est la quantité suivante:

$$\gamma_2 = \frac{\sum_{i=1}^{n} (x_i - \bar{x}_n)^4}{n s_n^4} - 3$$

Une distribution est dite :

- mésokurtique si $\gamma_2 \simeq 0$ (la loi normale).
- leptokurtique si $\gamma_2 > 0$: histogramme plus pointu et queues plus longues (distribution moins aplatie que la distribution normale).
- platykurtique si $\gamma_2 < 0$: histogramme plus arrondi et queues plus courtes (distribution plus aplatie que la distribution normale).



Analyses statistiques bivariées

- Introduction
- Liaison de deux variables qualitatives
- Liaison de deux variables quantitatives
- Liaison entre une variable qualitative et une variable quantitative

Introduction

Analyses statistiques bivariées

Analyses statistiques bivariées: introduction

- Les analyses à mener ne peuvent se limiter à l'analyse d'une variable:
  - La compréhension passe généralement par plusieurs variables
  - On comprend bien que pour développer un hélico qui vole longtemps on doit trouver le meilleur ensemble de paramètres
  - D'où une analyse multivariée . . . qui commence par l'**analyse bivariée**.
- Questions:
  - deux variables sont elles **liées** ou sont elles **indépendantes**?
  - Quelle est la **nature de cette dépendance**?
- La réponse à ces questions (et les outils à utiliser) **dépend de la nature des deux variables X et Y**
- on distingue les cas suivants:
  - 2 variables quantitatives
  - 1 variable quantitative et variable qualitative
  - 2 variables qualitatives (ou groupées par intervalles)

Définitions et notations

Considérons deux variables X et Y qui peuvent être soit qualitatives, quantitatives discrètes ou continues.

Le but de cette section est d'étudier les relations entre X et Y, ce qui revient, mathématiquement, à étudier les **propriétés du couple de VA (X,Y)**. On définit dans ce chapitre essentiellement deux types de quantités, celles dites :

- **marginales** qui ne dépendent que d'une seule variable mais pas des deux ;
- **conditionnelles** qui renseignent sur un critère en fonction des valeurs ou modalités de l'autre.

On a la série statistique double sous forme brute pour un échantillon de taille n: $\{(X(1), Y(1)), \ldots, (X(n), Y(n))\}$:

- les modalités/valeurs/centre de classes de la variables X sont $(p <= n)$: $\{x_1, \ldots, x_p\}$
- les modalités/valeurs/centre de classes de la variables Y sont $(q <= n)$: $\{y_1, \ldots, y_q\}$
- l'indice i servira exclusivement à indexer des données relatives à X, et l'indice j exclusivement à indexer des données relatives à Y.

Liaison de deux variables qualitatives

Analyses statistiques bivariées

Liaison de deux variables qualitatives

Rem:Variables concernées

Les outils présentés dans cette partie sont valables pour **deux variables qualitatives et/ou quantitatives discrètes ou continues regroupées par intervalles**...toute variable qui donne la possibilité de construire une table statistique des effectifs.

Cas de l'hélicoptère : variables qualitatives "coupe" avec deux modalités et "type d'hélico" avec quatre modalités

Numéro du lancer	Helico	Coupe	Temps
1	A	NON	1.97
2	A	NON	2.03
3	A	NON	2.1
4	A	NON	1.86
5	A	NON	2
6	A	NON	2.14
7	A	NON	2.07
8	A	NON	2.19
9	B	NON	2.52
10	B	NON	3.01
11	B	NON	2.69
12	B	NON	2.71
13	B	NON	2.93
14	B	NON	2.83
15	B	NON	2.7
16	B	NON	3.11
17	C	NON	2.52
18	C	NON	2.25
19	C	NON	2.47
20	C	NON	2.44
21	C	NON	2.44
22	C	NON	2.45
23	C	NON	2.36
24	C	NON	2.27
25	D	OUI	1.87
26	D	OUI	2.12
27	D	OUI	1.84
28	D	OUI	2.08
29	D	OUI	1.98
30	D	OUI	1.98
31	D	OUI	1.78
32	D	OUI	1.88

n_{ij}	A	B	C	D
NON	8	8	8	0
OUI	0	0	0	8

Table statistique des effectifs

Soient $i \in \{1, \ldots, p\}$ et $j \in \{1, \ldots, q\}$

Def:Table statistique des effectifs

L'**effectif du couple** (x_i, y_j), noté n_{ij}, est le nombre d'individus associés à la fois à x_i pour X et à y_j pour Y et sa **fréquence**, noté f_{ij}, est le quotient de son effectif par la taille de la population :

$$n_{ij} = \text{card}\{u \in \text{échantillon } | X(u) = x_i \text{ et } Y(u) = y_j\} \text{ et } f_{ij} = \frac{n_{ij}}{n}$$

Exemple

n_{ij}	A	B	C	D
NON	8	8	8	0
OUI	0	0	0	8

f_{ij}	A	B	C	D
NON	8/32	8/32	8/32	0
OUI	0	0	0	8/32

Effectifs marginaux et fréquences marginales

Soient $i \in \{1, \ldots, p\}$ et $j \in \{1, \ldots, q\}$

Def:Effectifs marginaux

L'effectif marginal de x_i (respectivement y_j), noté $n_{i\bullet}$ (respectivement $n_{\bullet j}$), est l'effectif de x_i (respectivement y_j) pour la variable X (respectivement Y) :

$$n_{i\bullet} = \sum_{j=1}^{q} n_{ij} \text{ et } n_{\bullet j} = \sum_{i=1}^{p} n_{ij}$$

Def:Fréquences marginales

La fréquence marginale de x_i (respectivement y_j), notée $f_{i\bullet}$ (respectivement $f_{\bullet j}$), est l'effectif de x_i (respectivement y_j) pour la variable X (respectivement Y) :

$$f_{i\bullet} = \frac{n_{i\bullet}}{n} = \sum_{j=1}^{q} f_{ij} \text{ et } f_{\bullet j} = \frac{n_{\bullet j}}{n} = \sum_{i=1}^{p} f_{ij}$$

Effectifs marginaux et fréquences marginales

Soient $i \in \{1, \ldots, p\}$ et $j \in \{1, \ldots, q\}$

Prop:

$$\sum_{i=1}^{p}\sum_{j=1}^{q} n_{ij} = n, \sum_{i,j} f_{ij} = 1$$

$$\sum_{i=1}^{p} n_{i\bullet} = \sum_{j=1}^{q} n_{\bullet j} = n \text{ et } \sum_{i=1}^{p} f_{i\bullet} = \sum_{j=1}^{q} f_{\bullet j} = 1$$

somme sur les lignes ou les colonnes

n_{ij}	A	B	C	D	$n_{i,\bullet}$
NON	8	8	8	0	24
OUI	0	0	0	8	8
$n_{\bullet,j}$	8	8	8	8	32

f_{ij}	A	B	C	D	$f_{i,\bullet}$
NON	8/32	8/32	8/32	0/32	24/32
OUI	0	0	0	8/32	8/32
$f_{\bullet,j}$	8/32	8/32	8/32	8/32	1

Tables de contingence des effectifs et des fréquences

Effectifs

X \ Y	y_1	$\cdots$	y_j	$\cdots$	y_q	Total
x_1	n_{11}	$\cdots$	n_{1j}	$\cdots$	n_{1q}	$n_{1\bullet}$
$\vdots$	$\vdots$		$\vdots$		$\vdots$	$\vdots$
x_i	n_{i1}	$\cdots$	n_{ij}	$\cdots$	n_{iq}	$n_{i\bullet}$
$\vdots$	$\vdots$		$\vdots$		$\vdots$	$\vdots$
x_p	n_{p1}	$\cdots$	n_{pj}	$\cdots$	n_{pq}	$n_{p\bullet}$
Total	$n_{\bullet 1}$	$\cdots$	$n_{\bullet j}$	$\cdots$	$n_{\bullet q}$	n

Fréquences

X \ Y	y_1	$\cdots$	y_j	$\cdots$	y_q	Total
x_1	f_{11}	$\cdots$	f_{1j}	$\cdots$	f_{1q}	$f_{1\bullet}$
$\vdots$	$\vdots$		$\vdots$		$\vdots$	$\vdots$
x_i	f_{i1}	$\cdots$	f_{ij}	$\cdots$	f_{iq}	$f_{i\bullet}$
$\vdots$	$\vdots$		$\vdots$		$\vdots$	$\vdots$
x_p	f_{p1}	$\cdots$	f_{pj}	$\cdots$	f_{pq}	$f_{p\bullet}$
Total	$f_{\bullet 1}$	$\cdots$	$f_{\bullet j}$	$\cdots$	$f_{\bullet q}$	1

Rem:

En extrayant une colonne du tableau de contingence:

- on peut obtenir une distribution conditionnelle de X (cf. planche suivante).
- l'extraction de la colonne j permet de répondre à la question «Sachant que Y vaut y_j , comment se comporte X ? ».

En extrayant une ligne du tableau de contingence:

- on peut obtenir une distribution conditionnelle de Y.
- l'extraction de la ligne i permet de répondre à la question «Sachant que X vaut x_i, comment se comporte Y ? ».

Fréquences conditionnelles

Ainsi, une distribution conditionnelle est l'étude d'un critère lorsque l'autre reste fixe. On note $X|_{Y=y_j}$ (respectivement $Y|_{X=x_i}$) la distribution conditionnelle de X sachant $Y = y_j$ (respectivement de Y sachant $X = x_i$).

Def:Fréquence conditionnelle

Soient $i \in \{1, \ldots, p\}$ et $j \in \{1, \ldots, q\}$. La **fréquence conditionnelle** de x_i sachant y_j (respectivement y_j sachant x_i), notée $f_{i|Y=y_j}$ ou $f_{i|j}$ (respectivement $f_{j|X=x_i}$ ou $f_{j|i}$), est la fréquence d'occurrence de x_i dans la colonne j (respectivement y_j dans la ligne i) du tableau de contingence :

$$f_{i|Y=y_j} = \frac{n_{ij}}{n_{\bullet j}} \text{ et } f_{j|X=x_i} = \frac{n_{ij}}{n_{i\bullet}}$$

Prop:

$$\forall j \in \{1, \ldots, q\}, \sum_{i=1}^{p} f_{i|Y=y_j} = 1 \text{ et } \forall j \in \{1, \ldots, q\}, \sum_{j=1}^{q} f_{j|X=x_i} = 1$$

Fréquences conditionnelles

Parmi la sous population conditionnelle, quelle sont les fréquences associées?

Fréquences conditionnelles

n_{ij}	A	B	C	D	$n_{i\bullet}$
NON	8	8	8	0	24
OUI	0	0	0	8	8
$n_{\bullet j}$	8	8	8	8	32

$f_{i\|Y=y_j}$	A	B	C	D
NON	1	1	1	0
OUI	0	0	0	1
Total	1	1	1	1

$f_{j\|X=x_i}$	A	B	C	D	Total
NON	1/3	1/3	1/3	0	1
OUI	0	0	0	1	1

Table des profils-colonnes et profils-lignes

Def:Profils lignes et profils colonnes

La table des **profils-colonne** représente les distributions conditionnelles de $X|_Y$. Le tableau des **profils-ligne** représente les distributions conditionnelles $Y|_X$.

$X\|_Y$ \ Y	y_1	$\cdots$	y_q
x_1	$f_{1\|Y=y_1}$	$\cdots$	$f_{1\|Y=y_q}$
$\vdots$	$\vdots$		$\vdots$
x_p	$f_{p\|Y=y_1}$	$\cdots$	$f_{p\|Y=y_q}$
Total	1	$\cdots$	1

Tableau des profils-colonne

X \ $Y\|_X$	y_1	$\cdots$	y_q	Total
x_1	$f_{1\|X=x_1}$	$\cdots$	$f_{q\|X=x_1}$	1
$\vdots$	$\vdots$			$\vdots$
x_p	$f_{1\|X=x_p}$	$\cdots$	$f_{q\|X=x_p}$	1

Tableau des profils-ligne

Prop:

$$\forall j \in \{1,\dots,q\} \text{ et } j \in \{1,\dots,q\},$$
$$f_{ij} = f_{i|Y=y_j} f_{\bullet j} \text{ et } f_{ij} = f_{j|X=x_i} f_{i\bullet}$$

Remarque sur les fréquences

Toutes les fréquences sont des estimations de probabilité d'une population à partir d'un échantillon...Lesquelles?

- fréquence $f_{ij} \longrightarrow \mathbb{P}(X = x_i \text{ et } Y = y_j)$
- fréquence marginale $f_{i\bullet} \longrightarrow \mathbb{P}(X = x_i)$
- fréquence conditionnelle $f_{i|Y=y_j} \longrightarrow \mathbb{P}(X = x_i | Y = y_j)$

Indépendance de deux variables qualitatives

Def:indépendance

Les variables X et Y sont dites indépendantes si

$$\forall i \in \{1, \ldots, p\} \text{ et } j \in \{1, \ldots, q\}, f_{ij} = f_{i\bullet} f_{\bullet j}$$

Prop:

Les assertions suivantes sont équivalentes

X et Y sont indépendantes.

$\forall (i,j) \in \{1, \ldots, p\} \times \{1, \ldots, q\}, n_{ij} = \frac{n_{i\bullet} n_{\bullet j}}{n}$

$\forall (i,j) \in \{1, \ldots, p\} \times \{1, \ldots, q\}, f_{i|Y=y_j} = f_{i\bullet}$

$\forall (i,j) \in \{1, \ldots, p\} \times \{1, \ldots, q\}, f_{j|X=x_i} = f_{\bullet j}$

Écart à l'indépendance de deux variables qualitatives

En pratique, on va quantifier l'écart à l'indépendance. Pour cela, on peut calculer la quantité suivante:

Def:χ^2 observé

$$\chi^2 = n \sum_{i,j} \frac{(f_{ij} - f_{i\bullet} f_{\bullet j})^2}{f_{i\bullet} f_{\bullet j}} = \sum_{i,j} \frac{\left(n_{ij} - \frac{n_{i\bullet} n_{\bullet j}}{n}\right)^2}{\frac{n_{i\bullet} n_{\bullet j}}{n}}$$

Prop:

- Le χ^2 est toujours positif ou nul
- $\chi^2 = 0 \Leftrightarrow$ X et Y sont indépendantes
- Plus le χ^2 est grand, plus les variables sont dépendantes

Écart à l'indépendance de deux variables qualitatives

Il se trouve que le χ^2 observé croît avec la taille de la population. Pour cette raison, il est utile de le renormaliser de manière adéquate.

Def:Mesures dérivées du χ^2 observé

- Φ^2 : $\Phi^2 = \frac{\chi^2}{n}$
- Tschuprow: $T = \frac{\Phi^2}{\sqrt{(p-1)(q-1)}}$
- V de Cramer: $V = \sqrt{\frac{\Phi^2}{\min(p,q)-1}} \in \{0,1\}$

On verra plus tard une méthodologie permettant d'apporter une réponse à cette question (test non paramétrique du χ^2 d'indépendance)

Liaison de deux variables quantitatives

Analyses statistiques bivariées

Liaison de deux variables quantitatives (1/2)

Rem:Variables et données concernées

Les outils présentés dans cette partie sont valables uniquement pour :

- 2 variables **quantitatives** $\mathbf{X}$ et $\mathbf{Y}$
- **discrètes** ou **continues**
- **regroupées dans une table des effectifs** ou **non**

Ainsi, nous pourrons donc utiliser

- les **données brutes** (comme dans l'exemple ci-dessous)
- **ou** les **données brutes regroupées** dans une **table des effectifs** $\mathbf{n_{ij}}$ ou des **fréquences** $\mathbf{f_{ij}}$ (comme dans la partie précédente)

Liaison de deux variables quantitatives (2/2)

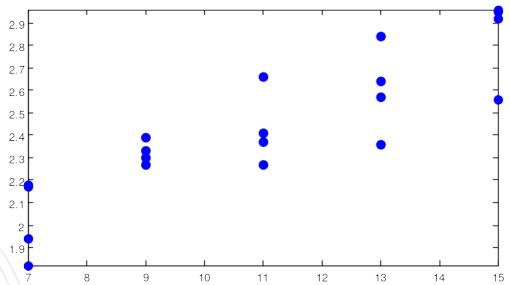
Données brutes: $\{(x_1, y_1), \ldots, (x_n, y_n)\}$

Lancer	Ha	Temps
1	7	1.94
2	9	2.3
3	11	2.66
4	13	2.36
5	15	2.96
6	7	2.18
7	9	2.33
8	11	2.37
9	13	2.64
10	15	2.56
11	7	1.82
12	9	2.39
13	11	2.41
14	13	2.57
15	15	2.92
16	7	2.17
17	9	2.27
18	11	2.27
19	13	2.84
20	15	2.95

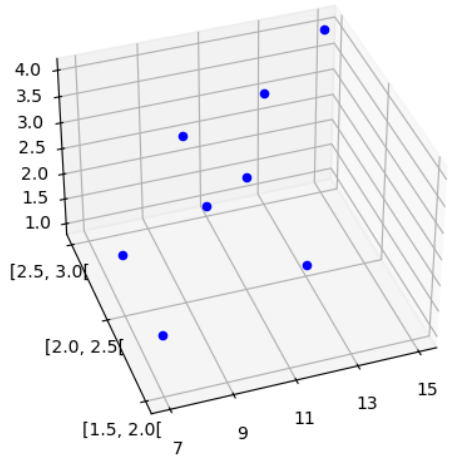
Table des effectifs $\mathbf{n_{ij}}$

Ha \ Temps	$[1.5, 2.[$	$[2., 2.5[$	$[2.5, 3.[$	$\sum_j \mathbf{n_{ij}} = \mathbf{n_{i,\bullet}}$
7	2	2		**4**
9		4		**4**
11		3	1	**4**
13		1	3	**4**
15			4	**4**
$\sum_i \mathbf{n_{ij}} == \mathbf{n_{\bullet,j}}$	**2**	**10**	**8**	**20**

Possible de représenter les données brutes par un nuage de n points dans $\mathbb{R}^2$



Temps vs H_a



Temps vs H_a vs $\mathbf{n_{ij}}$

Décrire les deux variables marginales: moyenne, variance

Marginale signifie que l'on considère les variables X et Y indépendamment l'une de l'autre.
Pour les données brutes (série statistique), se reporter aux formules définies pour l'analyse univariée.

Def:Moyenne marginale à partir d'une **table des effectifs**

X prend p valeurs x_i d'effectif $n_{i\bullet}$ et Y prend q valeurs $n_{\bullet j}$

- Moyennes marginales $\bar{x}_n$ et $\bar{y}_n$,

$$\bar{x}_n = \frac{1}{n}\sum_{i=1}^{p} n_{i\bullet} x_i \text{ et } \bar{y}_n = \frac{1}{n}\sum_{j=1}^{q} n_{j\bullet} y_j$$

- variances marginales s_X^2 et s_Y^2

$$s_{n,X}^2 = \frac{1}{n}\sum_{i=1}^{p} n_{i\bullet}\left(x_i - \bar{x}_n\right)^2 \text{ et } s_{n,Y}^2 = \frac{1}{n}\sum_{j=1}^{q} n_{j\bullet}\left(y_j - \bar{y}_n\right)^2$$

- écart-types marginaux $s_{n,X}$ et $s_{n,Y}$: $s_{n,X} = \sqrt{s_{n,X}^2}$ et $s_{n,X} = \sqrt{s_{n,Y}^2}$

Quantifier le lien: covariance

Soit X et Y deux variables quantitatives,

Def:Covariance à partir des **données brutes**

$$\mathrm{Cov}\{X,Y\} = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x}_n)(y_i - \bar{y}_n) = \frac{1}{n}\left(\sum_{i=1}^{n} x_i y_i\right) - \bar{x}_n \bar{y}_n$$

Def:Covariance à partir des **données d'une table d'effectifs** ou de fréquences

$$\begin{aligned}\mathrm{Cov}\{X,Y\} &= \frac{1}{n}\sum_{i=1}^{p}\sum_{j=1}^{q} n_{ij}(x_i - \bar{x}_n)(y_j - \bar{y}_n) \\ &= \left(\frac{1}{n}\sum_{i=1}^{p}\sum_{j=1}^{q} n_{ij} x_i y_j\right) - \bar{x}_n \bar{y}_n\end{aligned}$$

Quantifier le lien: Coefficient de corrélation linéaire

Def:Coefficient de corrélation linéaire

Le coefficient de corrélation ρ de X et Y est défini par

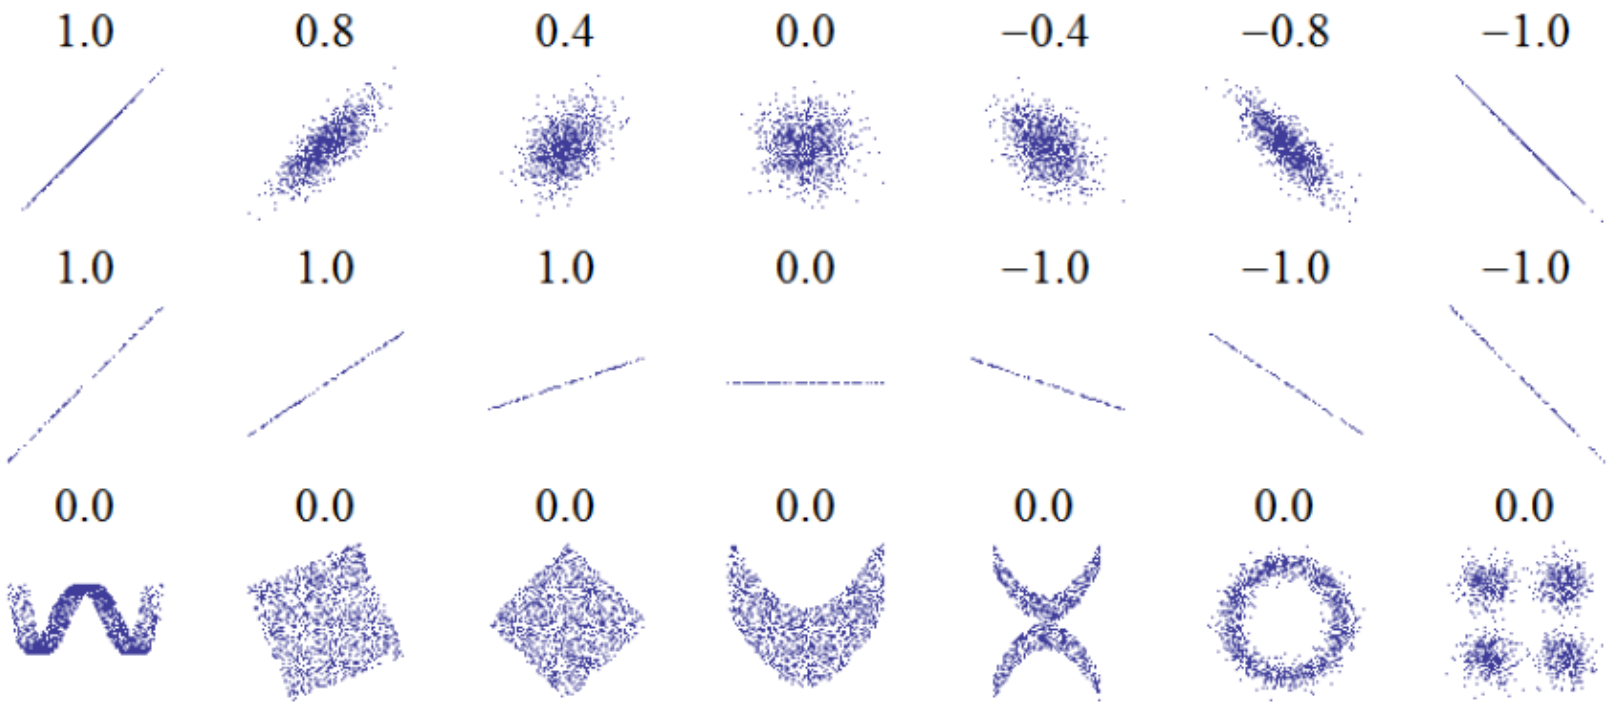
$$\rho_{X,Y} = \frac{\mathrm{Cov}\{X,Y\}}{s_{n,X}\, s_{n,Y}} \in [-1,+1]$$

Si $\rho_{X,Y} =$

- 1, il existe une relation linéaire parfaite entre X et Y. De plus, quand X augmente, Y augmente.
- 0, il n'existe pas de relation linéaire entre X et Y
- -1, il existe une relation linéaire parfaite entre X et Y. De plus, quand X augmente, Y diminue.

Quantifier le lien: Coefficient de corrélation linéaire

Lien entre la valeur de $\rho_{X,Y}$ et la forme du nuage de points:



Quantifier le lien: régression linéaire

On suppose ici qu'il y a une relation linéaire importante entre X et Y . Le principe d'un ajustement affine, aussi appelé régression linéaire, est de déterminer la « meilleure » droite pour exprimer la liaison affine entre X et Y, c'est-à-dire la droite qui approxime au mieux le nuage de points.

Méthodes des moindres carrés

Si X n'est pas constante, la droite de régression par la méthode des moindres carrés de Y en fonction de X est la droite d'équation $y = \hat{a}x + \hat{b}$ dans le repère du nuage de points de (X,Y) avec:

$$\hat{a} = \rho_{X,Y} \frac{s_{n,Y}}{s_{n,X}} \text{ et } \hat{b} = \bar{y}_n - \rho_{X,Y} \frac{s_{n,Y}}{s_{n,X}} \bar{x}_n$$

Quantifier le lien: Exemple

Temps de vol des hélico en fonction de H_a

Lancer	Ha	Temps
1	7	1.94
2	9	2.3
3	11	2.66
4	13	2.36
5	15	2.96
6	7	2.18
7	9	2.33
8	11	2.37
9	13	2.64
10	15	2.56
11	7	1.82
12	9	2.39
13	11	2.41
14	13	2.57
15	15	2.92
16	7	2.17
17	9	2.27
18	11	2.27
19	13	2.84
20	15	2.95

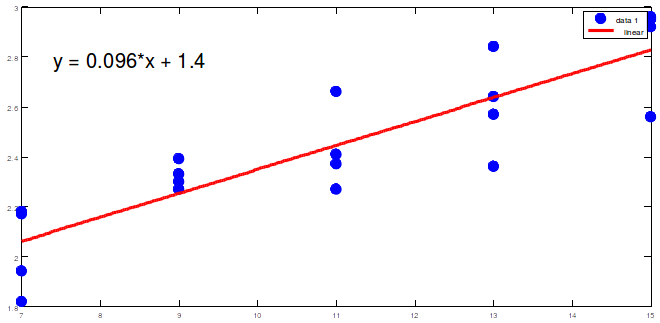


Figure: $\rho = 0.88$

Liaison entre une variable qualitative et une variable quantitative

Analyses statistiques bivariées

Liaison entre deux variables: qualitative vs quantitative

Variables et données concernées

Les outils présentés dans cette partie sont valables uniquement pour **une variable qualitative et une variable quantitative discrète ou continue regroupée par intervalle**. Nous allons donc utiliser les données brutes.

Hélico Vs Temps de vol

- Y a-t-il un effet de la variable qualitative sur la quantitative?
- Y a-t-il un lien entre les caractéristiques statistiques des temps de vol pour chacune des valeurs de Hélico?
- Les stats dépendent-elles du type d'hélico?
- On parlera d'**analyse de la variance** (dispersion des données)

Numéro du lancer	Helico	Temps
1	A	1.97
2	A	2.03
3	A	2.1
4	A	1.86
5	A	2
6	A	2.14
7	A	2.07
8	A	2.19
9	B	2.52
10	B	3.01
11	B	2.69
12	B	2.71
13	B	2.93
14	B	2.83
15	B	2.7
16	B	3.11
17	C	2.52
18	C	2.25
19	C	2.47
20	C	2.44
21	C	2.44
22	C	2.45
23	C	2.36
24	C	2.27
25	D	1.87
26	D	2.12
27	D	1.84
28	D	2.08
29	D	1.98
30	D	1.98
31	D	1.78
32	D	1.88

Liaison entre deux variables: qualitative vs quantitative

L'analyse de la liaison consiste à découper l'échantillon en plusieurs sous-échantillons (un pour chaque valeur de la variable qualitative)

Hélico Vs Temps de vol

Numéro du lancer	Helico	Temps
1	A	1,97
2	A	2,03
3	A	2,1
4	A	1,86
5	A	2
6	A	2,14
7	A	2,07
8	A	2,19
9	B	2,52
10	B	3,01
11	B	2,69
12	B	2,71
13	B	2,93
14	B	2,83
15	B	2,7
16	B	3,11
17	C	2,52
18	C	2,25
19	C	2,47
20	C	2,44
21	C	2,44
22	C	2,45
23	C	2,36
24	C	2,27
25	D	1,87
26	D	2,12
27	D	1,84
28	D	2,08
29	D	1,98
30	D	1,98
31	D	1,78
32	D	1,88

Définitions et notations

Soient

- X la variable qualitative prenant p valeurs $\{x_1, \ldots, x_p\}$ d'effectifs $\{n_1, \ldots, n_p\}$
- $\sum_{i=1}^{p} n_i = n$
- Y la variable quantitative de moyenne $\bar{y}_n$ et de variance $s^2_{n,Y}$
- chaque valeur x_i de X définit un sous échantillon Y_i d'effectifs $\{n_1, \ldots, n_p\}$ possédant une moyenne $\bar{y}_i$ et une variance associée s^2_{n,Y_i} :

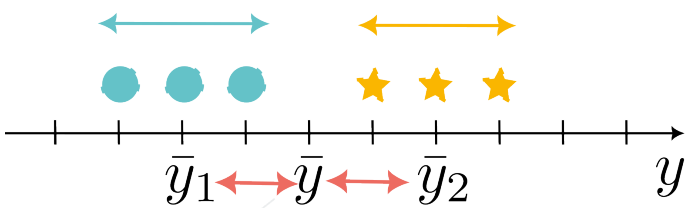
Formule de décomposition de la variance

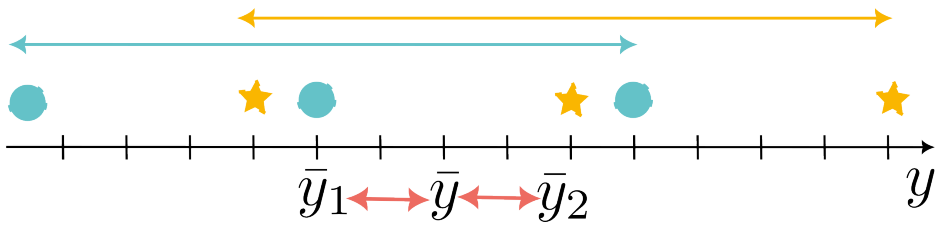
Prop:

La variance totale se décompose en somme de la variance interclasse et intraclasse:

$$
\begin{aligned}
s^2_{n,Y} &= \frac{1}{n}\sum_{i=1}^{p} n_i \left(\bar{y}_i - \bar{y}\right)^2 &&+\frac{1}{n}\sum_{i=1}^{p} n_i s^2_{n,Y_i} \\
&= s^2_B &&+s^2_W \\
&= \text{variance inter-classe} &&+\text{variance intra-classe}
\end{aligned}
$$

Illustration





Quantifier la liaison entre deux variables: quantitative vs qualitative

Rapport de corrélation

Def:Rapport de corrélation

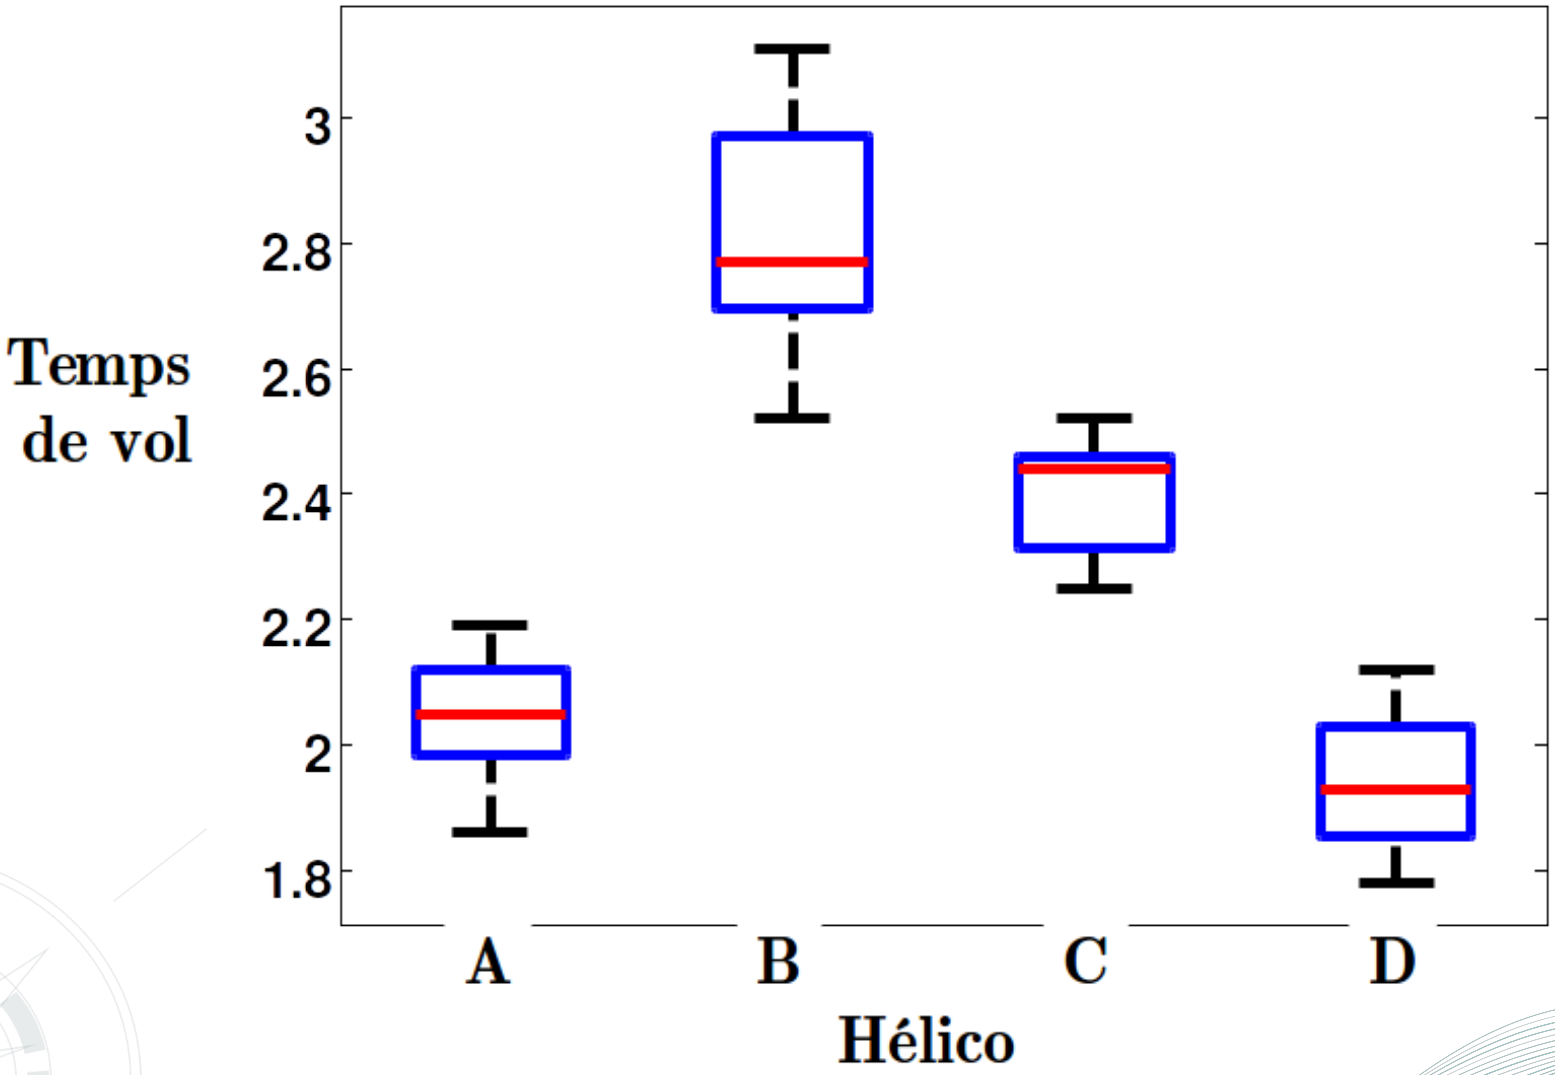
La rapport de corrélation entre X variable qualitative et Y variable quantitative est défini par:

$$S_{Y/X} = \sqrt{\frac{s_B^2}{s_{n,Y}^2}} \in \{0, 1\}$$

- $S_{Y/X}$ exprime l'impact de la partition en p valeurs de X sur la dispersion des mesures de Y
- En pratique, si $S_{Y/X}$
  - est proche de 0 $\Rightarrow s_B^2 \ll s_W^2 \Rightarrow$ faible séparabilité des sous-échantillons $\Rightarrow$ la partition de X n'a aucun impact sur la variable Y
  - est proche de 1 $\Rightarrow s_B^2 \gg s_W^2 \Rightarrow$ bonne séparabilité des sous-échantillons $\Rightarrow$ la partition de X a un impact sur la variable Y

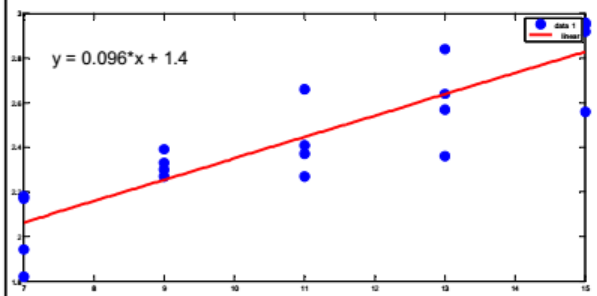
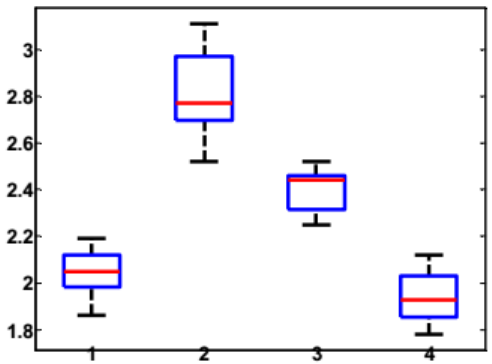
Représenter la liaison entre une variable quantitative et qualitative

Une boîte à moustaches par modalité de la variable qualitative



Analyse des statistiques bivariées

Résumé des trois cas possibles

Quantitatif Vs Quantitatif	Quantitatif Vs Qualitatif	Qualitatif Vs Qualitatif
Nuage de points 	**Boites à moustache parallèles** 	**Table de contingence**

n_{ij}	A	B	C	D
Oui	8	8	8	0
Non	0	0	0	8

Coefficient de corrélation linéaire

$$\rho = \frac{\mathrm{Cov}(X,Y)}{S_N^X S_N^Y} \in [-1,1]$$

Rapport de corrélation

$$S_{Y/X} = \sqrt{\frac{S_B^2}{S_{N,Y}^2}} \in [0,1]$$

Distance du χ^2

$$\chi^2 = \sum_{i=1}^{r}\sum_{j=1}^{s} \frac{\left(n_{ij} - \frac{n_{i,\bullet} n_{\bullet,j}}{N}\right)^2}{\frac{n_{i,\bullet} n_{\bullet,j}}{N}}$$

Figure

Plan du cours

PART 1: Introduction

PART 2: Éléments d'analyse statistique descriptive

PART 3: Éléments de statistique inférentielle

Estimations ponctuelle et par intervalle de confiance à partir d'un échantillon

- Introduction
- Intervalles de confiance pour un échantillon
- Intervalle de confiance de la moyenne d'une distribution normale, σ^2 connue
- Intervalle de confiance de la moyenne d'une distribution normale, σ^2 inconnue
- Intervalle de confiance de la moyenne d'une distribution dans le cas d'un grand échantillon
- Intervalle de confiance pour la proportion d'un grand échantillon
- Méthode générale pour définir un intervalle de confiance d'un paramètre θ

Introduction

Estimations ponctuelle et par intervalle de confiance à partir d'un échantillon

Introduction

Def:Inférence statistique, estimation de paramètres et tests d'hypothèses

- Les méthodes statistiques sont utilisées pour **prendre des décisions et tirer des conclusions sur des populations** statistiques.
- Ces techniques **utilisent l'information contenue dans un échantillon** issue d'une population pour **inférer** des conclusions.
- L'**inférence statistique** peut être divisée en deux axes:
  - l'**estimation de paramètres** (ex:estimation du temps moyen de vol; quelles sont les valeurs plausibles de la moyenne du temps de vol?)
  - les **tests d'hypothèses** (ex:indépendance de deux paramètres de l'hélico; distribution du temps de vol?)

Dans la suite du cours, on va aborder aussi **deux grands types de problèmes pratiques**:

- J'ai un échantillon de données et je veux savoir si c'est conforme à des spécifications constructeurs, à une théorie, à un modèle physique
- J'ai deux (ou plus) échantillons de données et je veux les comparer.

Quelques définitions et notions importantes

Def: n-échantillon | statistique

- Les VA $X_1, X_2, \ldots, X_n$ forment un **n-échantillon** si:
  - les X_i sont des VA indépendantes.
  - chaque VA X_i a la même distribution de probabilité (loi ou densité) *i.e.* les VA sont identiquement distribuées.
- Une **statistique** est n'importe quelle fonction d'un n-échantillon.
- La distribution de probabilité d'une statistique est appelée **distribution d'échantillonnage (sampling distribution)**.

Estimation ponctuelle d'un paramètre

L'inférence statistique ambitionne de tirer des conclusions sur un ou plusieurs paramètres d'une population. Une étape importante est donc d'obtenir des estimateurs des paramètres.

- Une **estimée ponctuelle** est une valeur raisonnable d'un paramètre d'une population.
- Cette valeur est la réalisation d'une statistique d'un n-échantillon.
- Par exemple, $\bar{X}_n$ et S_n^2, sont des statistiques, fonctions de des VA $X_1, X_2, \ldots, X_n$ et donc aussi des VA.

Estimateur/Estimation ponctuel.le d'un paramètre (cas déterministe dans ce cours)

Rem:Notations

Il est utile d'avoir une **notation générale** pour représenter le paramètre qu'on cherche à estimer.

- Nous utiliserons θ pour représenter ce paramètre qui pourra représenter dans la suite la moyenne μ, la variance σ^2, une proportion, etc.
- Nous allons estimer ce paramètre par une statistique $\hat{\Theta} = h(X_1, X_2, \ldots, X_n)$, VA appelée **estimateur ponctuel**.
- Une fois qu'un échantillon de données a été collecté, $\hat{\Theta}$ prend une valeur particulière $\hat{\theta}$ appelée **estimée**. L'estimée est ainsi une réalisation de l'estimateur.

Estimateur/Estimée ponctuel.le d'un paramètre (déterministe)

Supposons que la VA X est distribuée selon une gaussienne avec une espérance/moyenne de la population μ inconnue

- La moyenne de l'échantillon $\bar{X}_n$ est un estimateur ponctuel (une VA) de la moyenne de la population μ.
- Sur un échantillon de données collecté, la valeur calculée $\bar{x}_n$ est l'estimée ponctuelle de μ.
- Ainsi, si $x_1 = 25, x_2 = 30, x_3 = 29$, et $x_4 = 31$, l'estimée de μ est $\bar{x}_n = \frac{25+30+29+31}{4} = 28.75$.

Estimateur/Estimée ponctuel.le d'un paramètre

Quelques propriétés attendues des estimateurs

- Absence de biais $b(\hat{\Theta})$: un estimateur non biaisé donnera **en moyenne** la valeur vraie du paramètre.
- Variance $var(\hat{\Theta})$ minimale : un estimateur est d'autant plus précis que sa variance est faible
- Biais et variance de l'estimateur peuvent être simultanément minimisés via l'**erreur quadratique moyenne** $EQM(\hat{\Theta}) = var(\hat{\Theta}) + b^2(\hat{\Theta})$.

- L'estimateur moyenne arithmétique est non biaisé et de variance minimale.
- L'estimateur de la variance S_n^2 donné ci-dessus est biaisé, l'estimateur non biaisé S_{n-1}^2 de la variance est un peu différent et relié à l'estimateur biaisé par la formule : $S_{n-1}^2 = \frac{n}{n-1} S_n^2$
- Ce qui explique la popularité de l'estimateur biaisé de la variance est sa variance plus faible qui donne une estimation plus précise au sens de l'EQM : c'est une illustration du dilemme biais-variance des estimateurs.

Quelques paramètres et leur estimateur ponctuel (statistique)

Les problèmes d'estimation se rencontrent fréquemment en ingénierie.

- **Pour un échantillon:**

Paramètre de la population	Estimateur ponctuel	Estimée sur l'échantillon
μ	Moyenne $\bar{X}_n$	$\bar{x}_n$
σ^2	Variance S_n^2	s_n^2
σ	Écart-type S_n	s_n
p	Proportion $\hat{P}_i$	$\hat{p}_i = n_i/n$

- **Pour deux échantillons:**

$\mu_1 - \mu_2$	Différence des moyennes $\bar{X}_{n,1} - \bar{X}_{n,2}$	$\bar{x}_{n,1} - \bar{x}_{n,2}$
$p_1 - p_2$	Différence des proportions $\hat{P}_1 - \hat{P}_2$	$\hat{p}_1 - \hat{p}_2$

D'autres choix d'estimateurs sont possibles...par exemple pour la moyenne de la population, on pourrait aussi utiliser la moyenne entre la plus petite valeur et la plus grande valeur. Il existe des critères statistiques pour comparer ces estimateurs mais ceci est en dehors du cadre de ce cours.

Intervalles de confiance pour un échantillon

Estimations ponctuelle et par intervalle de confiance à partir d'un échantillon

Introduction aux intervalles de confiance

On sait:

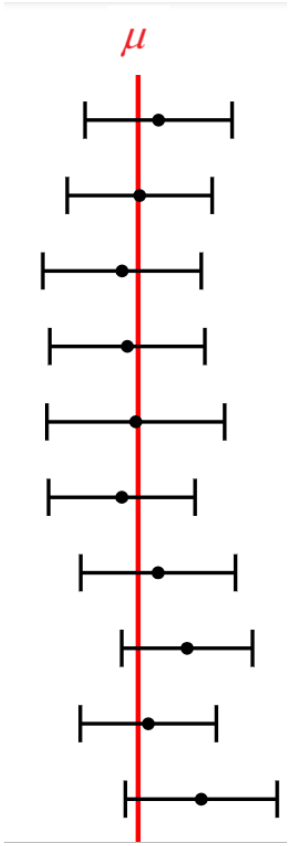
- estimer des paramètres par une statistique
- qu'on peut utiliser une moyenne d'échantillons $\bar{x}_n$ pour estimer la vraie moyenne μ
- qu'elle ne sera probablement pas égale à μ

On ne connaît pas:

- si $\bar{x}_n$ est proche ou considérablement éloignée de μ...
- c-à-d l'incertitude associée à l'estimation de μ

Introduction aux intervalles de confiance

Une méthode pour améliorer cela est de remplacer l'estimation ponctuelle par une **estimation par intervalle** qui consiste à donner un intervalle aléatoire, appelé **intervalle de confiance**, qui couvre μ avec une grande probabilité, souvent égale à 0,95. Ainsi l'intervalle contient μ plus de 95% du temps et son étendue donne la précision de l'estimation (voir plus loin). Nous apprenons dans cette section à construire de tels intervalles de confiance.

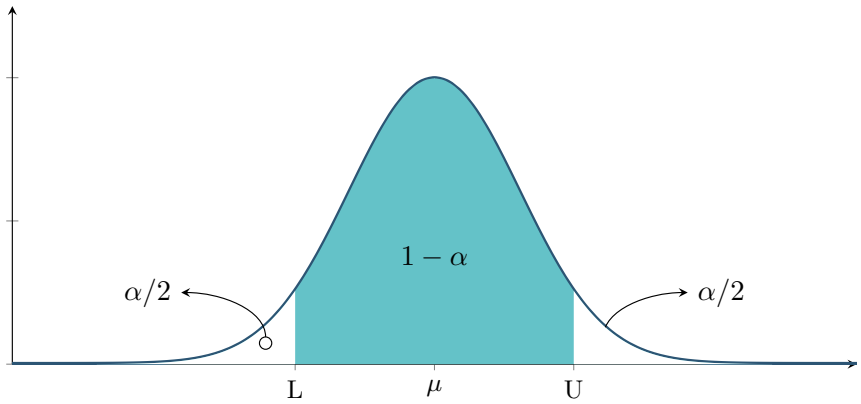


Développement d'un intervalle de confiance et ses propriétés basiques

Intervalles de confiance pour un échantillon

Estimations ponctuelle et par intervalle de confiance à partir d'un échantillon

Définition générale de l'intervalle de confiance (1/2)



Def:Intervalle de confiance aléatoire pour un paramètre quelconque θ

Un intervalle de confiance est tel que dans $100(1-\alpha)\%$ du temps, il contient la vraie valeur du paramètre inconnu quelconque θ.

- $(1-\alpha)$ est appelé niveau de confiance de l'intervalle (souvent exprimé en $\%$), avec $0 \leq \alpha \leq 1$ appelé seuil ou risque.

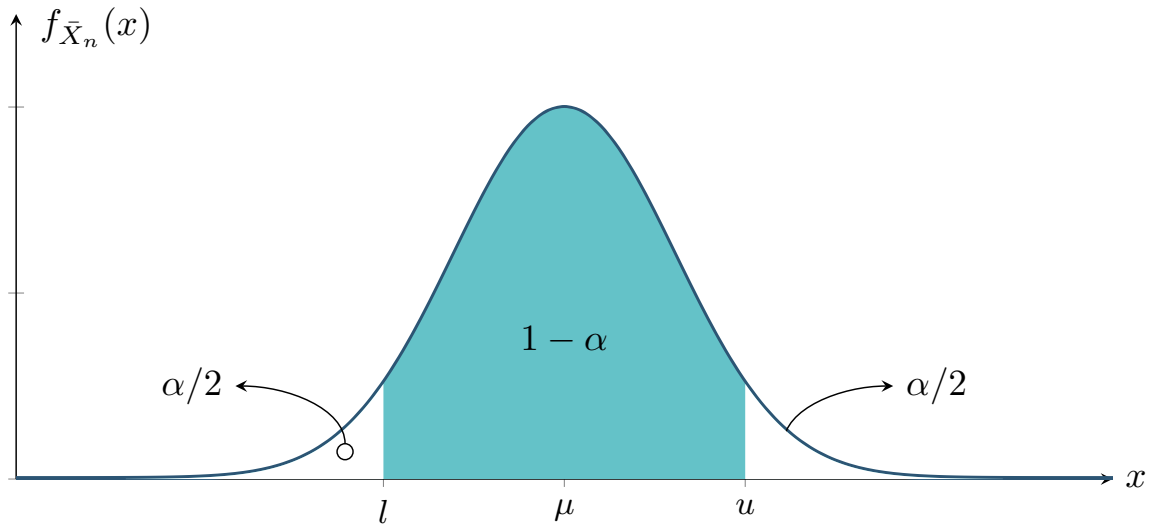
Plus précisément, un intervalle est défini par deux statistiques L et U qui donnent les bornes de l'intervalle. L et U définissent un intervalle de confiance à $100(1-\alpha)\%$ si:

$$\mathbb{P}\left(L \leq \mu \leq U\right) = 1-\alpha$$

Définition générale de l'intervalle de confiance (2/2)

Pour une réalisation donnée du n-échantillon, (*i.e.* $X_1 = x_1, X_2 = x_2, \ldots, X_n = x_n$), une estimation de l'**intervalle de confiance (IC)** de niveau $100(1-\alpha)\%$ pour la moyenne μ de la population

- donne un intervalle de la forme $l \leq \mu \leq u$ aussi noté $IC_{\mu,\alpha} = [l, u]$
- où l et u sont une réalisation des deux statistiques (VA) L et U



Intervalle de confiance de la moyenne d'une distribution normale, σ^2 connue

Estimations ponctuelle et par intervalle de confiance à partir d'un échantillon

IC pour la moyenne d'une distribution normale, σ^2 connue

Prop:Distrib. de la moyenne d'un éch. gaussien, variance σ^2 connue

Supposons qu'on dispose d'un n-échantillon $X_1, X_2, \ldots, X_n$ (de taille n donc) généré par une population normale de moyenne/espérance μ et de variance σ^2
alors $\bar{X}_n = \frac{X_1+X_2+\cdots+X_n}{n}$ **suit une loi normale** de moyenne μ et de variance $\frac{\sigma^2}{n}$
(*i.e.* $\bar{X}_n \sim \mathcal{N}(\mu, \frac{\sigma^2}{n})$)

- Toutes les observations, $X_1, X_2, \ldots, X_n$, sont normalement distribuées et indépendantes les unes des autres.
- Toute fonction linéaire de VA normales et indépendantes est une VA normale.
  $\mathbb{E}\left\{\bar{X}_n\right\} = \frac{\mu+\mu+\cdots+\mu}{n} = \mu$ et $\sigma^2_{\bar{x}_n} = \frac{\sigma^2+\sigma^2+\cdots+\sigma^2}{n^2} = \frac{\sigma^2}{n}$
- On a l'équivalence:
  $\bar{X}_n \sim \mathcal{N}(\mu, \frac{\sigma^2}{n}) \Leftrightarrow Z = \frac{\bar{X}_n-\mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0,1)$
- La loi de Z est libre en μ (*i.e.* ne dépend pas de μ). Cette propriété fait de Z un pivot qui va nous permettre de trouver les bornes de l'intervalle de confiance.

IC pour la moyenne d'une distribution normale, σ^2 connue

Le pivot Z nous permet de construire un intervalle aléatoire au niveau de confiance $100(1-\alpha)\%$ de la moyenne μ en passant par la détermination du centile $z_{\alpha/2}$ d'ordre $1-\alpha/2$ de la distribution normale:

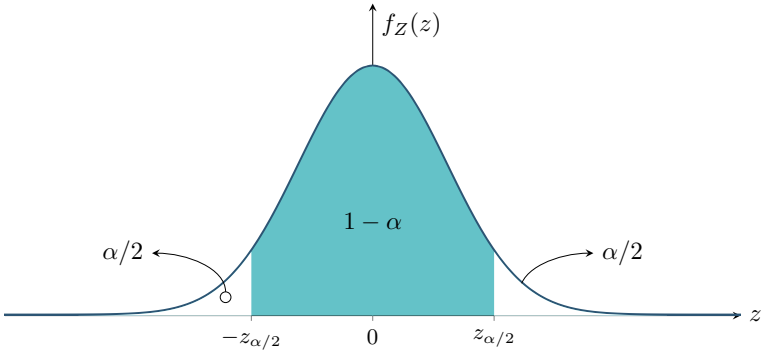
$$\mathbb{P}\left(-z_{\alpha/2} \leq Z \leq z_{\alpha/2}\right) = 1-\alpha$$
$$\mathbb{P}\left(-z_{\alpha/2} \leq \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \leq z_{\alpha/2}\right) = 1-\alpha$$
$$\mathbb{P}\left(\bar{X}_n - z_{\alpha/2}\sigma/\sqrt{n} \leq \mu \leq \bar{X}_n + z_{\alpha/2}\sigma/\sqrt{n}\right) = 1-\alpha$$
$$\mathbb{P}\left(L \leq \mu \leq U\right) = 1-\alpha$$

L'intervalle de confiance symétrique $IC_{\mu,\alpha} = [L, U]$ à $100(1-\alpha)\%$ pour μ (avec σ^2 connue) est ainsi:

$$IC_{\mu,\alpha} = [\bar{X}_n - z_{\alpha/2}\sigma/\sqrt{n}, \bar{X}_n + z_{\alpha/2}\sigma/\sqrt{n}]$$

IC pour la moyenne d'une distribution normale, σ^2 connue

Sachant $Z = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0,1)$, le centile $z_{\alpha/2}$ de la distribution normale s'obtient facilement à partir de :



$$\mathbb{P}\left(-z_{\alpha/2} \leq Z \leq z_{\alpha/2}\right) = 1-\alpha \quad \Leftrightarrow F_Z\left(z_{\alpha/2}\right) - F_Z\left(-z_{\alpha/2}\right) = 1-\alpha$$

$$\Leftrightarrow 2F_Z\left(z_{\alpha/2}\right) - 1 = 1-\alpha \quad \text{car } F_Z(x) = 1 - F_Z(-x)$$

$$\Leftrightarrow F_Z\left(z_{\alpha/2}\right) = 1 - \frac{\alpha}{2} \quad \Leftrightarrow \text{erf}\left(z_{\alpha/2}\right) = 1 - \frac{\alpha}{2}$$

$$\Leftrightarrow z_{\alpha/2} = \text{erf}^{-1}\left(1 - \frac{\alpha}{2}\right)$$

Ainsi ce centile peut être déterminé par la table de la distribution normale en annexe (table des valeurs de la fonction de répartition $\text{erf}\,()$ de la loi normale $\mathcal{N}(0,1)$) ou calculé par python/matlab.

IC pour la moyenne d'une distribution normale, σ^2 connue

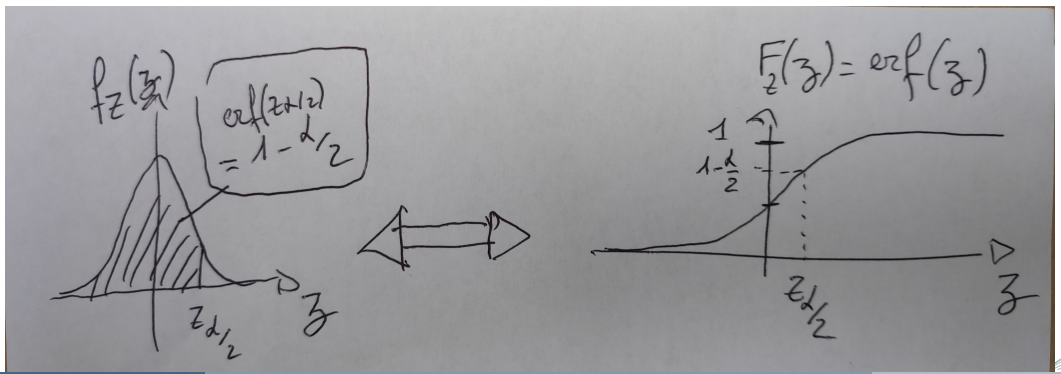
Def: IC pour la moyenne d'une distribution normale, σ^2 connue

Si $\bar{x}_n$ est la moyenne calculée sur la réalisation d'un n-échantillon généré par une population normale de variance σ^2 connue, on a alors les réalisations :
$u = \bar{x}_n + z_{\alpha/2} \cdot \sigma/\sqrt{n}$ et $l = \bar{x}_n - z_{\alpha/2} \cdot \sigma/\sqrt{n}$
L'intervalle de confiance estimé de la moyenne de la population μ au niveau $100(1-\alpha)\%$ est donné par

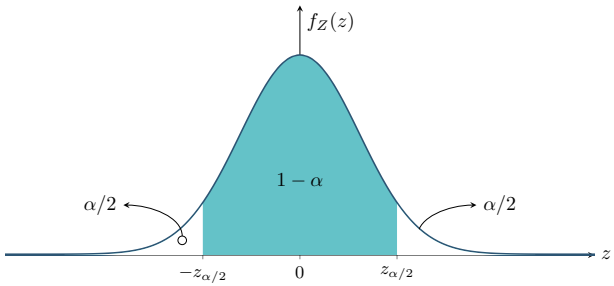
$$\bar{x}_n - z_{\alpha/2}\frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{x}_n + z_{\alpha/2}\frac{\sigma}{\sqrt{n}}$$

$$\textit{i.e. } IC_{\mu,\alpha} = \left[\bar{x}_n \pm z_{\alpha/2}\frac{\sigma}{\sqrt{n}}\right]$$

où $z_{\alpha/2} = \mathrm{erf}^{-1}\left(1 - \frac{\alpha}{2}\right)$ est le centile d'ordre $1-\alpha/2$ de la distribution normale :



Remarque générale sur les intervalles de confiance



Si α est fixé à

- **0.05**, l'IC est à 95%, $z_{\alpha/2} = z_{0.025} = 1.96$
- **0.01**, l'IC est à 99%, $z_{\alpha/2} = z_{0.005} = 2.58$

- **Généralement, pour une taille d'échantillon fixée n et une variance fixée σ^2, plus le niveau de confiance $100(1-\alpha)\%$ est haut, plus l'IC est long**.
- **Mais**, il est souvent **intéressant d'obtenir un IC de largeur réduite** pour prendre des décisions adéquates en ayant une bonne confiance.
- Un moyen d'atteindre ce but est de choisir une taille d'échantillon n suffisamment grande pour que l'IC ait une longueur traduisant une précision donnée.

Choix de la taille n de l'échantillon

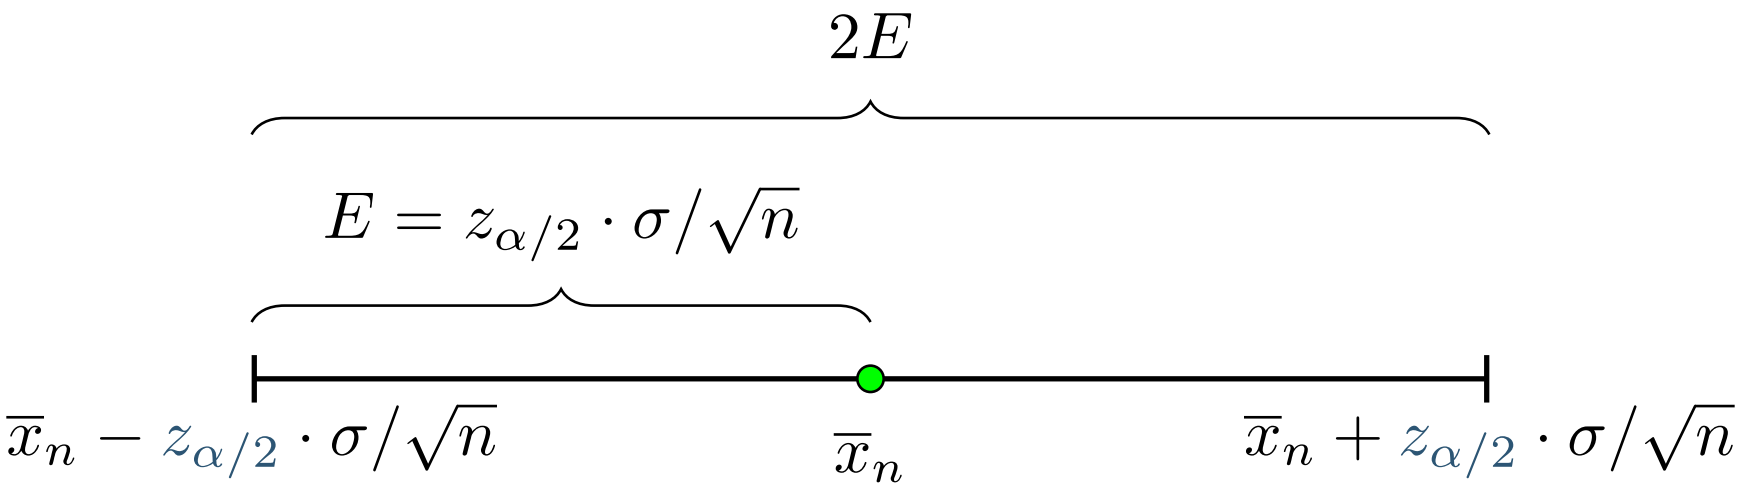
Intervalle de confiance de la moyenne d'une distribution normale, σ^2 connue

Estimations ponctuelle et par intervalle de confiance à partir d'un échantillon

Niveau de confiance et précision de l'estimation par intervalle de confiance

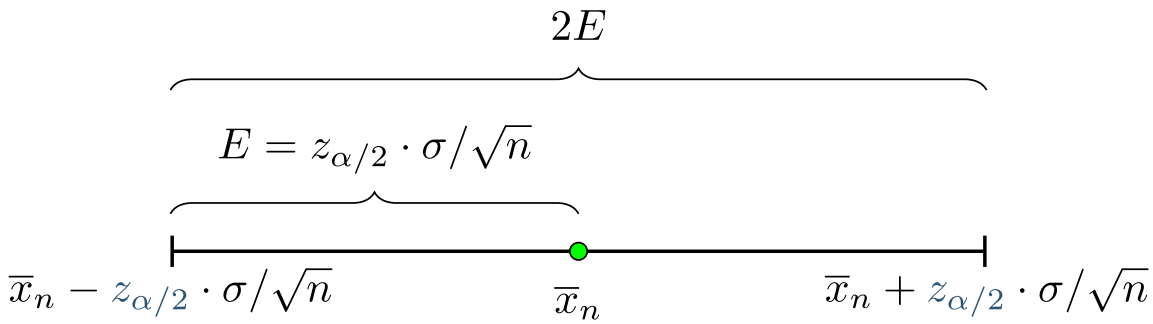
Def: précision de l'estimation par intervalle de confiance

La **1/2 longueur de l'IC** ($2z_{\alpha/2}\frac{\sigma}{\sqrt{n}}$) est une mesure de la **précision** de l'estimation de $\bar{x}_n$ par rapport à μ.



- $2E$ est la **longueur de l'IC résultant appelée parfois amplitude de l'IC**
- E = erreur = précision

Choix de la taille n de l'échantillon



Def: Choix de la taille n de l'échantillon

Lorsque la taille de l'échantillon peut être maîtrisée, il est possible de choisir n pour être confiant à un niveau $100(1-\alpha)\%$ que l'estimation de μ par $\bar{x}_n$ atteint une certaine précision E. Dans ce cas, la taille de l'échantillon doit vérifier:

$$n \geq \left(\frac{z_{\alpha/2}\sigma}{E} \right)^2$$

- Quand n n'est pas un entier, il faut arrondir à l'entier supérieur

Intervalle de confiance de la moyenne d'une distribution normale, σ^2 inconnue

Estimations ponctuelle et par intervalle de confiance à partir d'un échantillon

n-échantillon gaussien, variance σ^2 inconnue

Les hypothèses "gaussien et variance connue" sont très fortes, impactantes et surtout peu réalistes. On va donc maintenant couvrir des cas plus généraux en commençant par la variance inconnue (théoriquement).

Prop:Distrib. de la moyenne d'un éch. gaussien; variance σ^2 inconnue

Supposons qu'on dispose d'un n-échantillon $X_1, X_2, \ldots, X_n$ généré par une population normale de moyenne/espérance μ et de variance σ^2 inconnue.
Alors la variable

$$T = \frac{\bar{X}_n - \mu}{S_{n-1}/\sqrt{n}}$$

suit une distribution de Student (t-distribution) avec $n-1$ degrés de liberté.

- Le dénominateur n'est plus une valeur réelle mais une VA aléatoire car S_{n-1} est une VA.
- Si n est grand, peu d'effet et on peut utiliser le cas d'un grand échantillon que nous introduirons plus loin (slide 131)

La distribution de Student ou t-distribution

Intervalle de confiance de la moyenne d'une distribution normale, σ^2 inconnue

Estimations ponctuelle et par intervalle de confiance à partir d'un échantillon

La distribution de Student ou t-distribution

Def:Distribution de Student

Soit un n-échantillon $X_1, X_2, \ldots, X_n$ généré par une distribution normale de moyenne μ inconnue et de variance σ^2 inconnue. la variable aléatoire

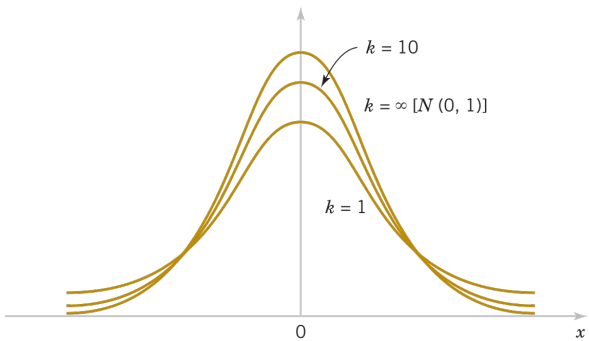
$$T = \frac{(\bar{X}_n - \mu)}{S_{n-1}/\sqrt{n}}$$

possède une distribution de Student appelée aussi t-distribution à $n-1$ degrés de liberté. La loi de T est libre en μ (*i.e.* ne dépend pas de μ). La V.A. T est donc un pivot qui va nous permettre de trouver les bornes de l'intervalle de confiance.

La densité de probabilité d'une variable T de la loi de Student à k **degrés de liberté** (notée $\mathcal{S}t(k)$) est symétrique et définie par:

$$\forall x \in \mathbb{R},\ f_T(x) = \frac{\Gamma\left[(k+1)/2\right]}{\sqrt{\pi k}\Gamma\left[k/2\right]} \frac{1}{\left[(x^2/k)+1\right]^{(k+1)/2}}$$

où $\Gamma(.)$ est la fonction Gamma d'Euler.



Intervalle de confiance pour la moyenne μ d'une distribution normale, σ^2 inconnue

Intervalle de confiance de la moyenne d'une distribution normale, σ^2 inconnue

Estimations ponctuelle et par intervalle de confiance à partir d'un échantillon

Int. de conf. pour la moyenne μ d'une distribution normale, σ^2 inconnue

Le pivot T nous permet de construire un intervalle aléatoire au niveau de confiance $100(1-\alpha)\%$ de la moyenne μ en passant par la détermination du centile $t_{\alpha/2,n-1}$ d'ordre $1-\alpha/2$ de la distribution de Student:

$$\mathbb{P}\left(-t_{\alpha/2,n-1} \leq T \leq t_{\alpha/2,n-1}\right) = 1-\alpha$$

$$\mathbb{P}\left(-t_{\alpha/2,n-1} \leq \frac{\bar{X}_n - \mu}{S_{n-1}/\sqrt{n}} \leq t_{\alpha/2,n-1}\right) = 1-\alpha$$

$$\mathbb{P}\left(\bar{X}_n - t_{\alpha/2,n-1}S_{n-1}/\sqrt{n} \leq \mu \leq \bar{X}_n + t_{\alpha/2,n-1}S_{n-1}/\sqrt{n}\right) = 1-\alpha$$

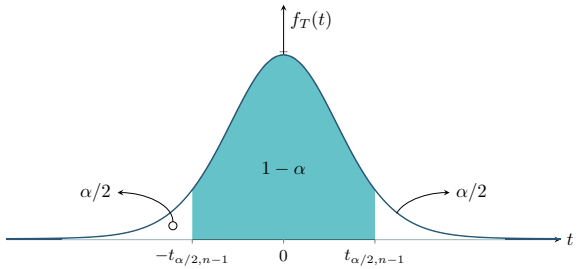
$$\mathbb{P}\left(L \leq \mu \leq U\right) = 1-\alpha$$

L'intervalle de confiance symétrique $IC_{\mu,\alpha} = [L, U]$ à $100(1-\alpha)\%$ pour μ (avec σ^2 inconnue) est ainsi:

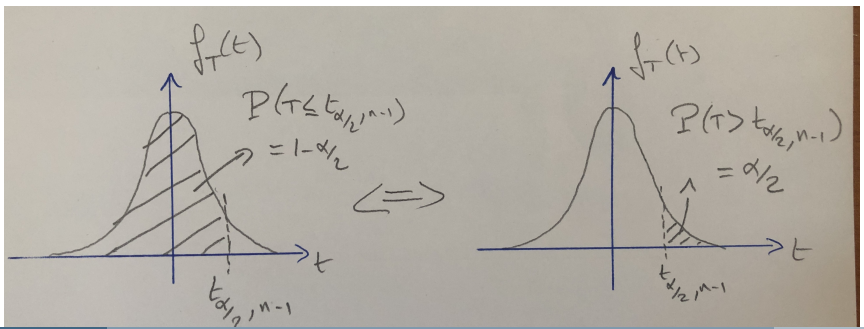
$$IC_{\mu,\alpha} = [\bar{X}_n - t_{\alpha/2,n-1}S_{n-1}/\sqrt{n}, \bar{X}_n + t_{\alpha/2,n-1}S_{n-1}/\sqrt{n}]$$

Int. de conf. pour la moyenne μ d'une distribution normale, σ^2 inconnue

Sachant $T = \frac{(\bar{X}_n - \mu)}{S_{n-1}/\sqrt{n}} \sim \mathcal{S}t(n-1)$, le centile $t_{\alpha/2,n-1}$ d'ordre $1-\alpha/2$ de la distribution de Student de $n-1$ degrés de liberté s'obtient à partir d'un dispositif numérique ou par la table de la loi de Student (table des valeurs des centiles $t_{\alpha,\nu}$ données par la fonction de répartition de Student).



La table de la loi de Student donnée en annexe représente $\mathbb{P}\left(T > t_{\alpha/2,n-1}\right) = \frac{\alpha}{2}$. Il faut noter qu'une autre table peut représenter la fonction de répartition de la loi de Student et que dans ce cas, il s'agit de déterminer de manière équivalente $t_{\alpha/2,n-1}$ tel que $\mathbb{P}\left(T > t_{\alpha/2,n-1}\right) = 1 - \mathbb{P}\left(T \leq t_{\alpha/2,n-1}\right) = \alpha/2$.



Int. de confiance pour la moyenne μ d'une distribution normale, σ^2 inconnue

Def:Int. de confiance pour la moyenne μ d'une distribution normale, σ^2 inconnue

Si $\bar{x}_n$ et s_{n-1} sont la moyenne et l'écart-type (non biaisé) d'un n-échantillon issu d'une distribution gaussienne dont la variance σ^2 de la population est inconnue, l'intervalle de confiance de niveau de confiance $100(1-\alpha)\%$ pour la moyenne de la population μ est estimé par:

$$\bar{x}_n - t_{\alpha/2,n-1} s_{n-1}/\sqrt{n} \leq \mu \leq \bar{x}_n + t_{\alpha/2,n-1} s_{n-1}/\sqrt{n}$$

$$\text{i.e. } IC_{\mu,\alpha} = \left[\bar{x}_n \pm t_{\alpha/2,n-1} s_{n-1}/\sqrt{n}\right]$$

où $t_{\alpha/2,n-1}$ peut être déterminé à partir :

- de la fonction de répartition de la loi de Student avec $n-1$ degrés de liberté par $F_T^{-1}(1-\alpha/2)$
- ou par $\mathbb{P}\left(T > t_{\alpha/2,n-1}\right) = \alpha/2$.

Choisir la taille de l'échantillon

Intervalle de confiance de la moyenne d'une distribution normale, σ^2 inconnue

Estimations ponctuelle et par intervalle de confiance à partir d'un échantillon

Choisir la taille de l'échantillon

Il n'est pas facile de sélectionner une taille d'échantillon n pour obtenir une précision d'estimation voulue pour cet intervalle de confiance comme vu dans le cas σ connu, car la **longueur de l'intervalle dépend de** s_{n-1} (qui est inconnu avant d'avoir la réalisation du n-échantillon), n et $t_{\alpha/2,n-1}$.
Il faut aussi noter que le t-percentile dépend de la taille n. En conséquence, par une stratégie d'essai/erreur, on peut trouver itérativement une taille d'échantillon n à condition de spécifier une hypothèse sur σ, et alors poser :

$$n \geq \left(\frac{t_{\alpha/2,n-1}\sigma}{E} \right)^2$$

Intervalle de confiance de la moyenne d'une distribution dans le cas d'un grand échantillon

Estimations ponctuelle et par intervalle de confiance à partir d'un échantillon

Échantillon de distribution inconnue (cas d'un grand échantillon)

Prop:n-échantillon de distribution inconnue (cas d'un grand échantillon)

Supposons qu'on dispose d'un n-échantillon $X_1, X_2, \ldots, X_n$ généré par une population de moyenne/espérance μ et de variance σ^2. La distribution de chaque X_i est inconnue mais identique. Le théorème de la limite centrale postule que la loi de la VA:

$$Z = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}}$$

si $n \to +\infty$ suit une distribution normale centrée réduite $\mathcal{N}(0,1)$

- La variance σ^2 peut être connue ou inconnue (alors estimée par s_n^2).
- Z est à nouveau un pivot qui va nous permettre de trouver les bornes de l'intervalle de confiance.

Échantillon de distribution inconnue (cas d'un grand échantillon)

A partir de quand $n \to +\infty$?

Quand la taille de l'échantillon est-elle assez grande pour que le théorème s'applique?

- La réponse dépend de la ressemblance de la distribution sous-jacente par rapport à la normale
- Il est convenu que si $n \geq 30$, le théorème s'applique presque toujours.

Échantillon de distribution inconnue (cas d'un grand échantillon)

Example (Distribution de la moyenne du score de plusieurs dés)

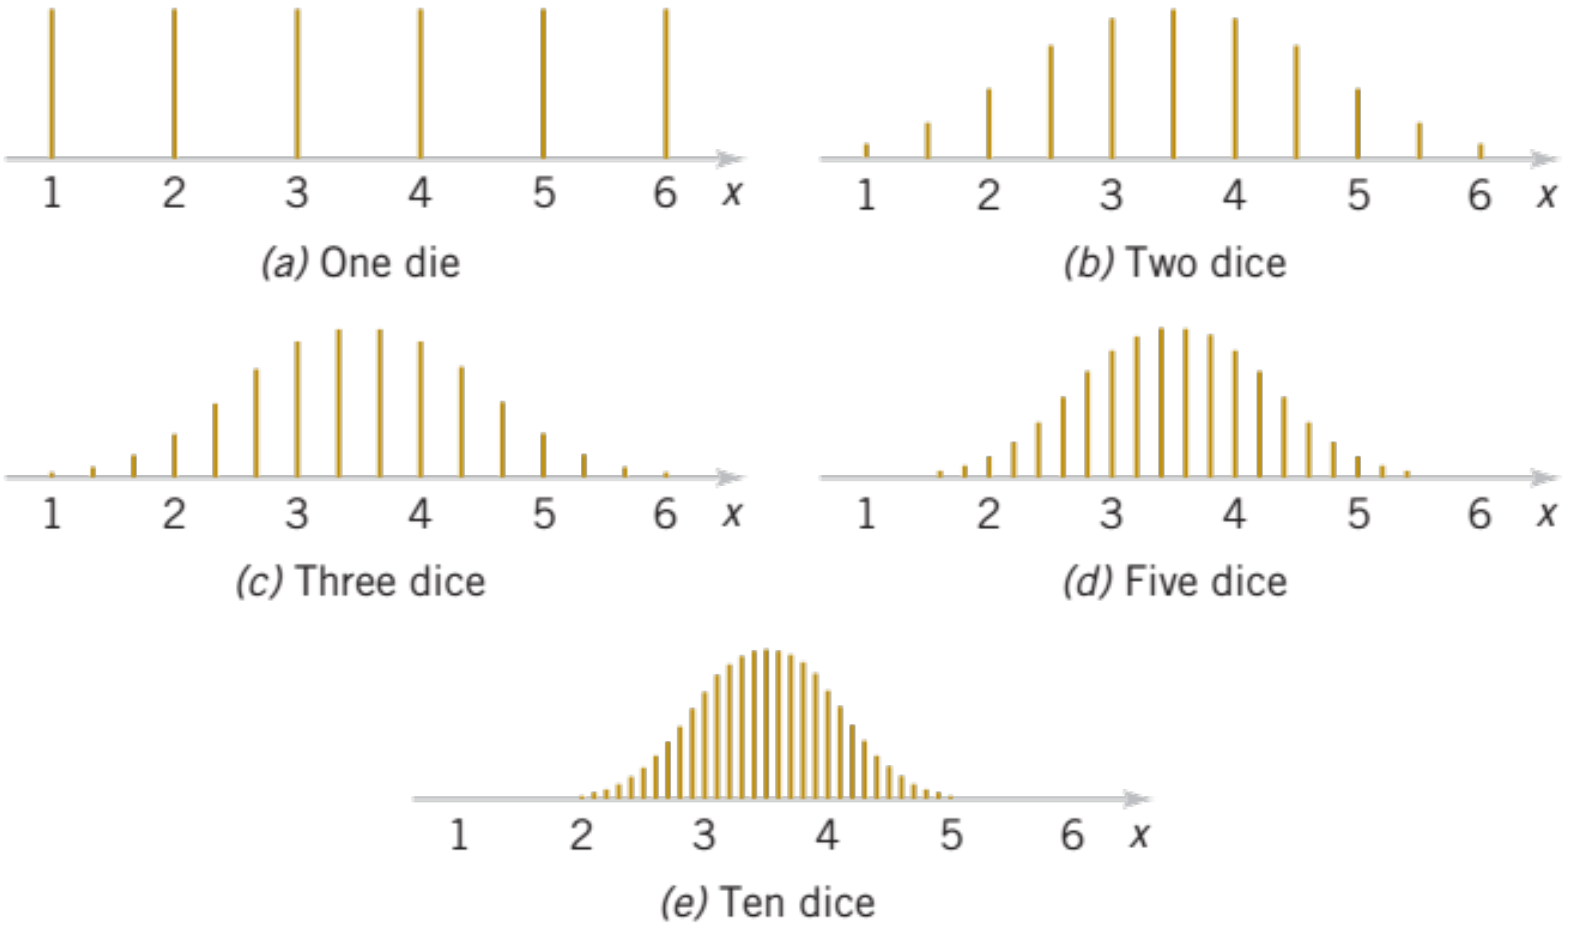


Figure: Distributions de la moyenne des scores d'un jeté de dés. Mean = 3.5

IC pour la moyenne d'une distribution quelconque (grand échantillon)

Def:IC pour la moyenne d'une distribution quelconque (grand échantillon)

Dans le cas d'un grand échantillon ($n \geq 30$) de taille n généré par une population de distribution quelconque (normale ou pas), un intervalle de confiance de niveau $100(1-\alpha)\%$ pour la moyenne de la population μ est estimé par

- si σ^2 est connue, $IC_{\mu,\alpha} = [\bar{x}_n \pm z_{\alpha/2}\frac{\sigma}{\sqrt{n}}]$
- si σ^2 est inconnue, elle peut être approximée par s_n^2, $IC_{\mu,\alpha} = [\bar{x}_n \pm z_{\alpha/2}\frac{s_n}{\sqrt{n}}]$

Remarques

- **Dans ce cours, nous utiliserons toujours la condition $n \geq 30$ pour qualifier un grand échantillon.**
- **Il faut néanmoins noter que** généralement, n devrait être au moins 40 pour utiliser la deuxième équation. Le fait de remplacer σ par s_n rajoute de la variabilité et l'hypothèse de normalité (TCL) est atteinte à peu près.
- rappel: $z_{\alpha/2} = \text{erf}^{-1}\left(1 - \frac{\alpha}{2}\right)$

Choix de la taille n de l'échantillon

Intervalle de confiance de la moyenne d'une distribution dans le cas d'un grand échantillon

Estimations ponctuelle et par intervalle de confiance à partir d'un échantillon

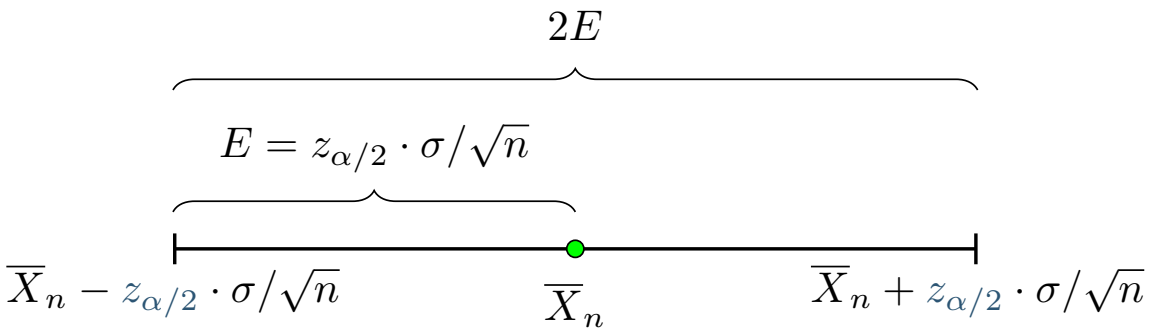
Choix de la taille n de l'échantillon

Def: Choix de la taille n de l'échantillon

Dans les situations où la taille de l'échantillon peut être maîtrisée, il est possible de choisir n de telle sorte qu'on puisse être confiant à un niveau $100(1-\alpha)\%$ que l'estimation de μ par $\bar{x}_n$ atteint une certaine précision E. Dans ce cas, la taille de l'échantillon est:

$$n \geq \left(\frac{z_{\alpha/2}\sigma}{E}\right)^2$$

- Quand le résultat n'est pas un entier, il faut arrondir à l'entier supérieur
- $2E$ est la **longueur de l'IC résultant appelée également amplitude**
- E = erreur = précision



Intervalle de confiance pour la proportion d'un grand échantillon

Estimations ponctuelle et par intervalle de confiance à partir d'un échantillon

Proportion d'un échantillon

- Si parmi n données, x ont la caractéristique étudiée par la proportion p, alors son estimation sur l'échantillon de données est obtenue par:

$$\hat{p} = \frac{x}{n}$$

  peut être utilisée pour estimer la proportion sur la population.
- l'estimateur est alors

$$\hat{P} = \frac{X}{n}$$

- La VA X est distribuée selon une loi binomiale (nombre de votes indépendants pour une caractéristique parmi n) $\mathcal{B}(n, p)$ de moyenne np et de variance $npq = np(1-p)$.
- La loi de la VA $\hat{P}$ est l'image de la loi binomiale précédente par changement d'échelle des valeurs possibles (et donc identiquement décrite par la loi de X) et les propriétés de la multiplication d'une VA par une constante permettent de trouver facilement que moyenne et variance deviennent p et $\frac{pq}{n}$ respectivement.
- Il existe beaucoup d'exemples pratiques de la loi binomiale X...par exemple les préférences des utilisateurs, un sondage d'opinion, dans lesquels on utilise un échantillon aléatoire de n personnes pour estimer la proportion p de la population qui a une caractéristique d'étude.

Proportion d'un échantillon

Prop:Distribution de la proportion $\hat{P}$

- On vient de voir que la distribution de la VA proportion d'un échantillon $\hat{P} = \frac{X}{n}$ suit une loi binomiale de moyenne p et d'écart-type $\sqrt{\frac{p(1-p)}{n}}$.
- (Cas d'un grand échantillon) Quand la taille de l'échantillon est grande ($n > 30$), la loi binomiale tend vers une loi normale, et par conséquent la loi de $\hat{P}$ peut être approximée par une distribution normale $\mathcal{N}(p, \frac{p(1-p)}{n})$.
- Toutefois, l'approximation sera bonne si $np > 5$ et si $n(1-p) > 5$.

Dans la suite on ne traitera que le cas des grands échantillons

IC pour la proportion d'un grand échantillon

Si n **est grand**, la distribution de :

$$Z = \frac{X - np}{\sqrt{np(1-p)}} = \frac{\hat{P} - p}{\sqrt{\frac{p(1-p)}{n}}} \text{ est approximativement une loi normale centrée réduite.}$$

Z est à nouveau un pivot qui va nous permettre de trouver les bornes de l'intervalle de confiance, identiques au cas grand échantillon précédent en remplaçant simplement :

- $\bar{X}_n$ par $\hat{P}$
- S_n par $\sqrt{p(1-p)}$

L'intervalle de confiance symétrique $IC_{\mu,\alpha} = [L, U]$ à $100(1-\alpha)\%$ pour μ (avec σ^2 connue) est donc en théorie:

$$IC_{p,\alpha} = [\hat{P} - z_{\alpha/2}\sqrt{\frac{p(1-p)}{n}}, \hat{P} + z_{\alpha/2}\sqrt{\frac{p(1-p)}{n}}]$$

Etant donné que les bornes de l'intervalle ne peuvent dépendre du paramètre vrai mais inconnu, l'estimée de cet intervalle de confiance sur la réalisation d'un n-échantillon est obtenue en remplaçant p par $\hat{p}$ dans l'écart-type $\frac{p(1-p)}{n}$ de $\hat{P}$ (voir planche suivante).

IC pour la proportion d'un grand échantillon

Def:IC pour la proportion d'un grand échantillon

Si $\hat{p}$ est la proportion des observations dans la réalisation d'un n-échantillon qui appartient à une classe d'intérêt, un intervalle de confiance de niveau de confiance $100(1-\alpha)\%$ pour la proportion p de la population qui appartient à cette classe est (si $np \geq 5$ et si $n(1-p) \geq 5$) :

$$\hat{p} - z_{\alpha/2}\sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \leq p \leq \hat{p} + z_{\alpha/2}\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

où $z_{\alpha/2} = \mathrm{erf}^{-1}\left(1 - \frac{\alpha}{2}\right)$ est le centile d'ordre $1-\alpha/2$ de la distribution normale centrée réduite qui peut être déterminé à l'aide la fonction de répartition tabulée de la loi normale ou d'un dispositif numérique.

Choisir la taille de l'échantillon

Intervalle de confiance pour la proportion d'un grand échantillon

Estimations ponctuelle et par intervalle de confiance à partir d'un échantillon

Choisir la taille de l'échantillon

Dans les situations où la taille de l'échantillon peut être contrôlée, on peut choisir n en étant confiant à un niveau $100(1-\alpha)\%$ que l'erreur d'estimer la proportion par la réalisation de $\hat{P}$ à la place de p (*i.e.* $|\hat{p}-p|=$ la demi-longueur de l'IC) soit inférieure à une valeur spécifiée E. La taille de l'échantillon pour la valeur spécifiée E est donnée par:

$$n \geq \left(\frac{z_{\alpha/2}}{E}\right)^2 \hat{p}(1-\hat{p})$$

- Quand le résultat n'est pas un entier, il faut arrondir à l'entier supérieur
- $2E$ est la **longueur de l'IC résultant appelée également amplitude**
- $E =$ erreur $=$ précision

Méthode générale pour définir un intervalle de confiance d'un paramètre θ

Estimations ponctuelle et par intervalle de confiance à partir d'un échantillon

Méthode générale pour définir un IC d'un paramètre θ

Soit $X_1, X_2, \ldots, X_n$ un n-échantillon dont les n observations sont identiquement distribuées selon une distribution qui dépend d'un paramètre inconnu θ. Supposons qu'on puisse trouver une statistique $g(X_1, X_2, \ldots, X_n; \theta)$ avec les propriétés suivantes:

1. Elle dépend du n-échantillon
2. Elle ne dépend pas θ (ni d'aucun paramètre inconnu), en d'autres termes sa distribution est libre en θ.

- Alors nous devons trouver des constantes C_L et C_U telles que $\mathbb{P}(C_L \leq g(X_1, X_2, \ldots, X_n; \theta) \leq C_U) = 1 - \alpha$
- Finalement, on manipule les inégalités dans la probabilité de telle sorte que $\mathbb{P}(L(X_1, X_2, \ldots, X_n) \leq \theta \leq U(X_1, X_2, \ldots, X_n)) = 1 - \alpha$

IC pour un paramètre θ (grand échantillon)

Soit θ un paramètre d'une distribution et soit $\hat{\Theta}$ un estimateur de θ.

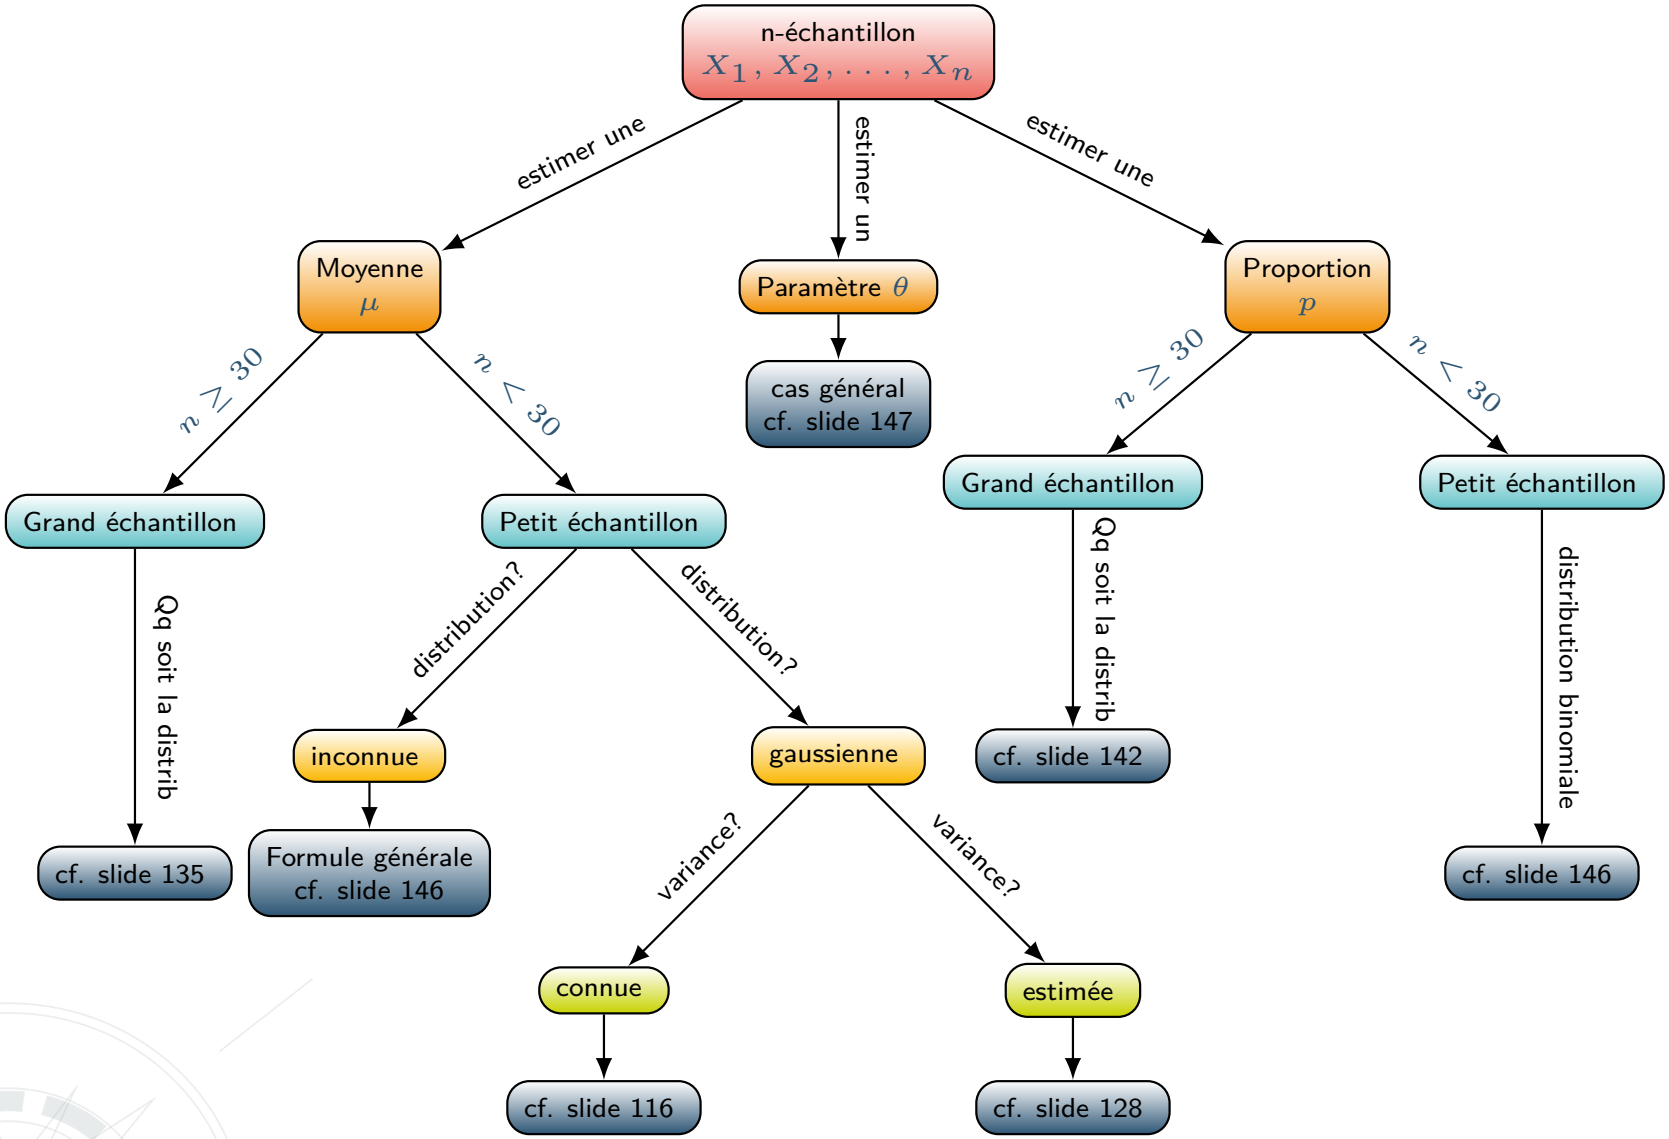
Def:IC pour un paramètre θ (grand échantillon)

Si $\hat{\Theta}$

1. a approximativement une distribution normale
2. est (au moins asymptotiquement, *i.e.* pour n infiniment grand) sans biais pour θ
3. a un écart type $\sigma_{\hat{\Theta}}$ qui peut être estimé par $s_{n,\hat{\Theta}}$

alors l'intervalle de confiance pour θ est $IC_{\theta,\alpha} = [\hat{\theta} \pm z_{\alpha/2}\sigma_{\hat{\Theta}}]$

Résumé de la méthode à utiliser par arbre de décisions



Tests statistiques d'hypothèses pour un échantillon

- Introduction
- Généralités sur les tests statistiques (bilatéraux)
- Test pour la moyenne d'une distribution normale, variance connue
- Test pour la moyenne d'un grand échantillon
- Test pour la moyenne d'une distribution normale, σ^2 inconnue
- Tests pour une proportion de la population
- Tests statistiques unilatéraux
- Tableau résumé des tests pour un échantillon
- Tester l'adéquation à un modèle de distribution
- Tests d'indépendance et d'homogénéité pour une table de contingence

Introduction

Tests statistiques d'hypothèses pour un échantillon

Généralités sur les tests statistiques (bilatéraux)

Tests statistiques d'hypothèses pour un échantillon

Introduction

- Dans les parties précédentes, on a vu comment un paramètre d'une population peut être estimé à partir des données d'un échantillon en utilisant:
  - soit une estimation ponctuelle
  - soit un intervalle de confiance (pour limiter l'effet de la sélection de l'échantillon)
- Dans beaucoup de situations, le problème qui se pose met en compétition deux propositions concernant la valeur d'un paramètre et l'ingénieur doit décider quelle proposition est correcte.

Introduction



- Par exemple, imaginons qu'un ingénieur construise un **système d'éjection d'avion**. Le système contient un **gaz propulseur** qui doit avoir **une vitesse moyenne de combustion de 50 cm/s**.
- Si cette vitesse est trop basse ou trop haute, le pilote n'est plus en sûreté.
- **La question pratique à laquelle l'ingénieur doit répondre est:** est-ce que la vitesse moyenne de combustion doit être de 50 cm/s, ou existe-t-il une autre valeur moyenne (soit supérieure soit inférieure) plus efficace?
- C'est le type de question que les **tests d'hypothèses statistiques** adressent à partir d'**un seul échantillon**.

Hypothèses statistiques

Généralités sur les tests statistiques (bilatéraux)

Tests statistiques d'hypothèses pour un échantillon

Hypothèses statistiques

Def: hypothèse statistique

Une **hypothèse statistique** est une proposition concernant les paramètres d'une ou plusieurs populations

- La procédure de décision entre plusieurs hypothèses s'appelle le **test d'hypothèses**.
- Beaucoup de problèmes de décision en ingénierie peuvent être formulés en termes de tests d'hypothèses.
- Une connexion très proche existe entre **intervalle de confiance et test d'hypothèse**.
- Les deux s'appuient fondamentalement sur une analyse de données basée sur une **comparaison statistique entre deux valeurs** (par ex. la moyenne d'une population et d'un échantillon, la moyenne de deux échantillons, etc.)

Hypothèses statistiques bilatérales

Reprenons l'exemple de la vitesse moyenne de combustion d'un siège d'éjection.

- Cette vitesse est une VA qui peut être donc représentée par une distribution.
- On se concentre uniquement sur la moyenne de la vitesse (un paramètre de la distribution)
- La question posée est ici: **la vitesse moyenne est elle de 50 cm/s?**

Def: Hypothèses statistiques bilatérales

- H_0: $\mu = 50$ cm/s appelée autrement l'**hypothèse nulle** (initialement considérée comme vraie)
- H_1: $\mu \neq 50$ cm/s appelée autrement l'**hypothèse alternative**

Remarque: comme l'hypothèse alternative H_1 spécifie une valeur de μ qui peut être supérieure ou inférieure à 50, elle est aussi appelée **hypothèse alternative bilatérale**.

Hypothèses statistiques: comment fixer H_0?

Les hypothèses portent toujours sur **des propositions concernant la population** ou la distribution et pas concernant l'échantillon.

La valeur du paramètre de la population spécifiée dans l'hypothèse nulle (50 cm/s) est généralement déterminée par une des trois manières suivantes:

1. la connaissance du problème éventuellement acquise par des **tests ou expériences précédentes**. L'objectif du test d'hypothèses est alors en général, de déterminer si la valeur du paramètre a changé ou pas.
2. cette valeur peut être déterminée par une **théorie ou modèle** (physique par exemple). L'objectif du test d'hypothèse est alors en général, de vérifier la théorie ou le modèle.
3. une troisième situation arrive quand la valeur du paramètre de la population résulte de considérations extérieures, tel que des **spécifications de fabrication ou des obligations contractuelles**. L'objectif est alors de tester la conformité de l'échantillon.

Tests d'hypothèses statistiques

Généralités sur les tests statistiques (bilatéraux)

Tests statistiques d'hypothèses pour un échantillon

Comment prendre la décision?

Reprenons l'exemple précédent pour le test d'hypothèse suivant:

- H_0: $\mu = 50$ cm/s
- H_1: $\mu \neq 50$ cm/s

Supposons qu'on ait un n-échantillon de données $X_1, X_2, \ldots, X_n$, la moyenne $\bar{x}_n$ peut prendre beaucoup de valeurs différentes selon sa réalisation. Le test fonctionne ainsi:

- si la moyenne calculée est proche de la moyenne μ de la population, on ne peut rejeter H_0 (**région d'acceptation**).
- si la moyenne calculée est trop éloignée de μ, on peut rejeter H_0 (**région critique**).
- les bornes entre ces deux régions s'appellent les **valeurs critiques**.

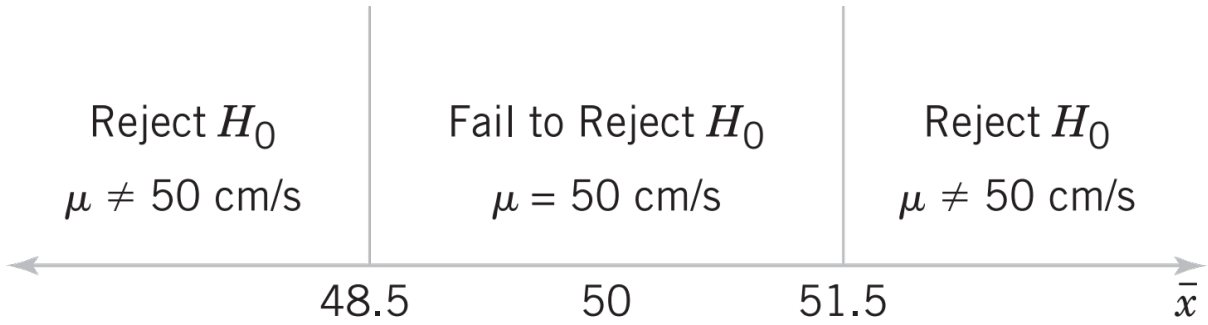


Figure: Régions de décision pour l'exemple de la vitesse de combustion.

Comment prendre la décision?

Def: test d'une hypothèse

Une procédure menant à une décision concernant l'hypothèse nulle est appelée **test d'une hypothèse**.

- Les procédures de test d'hypothèses s'appuient sur l'utilisation de l'information d'un n-échantillon généré sur une population d'intérêt.
- Si cette information est consistante avec l'hypothèse nulle, alors nous conclurons que l'hypothèse nulle est vraie (**ou plutôt que nous ne la rejetterons pas**) ;
- Dans le cas contraire, **nous rejetterons** H_0 et conclurons que l'hypothèse alternative est vraie.
- **ATTENTION**: Notez bien que le caractère vrai ou faux d'une hypothèse statistique ne peut jamais être statué avec certitude à moins d'examiner la population entière (ce qui est généralement impossible).

Bilan du test: quelles erreurs? quelles probabilités?

- On verra un peu après comment déterminer les régions de décision pour des cas particuliers.
- Admettons pour le moment qu'on puisse prendre des décisions.

La procédure de décision peut mener à deux fausses conclusions:

Def: Erreurs de type I et II

- Rejeter l'hypothèse nulle H_0 quand elle est vraie: **erreur de type I**
- Ne pas rejeter l'hypothèse nulle H_0 quand elle est fausse: **erreur de type II**

Quatre situations peuvent arriver:

Décision \ **Réalité**	H_0 **est vraie**	H_0 **est fausse**
Ne pas rejeter H_0	Pas d'erreur	Erreur de type II
Rejeter H_0	Erreur de type I	Pas d'erreur

Bilan du test: quelles erreurs? quelles probabilités?

Comme la décision est basée sur des VA, des **probabilités** peuvent être associées aux **erreurs** de type I et de type II.

Def: Probabilités d'erreurs de type I et II

$$\alpha = \mathbb{P}\left(\text{erreur de type I}\right) = \mathbb{P}\left(\text{rejeter } H_0 \text{ quand } H_0 \text{ est vraie}\right)$$
$$\beta = \mathbb{P}\left(\text{erreur de type II}\right) = \mathbb{P}\left(\text{ne pas rejeter } H_0 \text{ quand } H_0 \text{ est fausse}\right)$$

Décision \ **Réalité**	H_0 **est vraie**	H_0 **est fausse**
Ne pas rejeter H_0	Pas d'erreur	$\beta = \mathbb{P}\left(\text{erreur de type II}\right)$
Rejeter H_0	$\alpha = \mathbb{P}\left(\text{erreur de type I}\right)$	Pas d'erreur

La probabilité d'erreur de type I, α est également appelée:

- taille du test
- niveau ou seuil de signification (ou risque), que l'on nomme plus communément **seuil (ou risque)**

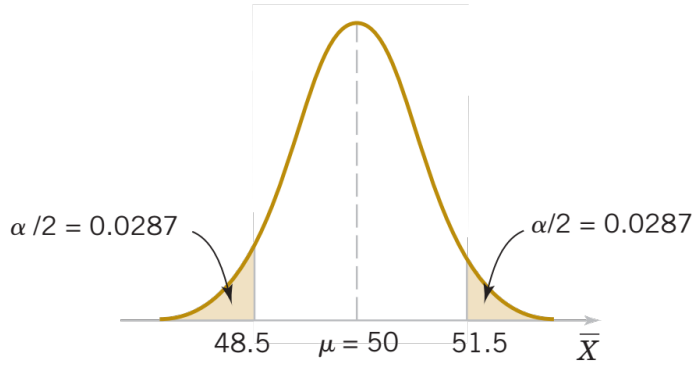
Exemple: quelle est la probabilité d'erreur de type I?

Reprenons l'**exemple de la vitesse de combustion**, et supposons qu'on ait **10 mesures**, que l'écart-type de la vitesse de combustion est $\sigma = 2.5$ cm/s et que la VA vitesse de combustion a une distribution telle que le théorème limite centrale (TCL) s'applique.

- l'**erreur de type I se produit** quand $\bar{x}_n > 51.5$ ou $\bar{x}_n < 48.5$ dans le cas où la vraie vitesse moyenne de combustion est $\mu = 50$ cm/s (**bornes obtenues par IC**).
- la **distribution de la vitesse moyenne** de l'échantillon est approximativement normale de moyenne $\mu = 50$ et d'écart-type $\sigma/\sqrt{n} = 2.5/\sqrt{10} = 0.79$.

La probabilité de faire une erreur de décision de type I est égale à la somme des aires sur les côtés de la distribution...mathématiquement:

$$\begin{aligned}
\alpha &= \mathbb{P}\left(\bar{X}_n < 48.5 \text{ quand } \mu = 50\right) \\
&\quad + \mathbb{P}\left(\bar{X}_n > 51.5 \text{ quand } \mu = 50\right) \\
&= \mathbb{P}\left(Z < \frac{48.5 - 50}{0.79}\right) + \mathbb{P}\left(Z > \frac{51.5 - 50}{0.79}\right) \\
&= 0.0287 + 0.0287 \ (Z \sim \mathcal{N}(0,1)) \\
&= 0.0574
\end{aligned}$$



α est le niveau de risque (équivalent au niveau de confiance $1 - \alpha$) déjà vu en intervalle de confiance

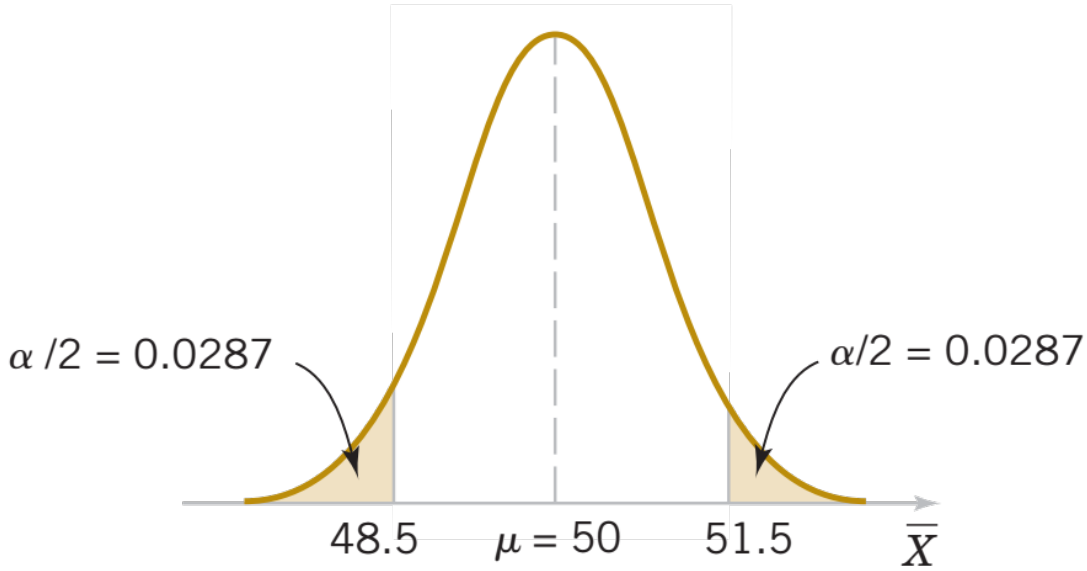
Probabilité d'erreur de type I

Def: Probabilité d'erreur de type I

$$\alpha = \mathbb{P}\,(\text{erreur de type I}) = \mathbb{P}\,(\text{rejeter } H_0 \text{ quand } H_0 \text{ est vraie})$$

Cette probabilité peut être réduite:

- en élargissant la région d'acceptation (les aires diminuent)
- en augmentant le nombre d'échantillon (la distribution est plus centrée sur la moyenne de la population)



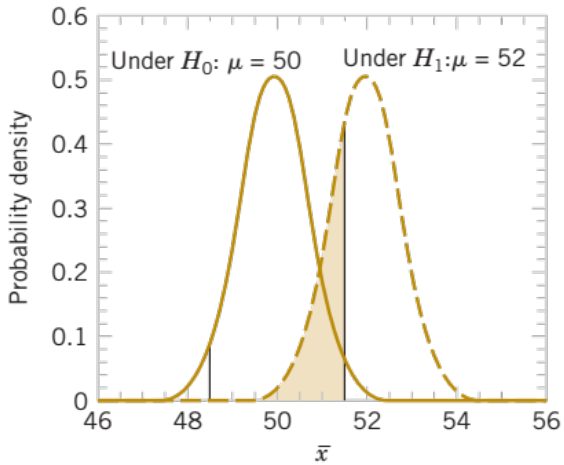
Exemple: quelle est la probabilité d'erreur de type II?

L'erreur de **type II se produit quand on ne rejette pas H_0 alors que H_1 est vraie**

- Pour calculer β, on doit spécifier une hypothèse alternative, *i.e.* une valeur μ concurrente
- H_0: $\mu = 50$ vs H_1: $\mu = 52$
- On observe les deux distributions de $\bar{X}_n$ selon H_0 et selon H_1
- On regarde la distribution de droite dans l'intervalle de non rejet de H_0 $[48.5; 51.5]$

La probabilité de faire une erreur de décision de type II est égale à l'aire sur les côtés de la distribution...mathématiquement:

$$\begin{aligned}\beta &= \mathbb{P}\left(48.5 \leq \bar{X}_n \leq 51.5 \text{ quand } \mu = 52\right) \\ &= \mathbb{P}\left(\frac{48.5 - 52}{0.79} \leq Z \leq \frac{51.5 - 52}{0.79}\right) \\ &= 0.2643 - 0.0000 \\ &= 0.2643\end{aligned}$$



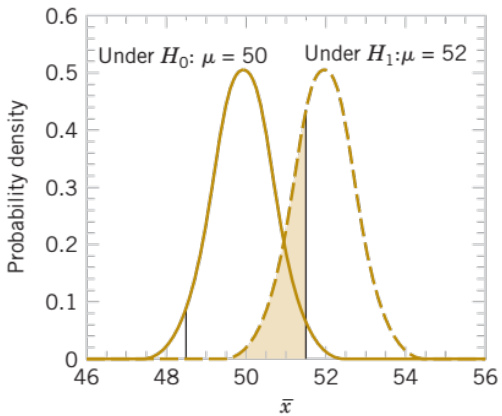
Probabilité d'erreur de type II

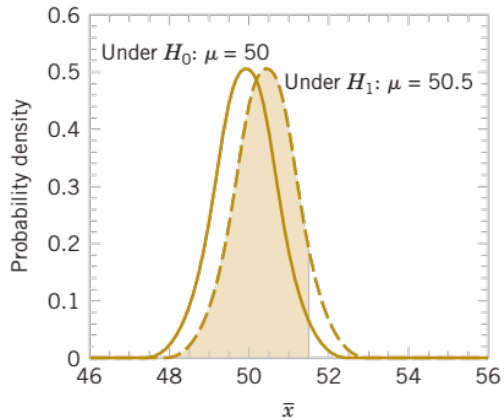
Def: Probabilité d'erreur de type II

$$\beta = \mathbb{P}\,(\text{erreur de type II}) = \mathbb{P}\,(\text{ne pas rejeter } H_0 \text{ quand } H_0 \text{ est fausse})$$

Cette probabilité:

- augmente si l'écart entre les deux moyennes diminue
- diminue en augmentant la taille de l'échantillon (les distributions sont plus centrées sur la moyenne de la population)





En résumé (1/1)

Soit H_0 l'hypothèse que la patiente est enceinte:



Test pour la moyenne d'une distribution normale, variance connue

Tests statistiques d'hypothèses pour un échantillon

Test pour la moyenne d'une distribution normale, variance connue

Dans cette section,

- nous considérons le test d'hypothèse pour la moyenne μ d'une **population normale où la variance de la population σ^2 est connue**.
- Nous supposerons que le **n-échantillon** $X_1, X_2, \ldots, X_n$ a été **généré à partir de cette population**.
- Nous savons que
  - la moyenne de l'échantillon $\bar{X}_n$ est un bon estimateur ponctuel de la moyenne de population μ
  - et qu'il est de variance σ^2/n.

Formalisation du test

Test pour la moyenne d'une distribution normale, variance connue

Tests statistiques d'hypothèses pour un échantillon

Formalisation du test

Ce test est souvent appelé **Z-test**.

- On veut **tester** H_0**:** $\mu = \mu_0$ **vs** H_1**:** $\mu \neq \mu_0$ où μ_0 est une constante spécifiée.
- $\bar{X}_n$ a une distribution normale $\mathcal{N}(\mu_0, \sigma/\sqrt{n})$ si l'**hypothèse nulle** H_0 **est vraie**.
- On préférera utiliser pour le test la VA $Z_0 = \frac{\bar{X}_n - \mu_0}{\sigma/\sqrt{n}}$ de distribution $\mathcal{N}(0,1)$.
- Nous disposons d'un n-échantillon $X_1, X_2, \ldots, X_n$ généré par une distribution normale.
- $z_0 = \frac{\bar{x}_n - \mu_0}{\sigma/\sqrt{n}}$ est l'**estimée de** Z_0 **à partir du n-échantillon** et appelée **valeur critique**.

Pour réaliser un test statistique, une fois que le niveau de confiance $100(1-\alpha)\%$ est fixé, **deux stratégies** sont possibles:

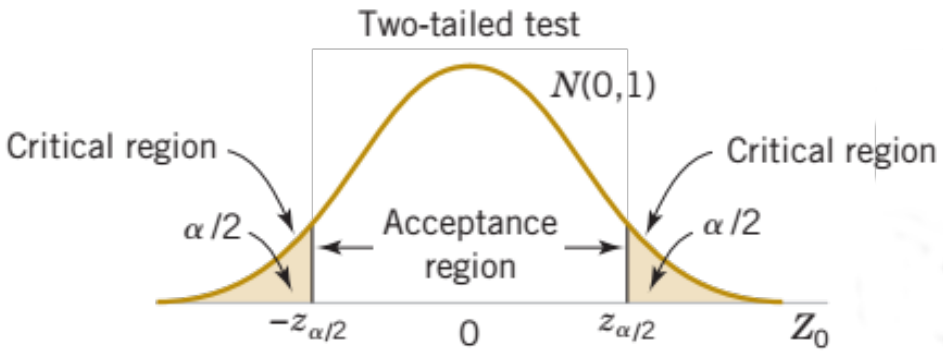
- regarder où se situe z_0 vis-à-vis de la **région critique**.
- calculer la p-**valeur** associée à la valeur critique z_0 (fixer les bornes) et la comparer au niveau de risque 0.05 (voir justification plus loin).

Formalisation du test: calcul de la région critique

Test pour la moyenne d'une distribution normale, variance connue

Tests statistiques d'hypothèses pour un échantillon

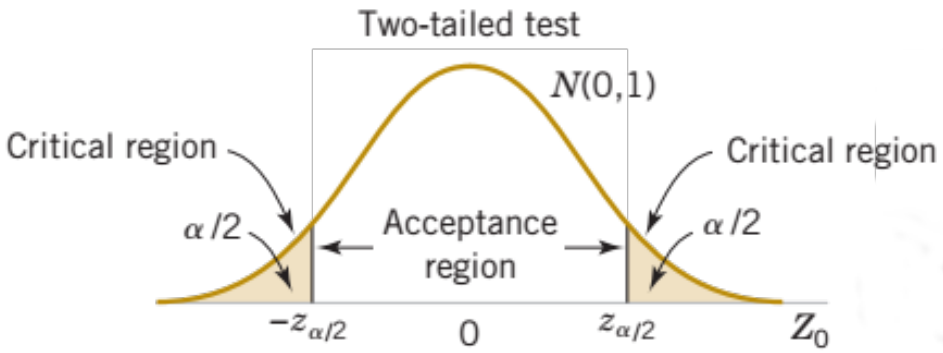
Déterminer la région critique



Pour un niveau de confiance $100(1-\alpha)\%$.

- Les bornes ($-z_{\alpha/2}$ et $z_{\alpha/2}$) fixent la région de rejet de H_0, où $z_{\alpha/2}$ est le centile d'ordre $(1-\alpha/2)$ de la distribution normale
- Si H_0 est vraie alors
  - la probabilité est de $1-\alpha$ que z_0 (**estimée à partir de l'échantillon ou réalisation de** $Z_0 \sim \mathcal{N}(0,1)$) tombe entre $-z_{\alpha/2}$ et $z_{\alpha/2}$.
  - *i.e.* la proba est de α que z_0 tombe à l'extérieur...donc que c'est un évènement peu probable et donc que dans ce cas que l'hypothèse H_0 est probablement fausse.

Déterminer la région critique



Il s'agit de fixer le niveau de confiance $100(1-\alpha)\%$.

- Ainsi, nous dirons que nous:
  - **rejetons** H_0 si
    $z_0 > z_{\alpha/2}$ ou $z_0 < -z_{\alpha/2}$ *i.e.* $\bar{x}_n > \mu_0 + z_{\alpha/2}\sigma/\sqrt{n}$ ou $\bar{x}_n < \mu_0 - z_{\alpha/2}\sigma/\sqrt{n}$
  - **ne pouvons rejeter** H_0 si
    $-z_{\alpha/2} \leq z_0 \leq z_{\alpha/2}$ *i.e.* $\mu_0 - z_{\alpha/2}\sigma/\sqrt{n} \leq \bar{x}_n \leq \mu_0 + z_{\alpha/2}\sigma/\sqrt{n}$

Relation entre les tests d'hypothèse & les intervalles de confiance

Test pour la moyenne d'une distribution normale, variance connue

Tests statistiques d'hypothèses pour un échantillon

Relation entre les tests d'hypothèse & les intervalles de confiance

- Une relation étroite existe entre le test d'une hypothèse sur un paramètre θ et un intervalle de confiance pour θ.
- Si $[l, u]$ est un intervalle de confiance pour le paramètre θ et si α est l'erreur de type I du test : $H_0 : \theta = \theta_0$ vs $H_1 : \theta \neq \theta_0$.
- Ce test **conclura à rejeter H_0 si θ_0 n'est pas dans l'intervalle de confiance** $[l, u]$.

p-valeurs dans les tests d'hypothèse

Test pour la moyenne d'une distribution normale, variance connue

Tests statistiques d'hypothèses pour un échantillon

p-valeurs dans les tests d'hypothèse

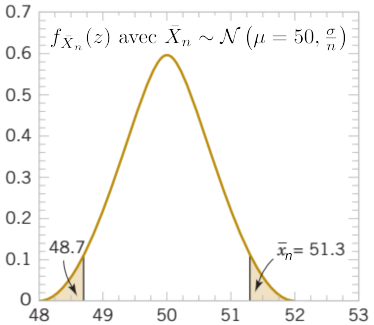
Nous avons vu la façon de reporter les résultats d'un test d'hypothèse *i.e.* H_0 est rejetée ou pas à un niveau de confiance $100(1-\alpha)\%$ (α est fixé).
C'est une décision dure (rejet ou pas), sans savoir si on est proche ou loin des bornes de la région critique.
La p-valeur permet de quantifier cela et amène une décision plus nuancée.

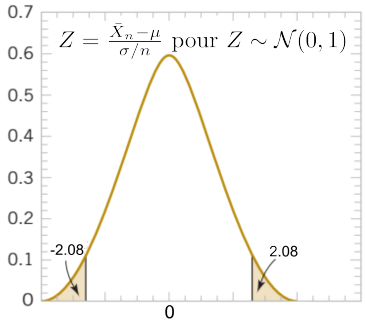
Def: p-valeur

La p-valeur est la plus petite valeur de α conduisant à rejeter l'hypothèse nulle H_0 pour un échantillon de données.

Exemple et interprétation de la p-valeur

Considérons l'exemple de la vitesse de combustion, pour le test bilatéral: H_0: $\mu = 50$cm/s vs H_1: $\mu \neq 50$cm/s. Supposons qu'un n-échantillon fournit une moyenne d'échantillon $\bar{x}_n = 51.3$ cm/s et une valeur critique correspondante $z_0 = 2.08$.
La p-valeur donne la probabilité d'observer un n-échantillon dont la moyenne est au moins aussi extrême, soit:





$$
\begin{aligned}
p\text{-value} &= 1 - \mathbb{P}\left(48.7 < \bar{X}_n < 51.3\right) \\
&= 1 - \mathbb{P}\left(-2.08 < Z < 2.08\right) \\
&= 0.038
\end{aligned}
$$

- La p-valeur nous dit que si H_0 est vraie, la proba d'obtenir un n-échantillon dont la moyenne d'échantillon est supérieure à 51.3 ou inférieure à 48.7 est de 0.038.
- *i.e.* obtenir un échantillon de moyenne 51.3 est rare si H_0 est vraie.

Pratique de la p-valeur

Un fois la p-valeur calculée, comment l'interpréter en pratique?

- Une **petite p-valeur**: la valeur observée de la statistique (ici $\bar{X}_n$) est éloignée de la vraie valeur du paramètre (μ). **Preuve forte que H_0 doit être rejetée.**
- Une **grande p-valeur**: la valeur observée de la statistique est proche de la vraie valeur du paramètre. **Pas suffisamment de preuve pour rejeter H_0**

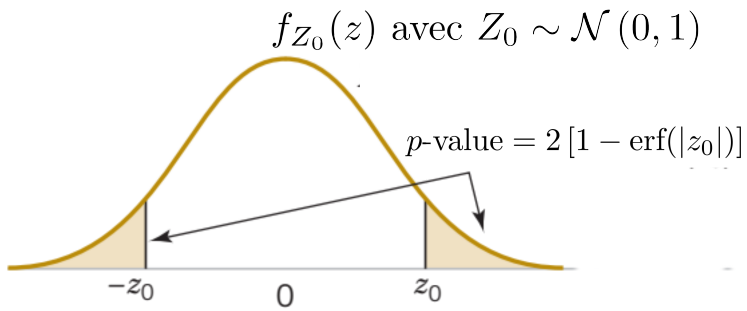
Prop: A partir de quelle p-valeur peut on rejeter H_0?

Si la p-valeur est inférieure ou égale à un niveau de confiance α préalablement choisi, alors l'hypothèse nulle H_0 peut être rejetée, et les résultats peuvent être considérés comme statistiquement significatifs à un niveau α. Beaucoup de chercheurs/scientifiques utilisent les règles suivantes:

- **Si p-valeur < 0.01**, H_0 est rejetée.
  Les résultats sont statistiquement hautement significatifs.
- **Si $0.01 <$ p-valeur < 0.05**, H_0 est rejetée.
  Les résultats sont statistiquement significatifs.
- **Si $0.05 <$ p-valeur < 0.10**, H_0 n'est pas rejetée.
  Les résultats tendent seulement à être statistiquement significatifs.
- **Si p-valeur > 0.10**, H_0 n'est pas rejetée.
  Les résultats ne sont pas statistiquement significatifs.

Calculer la p-valeur

Pour tester l'hypothèse nulle H_0 en utilisant l'approche de la p-valeur, il s'agit de trouver la probabilité d'observer une valeur de la moyenne de l'échantillon qui est au moins aussi extrême que $\bar{x}_n$ sous l'hypothèse que H_0 est vraie.



Si H_0 est vraie, $\mu = \mu_0$, alors la valeur $z_0 = \frac{\bar{x}_n - \mu_0}{\sigma/\sqrt{n}}$ est une réalisation de la VA $Z_0 = \frac{\bar{X}_n - \mu_0}{\sigma/\sqrt{n}}$ et elle définit les deux régions sur la figure. La p-valeur est la probabilité liée à ces régions (l'aire de ces régions). Mathématiquement,

$$\begin{aligned} p\text{-value} &= \mathbb{P}\left(Z_0 < -|z_0| \text{ ou } Z_0 > |z_0|\right) \\ &= 1 - \mathbb{P}\left(-|z_0| < Z_0 < |z_0|\right) \\ &= 1 - F_{Z_0}\left(|z_0|\right) + F_{Z_0}\left(-|z_0|\right) \\ &= 2 - 2F_{Z_0}\left(|z_0|\right) \\ &= 2 - 2\text{erf}\left(|z_0|\right) \end{aligned}$$

Procédure générale pour les tests d'hypothèse

Test pour la moyenne d'une distribution normale, variance connue

Tests statistiques d'hypothèses pour un échantillon

Procédure générale pour les tests d'hypothèse

D'un point de vue méthodologique, il vous est **obligatoire** d'adopter la procédure suivante pour mettre en œuvre un test statistique:

prop: Procédure obligatoire

1. **Grandeur d'intérêt: A partir du problème et de son contexte**, identifier la grandeur d'intérêt: moyenne, proportion, distribution, etc.
2. **Hypothèse nulle, H_0:** postuler l'hypothèse nulle.
3. **Hypothèse alternative, H_1:** Spécifier l'hypothèse alternative en fonction de la nature du test : test bilatéral ou unilatéral (voir plus loin).
4. **Test statistique:** Choisir et justifier le test statistique approprié (cherchez dans votre poly).
5. **Rejeter H_0 si:** Déterminer le critère de réjection pour H_0
   - (région critique) Choisir un niveau de risque α (généralement .05 ou .01) et calculer les limites de la région critique
   - (p-valeur) ou choisir de calculer la p-valeur
6. **Calculs:** Calculer les quantités nécessaires à partir de l'échantillon, les substituer dans l'équation pour le test statistique, et calculer la valeur finale.
7. **Décision:** Décider si H_0 doit être rejetée ou pas et conclure quant au contexte du problème.

Test pour la moyenne d'une distribution normale, variance connue

Def: Z-Test

Grandeur d'intérêt: moyenne
Hypothèse nulle: $H_0 : \mu = \mu_0$
Hypothèse alternative bilatérale: $H_1 : \mu \neq \mu_0$
Statistique du test: $Z_0 = \frac{\bar{X}_n - \mu_0}{\sigma/\sqrt{n}} \sim \mathcal{N}(0,1)$ estimée par z_0 à partir du n-échantillon.

Hypothèse alternative bilatérale	**Critères de rejet de H_0**	
	pour α fixé	**avec p-valeur**
$H_1 : \mu \neq \mu_0$	$z_0 > z_{\alpha/2}$ **ou** $z_0 < -z_{\alpha/2}$	$2 - 2\text{erf}\left(\lvert z_0 \rvert\right) < 0.05$

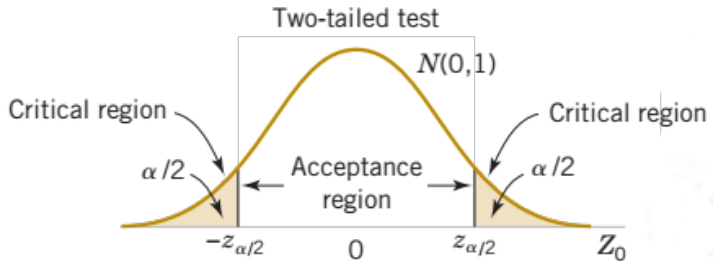
où $z_{\alpha/2} = \text{erf}^{-1}\left(1 - \frac{\alpha}{2}\right)$ peut être déterminé à partir du tableau (slide 288) de la fonction de répartition de la loi normale centrée réduite ou calculé numériquement (avec python par exemple).

Test pour la moyenne d'une distribution normale, variance connue

Graphiquement, à partir de la valeur critique z_0 calculée

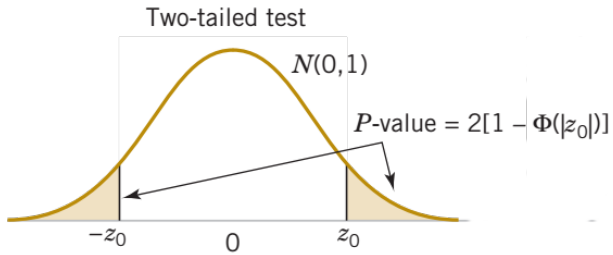
Critère de rejet de H_0 pour α fixé

On rejette H_0 si z_0 se situe dans la région critique dont la limite est fixée par le centile $z_{\alpha/2}$ pour un risque fixé $\alpha = 0.01, 0.05, \ldots$



Critère de rejet de H_0 avec p-valeur

On rejette H_0 si la proba p-valeur calculée à partir de la valeur critique z_0 est < 0.05



Test pour la moyenne d'un grand échantillon

Tests statistiques d'hypothèses pour un échantillon

Moyenne d'un grand échantillon de distribution quelconque

Pour un grand échantillon ($n \geq 30$), l'hypothèse de la distribution normale n'est plus nécessaire, la même procédure s'applique car le TCL s'applique. Si σ^2 est inconnue et si $n \geq 40$ (**dans ce cours** on garde $n \geq 30$), on peut remplacer σ^2 par s_n^2.

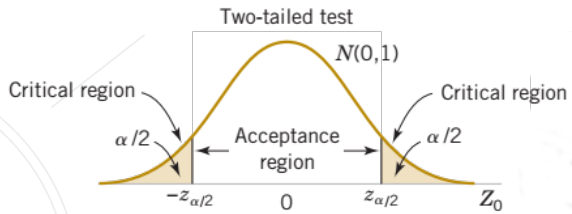
Def: moyenne d'un grand échantillon de distribution inconnue

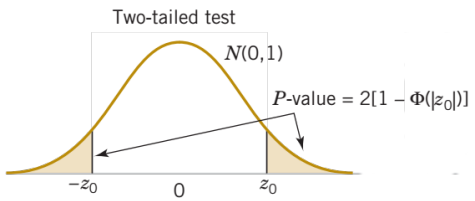
Grandeur d'intérêt: moyenne, **Hypothèse nulle**: H_0: $\mu = \mu_0$, **Hypothèse alternative bilatérale**: $H_1 : \mu \neq \mu_0$.

Statistique du test: $Z_0 = \frac{\bar{X}_n - \mu_0}{\sigma/\sqrt{n}} \sim \mathcal{N}(0,1)$ estimée par z_0 à partir du n-échantillon.

Hypothèse alternative bilatérale	**Critères de rejet de H_0**	
	pour α fixé	**avec p-valeur**
$H_1 : \mu \neq \mu_0$	$z_0 > z_{\alpha/2}$ ou $z_0 < -z_{\alpha/2}$	$2 - 2\text{erf}\left(\lvert z_0 \rvert\right) < 0.05$

où $z_{\alpha/2} = \text{erf}^{-1}\left(1 - \frac{\alpha}{2}\right)$ peut être déterminé à partir du tableau (slide 288) de la fonction de répartition de la loi normale centrée réduite ou calculé numériquement.





Test pour la moyenne d'une distribution normale, σ^2 inconnue

Tests statistiques d'hypothèses pour un échantillon

Test pour la moyenne d'une distribution normale, variance inconnue

Dans cette section,

- nous considérons le test d'hypothèse pour la moyenne μ d'une population normale où la variance de la population σ^2 est inconnue.
- Nous supposerons que le n-échantillon $X_1, X_2, \ldots, X_n$ a été généré à partir de cette population.

On raisonne exactement de la même manière que dans la section précédente et on reprend les mêmes résultats que pour les intervalles de confiance:

- $T_0 = \frac{\bar{X}_n - \mu}{S_{n-1}/\sqrt{n}}$ a une distribution de Student avec $n-1$ degrés de liberté.

Formalisation du test

Test pour la moyenne d'une distribution normale, σ^2 inconnue

Tests statistiques d'hypothèses pour un échantillon

Formalisation du test

- On veut tester H_0: $\mu = \mu_0$ vs H_1: $\mu \neq \mu_0$ où μ_0 est une constante spécifiée.
- T_0 a une distribution de Student à $n-1$ degrés de liberté si l'hypothèse nulle H_0 est vraie.
- Nous disposons d'un n-échantillon $X_1, X_2, \ldots, X_n$ généré par une distribution normale.
- Nous disposons donc d'une réalisation t_0 de T_0.

Pour le test, on peut construire une région critique (fixer le niveau de confiance) ou une p-valeur (fixer les bornes).
Ce test est souvent appelé **t-test**.

Formalisation du test: calcul de la région critique

Test pour la moyenne d'une distribution normale, σ^2 inconnue

Tests statistiques d'hypothèses pour un échantillon

Déterminer la région critique

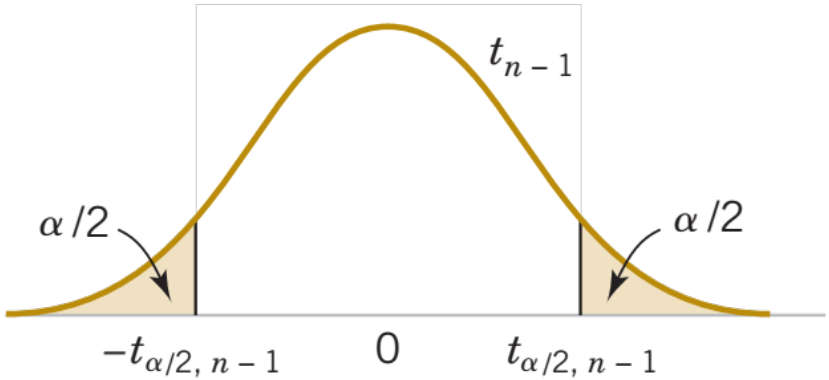


Figure: distribution de Student T_0 à $n-1$ degrés de liberté.

Il s'agit de fixer le niveau de confiance $100(1-\alpha\%)$.

- Déterminer les bornes ($-t_{\alpha/2,n-1}$ et $t_{\alpha/2,n-1}$) de la région de rejet de H_0
- Si H_0 est vraie alors
  - la probabilité est de $1-\alpha$ que t_0 tombe entre $-t_{\alpha/2,n-1}$ et $t_{\alpha/2,n-1}$ où $t_{\alpha/2,n-1}$ est le centile d'ordre $(1-\alpha/2)$ de la distribution de Student à $n-1$ degrés de liberté.
  - *i.e.* la proba est de α que t_0 tombe à l'extérieur...donc que c'est un évènement peu probable et donc que dans ce cas que l'hypothèse T_0 est probablement fausse.

Déterminer la région critique

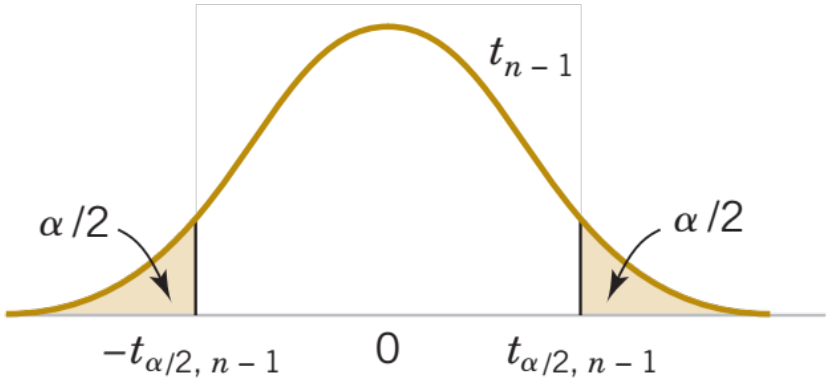


Figure: distribution de Student T_0 à $n-1$ degrés de liberté.

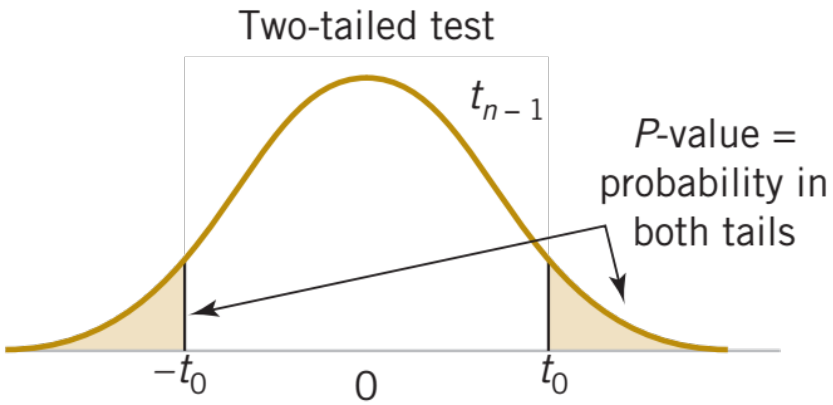
Ainsi, nous dirons que nous

- rejetons H_0 si
  $t_0 > t_{\alpha/2,n-1}$ ou $t_0 < -t_{\alpha/2,n-1}$ *i.e.*
  $\bar{x}_n > \mu_0 + t_{\alpha/2,n-1} s_{n-1}/\sqrt{n}$ ou $\bar{x}_n < \mu_0 - t_{\alpha/2,n-1} s_{n-1}/\sqrt{n}$

- ne pouvons rejeter H_0 si
  $-t_{\alpha/2,n-1} \leq t_0 \leq t_{\alpha/2,n-1}$ *i.e.*
  $\mu_0 - t_{\alpha/2,n-1} s_{n-1}/\sqrt{n} \leq \bar{x}_n \leq \mu_0 + t_{\alpha/2,n-1} s_{n-1}/\sqrt{n}$

Calculer la p-valeur

Pour tester l'hypothèse nulle H_0 en utilisant l'approche de la p-valeur, il s'agit de trouver la probabilité d'observer une valeur de la moyenne de l'échantillon qui est au moins aussi extrême que $\bar{x}_n$ sous l'hypothèse que H_0 est vraie.



Si H_0 est vraie, $\mu = \mu_0$, alors la valeur $t_0 = \frac{\bar{x}_n - \mu_0}{s_{n-1}/\sqrt{n}}$ est une réalisation de la VA $T_0 = \frac{\bar{X}_n - \mu_0}{S_{n-1}/\sqrt{n}}$ et elle définit deux régions sur la figure. La p-valeur est la probabilité liée à ces régions (l'aire de ces régions). Mathématiquement,

$$\begin{aligned} p\text{-value} &= \mathbb{P}\left(T_0 < -|t_0|\right) + \mathbb{P}\left(T_0 > |t_0|\right) \\ &= 2\mathbb{P}\left(T_0 > |t_0|\right) \\ &= 2 - 2F_{T_0}\left(|t_0|\right) \end{aligned}$$

Moyenne d'une distribution Normale, variance inconnue

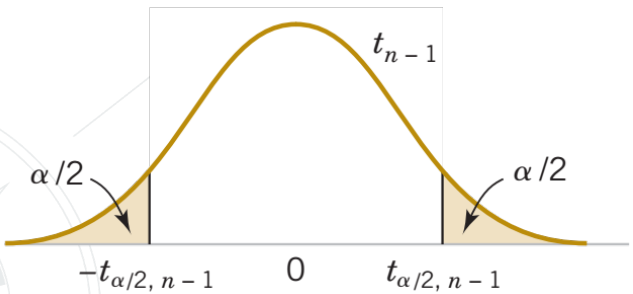
Def t-Test: Moyenne d'une distribution Normale, variance inconnue

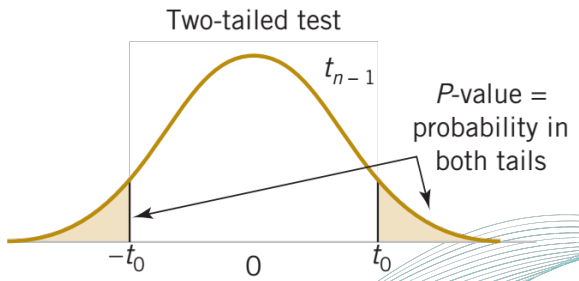
Grandeur d'intérêt: moyenne **Hypothèse nulle**: $H_0 : \mu = \mu_0$ **Hypothèse alternative bilatérale**: $H_1 : \mu \neq \mu_0$

Statistique du test: $T_0 = \frac{\bar{X}_n - \mu_0}{S_{n-1}/\sqrt{n}} \sim St(n-1)$ estimée par t_0 à partir du n-échantillon.

Hypothèse alternative bilatérale	**Critères de rejet de H_0**	
	pour α fixé	**avec p-valeur**
$H_1 : \mu \neq \mu_0$	$t_0 > t_{\alpha/2,n-1}$ ou $t_0 < -t_{\alpha/2,n-1}$	$2 - 2F_{T_0}(\lvert t_0 \rvert) < 0.05$

où la valeur $t_{\alpha/2,n-1} = F_T^{-1}(1-\alpha/2)$ peut être déterminée à partir du tableau de la fonction de répartition de la loi de Student avec $n-1$ degrés de liberté (cf annexes, slide 291).





Tests pour une proportion de la population

Tests statistiques d'hypothèses pour un échantillon

Formalisation du test d'une proportion

Tests pour une proportion de la population

Tests statistiques d'hypothèses pour un échantillon

Formalisation du test

Soit n individus d'une certaine population. Supposons qu'on veuille tester l'hypothèse selon laquelle la proportion p d'individus d'une certaine classe est égale à une valeur spécifiée p_0.

- Soit $X_1, X_2, \ldots, X_n$ un n-échantillon de cette population
- H_0: $p = p_0$ **vs** H_1: $p \neq p_0$
- La VA $X(\leq n)$ le nombre d'observations de cet échantillon appartenant à cette classe particulière.
- Alors $\hat{P} = X/n$ est un estimateur ponctuel de la proportion de la population p qui appartient à cette classe.
- X suit une loi Binomiale $\mathcal{B}(n, p)$
- Si $np_0 > 5$ et $n(1 - p_0) > 5$ **on peut approximer la loi de X par une loi normale** $\mathcal{N}(np_0, np_0(1 - p_0))$.
- **Dans ce cas, la statistique du test sous H_0 sera** $Z_0 = \frac{X - np_0}{\sqrt{np_0(1-p_0)}} = \frac{X/n - p_0}{\sqrt{np_0(1-p_0)/n}} = \frac{\hat{P} - p_0}{\sqrt{p_0(1-p_0)/n}}$ et sera estimée par z_0 sur l'échantillon.

Test grand échantillon pour une proportion d'une distribution

Tests pour une proportion de la population

Tests statistiques d'hypothèses pour un échantillon

Proportion d'une distribution (grand échantillon)

Pour un grand échantillon ($n \geq 30$ et $np > 5$ et $n(1-p) > 5$), la loi binomiale est approximée par une loi normale, le TCL s'applique. Soit X le nombre d'observations de cet échantillon appartenant à une classe particulière.

Def: Test grand échantillon pour une proportion

Grandeur d'intérêt: proportion
Hypothèse nulle: H_0: $p = p_0$
Hypothèse alternative bilatérale: $H_1 : p \neq p_0$
Statistique du test sous H_0:
$Z_0 = \frac{X - np_0}{\sqrt{np_0(1-p_0)}} = \frac{X/n - p_0}{\sqrt{np_0(1-p_0)}/n} = \frac{\hat{P} - p_0}{\sqrt{p_0(1-p_0)/n}} \sim \mathcal{N}(0,1)$ estimée sur l'échantillon par z_0

Hypothèse alternative bilatérale	**Critères de rejet de H_0**	
	pour α fixé	**avec p-valeur**
$H_1 : p \neq p_0$	$z_0 > z_{\alpha/2}$ ou $z_0 < -z_{\alpha/2}$	$2 - 2\text{erf}(\lvert z_0 \rvert) < 0.05$

où $z_{\alpha/2} = \text{erf}^{-1}\left(1 - \frac{\alpha}{2}\right)$ peut être déterminée à partir du tableau (slide 288) de la fonction de répartition de la loi normale centrée réduite.

Tests statistiques unilatéraux

Tests statistiques d'hypothèses pour un échantillon

Hypothèses statistiques unilatérales

Dans certaines situations, on formule une hypothèse alternative unilatérale

Def: Hypothèses statistiques unilatérales

la vitesse moyenne est elle inférieure à 50 cm/s?

- H_0: $\mu = 50$cm/s
- H_1: $\mu < 50$cm/s

OU

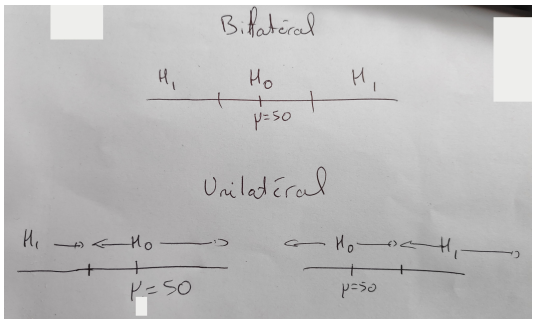
la vitesse moyenne est elle supérieure à 50 cm/s?

- H_0: $\mu = 50$ cm/s
- H_1: $\mu > 50$ cm/s

Rem: on pose toujours H_0 comme étant une égalité

En réalité,

- H_0: $\mu \geq 50$ cm/s
- H_0: $\mu \leq 50$ cm/s.



Hypothèses statistiques unilatérales (1/3)

Exemple pour une proportion (grand échantillon)

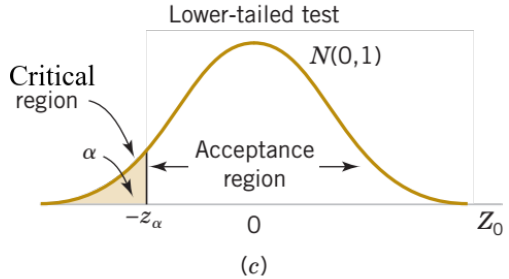
1. **Paramètre d'intérêt:** la proportion
2. **Hypothèse nulle,** H_0**:** $p = p_0$
3. **Hypothèse alternative,** H_1**:** $p < p_0$
4. **Test statistique:** Cas d'un grand échantillon: la formule pour le test bilatéral ne s'applique plus ! La statistique Z_0 est pourtant la même. $Z_0 = \frac{\hat{P} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}}$ et on doit calculer la borne $-z_\alpha$ à partir de $\mathbb{P}(Z_0 < -z_\alpha)$

Hypothèses statistiques unilatérales (2/3)

Exemple pour une proportion (grand échantillon)

1. **Rejeter H_0 si:**
   - **(région critique)** si $z_0 < -z_\alpha$ avec

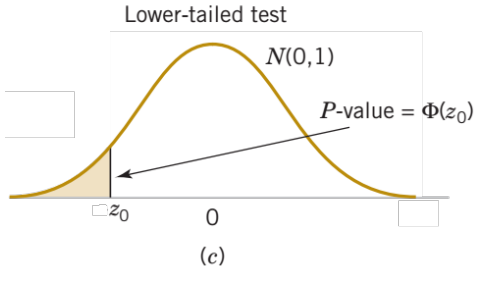
$$\mathbb{P}\left(Z_0 < -z_\alpha\right) = \alpha \Longleftrightarrow \mathbb{P}\left(Z_0 \geq z_\alpha\right) = \alpha$$
$$\Longleftrightarrow 1 - \mathbb{P}\left(Z_0 \leq z_\alpha\right) = \alpha$$
$$z_\alpha = \mathrm{erf}^{-1}\left(1-\alpha\right)$$



Détermination de $-z_\alpha$

   - **(p-valeur)** < 0.05.

$$p\text{-val} = \mathbb{P}\left(Z_0 < z_0\right)$$
$$= erf(z_0)$$



Calcul de la p-valeur

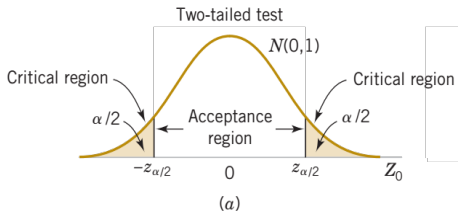
Hypothèses statistiques unilatérales (3/3)

Exemple pour une proportion (grand échantillon)

Def: Test bilatéral

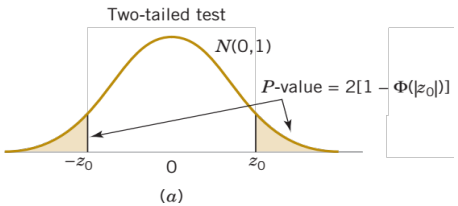
$$H_1 : p \neq p_0$$

Région critique



$$z_{\alpha/2} = \text{erf}^{-1}(1 - \alpha/2)$$

p-valeur

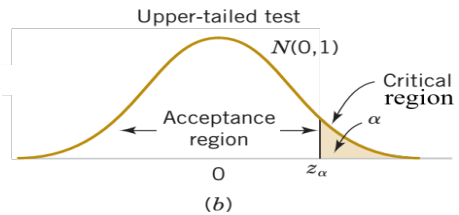


$$p\text{-val} = 2(1 - \text{erf}(|z_0|))$$

Test unilatéral à droite

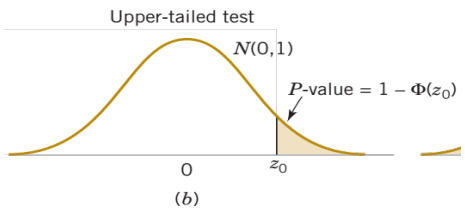
$$H_1 : p > p_0$$

Région critique



$$z_\alpha = \text{erf}^{-1}(1 - \alpha)$$

p-valeur

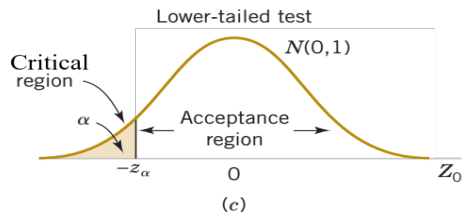


$$p\text{-val} = 1 - \text{erf}(z_0)$$

Test unilatéral à gauche

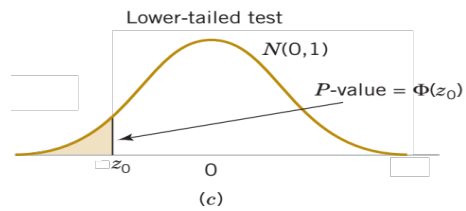
$$H_1 : p < p_0$$

Région critique



$$-z_\alpha = -\text{erf}^{-1}(1 - \alpha)$$

p-valeur



$$p\text{-val} = \text{erf}(z_0)$$

Tableau résumé des tests pour un échantillon

Tests statistiques d'hypothèses pour un échantillon

Test pour la moyenne d'une distribution normale, variance connue

Def: Z-Test

Grandeur d'intérêt: moyenne
Hypothèse nulle: $H_0 : \mu = \mu_0$
Hypothèse alternative : H_1 : à choisir ci-dessous
Statistique du test: $Z_0 = \frac{\bar{X}_n - \mu_0}{\sigma/\sqrt{n}} \sim \mathcal{N}(0,1)$ estimée par z_0 à partir du n-échantillon.

Hypothèse alternative	**Critères de rejet de H_0**	
	pour α fixé	**avec p-valeur**
$H_1 : \mu \neq \mu_0$	$z_0 > z_{\alpha/2}$ **ou** $z_0 < -z_{\alpha/2}$	$2 - 2\text{erf}\left(\lvert z_0 \rvert\right) < 0.05$
$H_1 : \mu > \mu_0$	$z_0 > z_\alpha$	$1 - \text{erf}\left(z_0\right) < 0.05$
$H_1 : \mu < \mu_0$	$z_0 < -z_\alpha$	$\text{erf}\left(z_0\right) < 0.05$

où $z_x = \text{erf}^{-1}\left(1 - x\right)$ peut être déterminé à partir du tableau (slide 288) de la fonction de répartition de la loi normale centrée réduite ou calculé numériquement (avec python par exemple).

Moyenne d'un grand échantillon de distribution quelconque

Pour un grand échantillon ($n \geq 30$), l'hypothèse de la distribution normale n'est plus nécessaire, la même procédure s'applique car le TCL s'applique. Si σ^2 est inconnue et si $n \geq 40$ (**dans ce cours** on garde $n \geq 30$), on peut remplacer σ^2 par s_n^2.

Def: moyenne d'un grand échantillon de distribution inconnue

Grandeur d'intérêt: moyenne **Hypothèse nulle**: H_0: $\mu = \mu_0$ **Hypothèse alternative** : H_1 : à choisir ci-dessous
Statistique du test: $Z_0 = \frac{\bar{x}_n - \mu_0}{\sigma/\sqrt{n}} \sim \mathcal{N}(0,1)$ estimée par z_0 à partir du n-échantillon.

Hypothèse alternative	**Critères de rejet de H_0**	
	pour α fixé	**avec p-valeur**
$H_1 : \mu \neq \mu_0$	$z_0 > z_{\alpha/2}$ ou $z_0 < -z_{\alpha/2}$	$2 - 2\text{erf}\left(\lvert z_0 \rvert\right) < 0.05$
$H_1 : \mu > \mu_0$	$z_0 > z_\alpha$	$1 - \text{erf}\left(z_0\right) < 0.05$
$H_1 : \mu < \mu_0$	$z_0 < -z_\alpha$	$\text{erf}\left(z_0\right) < 0.05$

où $z_x = \text{erf}^{-1}\left(1 - x\right)$ peut être déterminé à partir du tableau (slide 288) de la fonction de répartition de la loi normale centrée réduite ou calculé numériquement.

Moyenne d'une distribution Normale, variance inconnue

Def t-Test: Moyenne d'une distribution Normale, variance inconnue

Grandeur d'intérêt: moyenne
Hypothèse nulle: $H_0 : \mu = \mu_0$
Hypothèse alternative : à choisir ci-dessous
Statistique du test: $T_0 = \frac{\bar{X}_n - \mu_0}{S_n/\sqrt{n}} \sim St(n-1)$ estimée par t_0 à partir du n-échantillon.

Hypothèse alternative	**Critères de rejet de H_0**	
	pour α fixé	**avec p-valeur**
$H_1 : \mu \neq \mu_0$	$t_0 > t_{\alpha/2,n-1}$ ou $t_0 < -t_{\alpha/2,n-1}$	$2 - 2F_{T_0}(\lvert t_0 \rvert) < 0.05$
$H_1 : \mu > \mu_0$	$t_0 > t_{\alpha,n-1}$	$1 - F_{T_0}(t_0) < 0.05$
$H_1 : \mu < \mu_0$	$t_0 < -t_{\alpha,n-1}$	$F_{T_0}(t_0) < 0.05$

où la valeur $t_{x,n-1} = F_T^{-1}(1-x)$ peut être déterminée à partir du tableau de la fonction de répartition de la loi de Student avec $n-1$ degrés de liberté (cf slide 291) ou Python.

Proportion d'une distribution (grand échantillon)

Pour un grand échantillon ($n \geq 30$ et $np_0 > 5$ et $n(1-p_0) > 5$), la loi binomiale est approximée par une loi normale, le TCL s'applique. Soit X le nombre d'observations de cet échantillon appartenant à une classe particulière.

Def: Test grand échantillon pour une proportion

Grandeur d'intérêt: proportion
Hypothèse nulle: H_0: $p = p_0$
Hypothèse alternative : à choisir ci-dessous
Statistique du test sous H_0:
$Z_0 = \frac{X - np_0}{\sqrt{np_0(1-p_0)}} = \frac{X/n - p_0}{\sqrt{np_0(1-p_0)/n}} = \frac{\hat{P} - p_0}{\sqrt{p_0(1-p_0)/n}} \sim \mathcal{N}(0,1)$ estimée sur l'échantillon par z_0

Hypothèse alternative	**Critères de rejet de H_0**	
	pour α fixé	**avec p-valeur**
$H_1 : p \neq p_0$	$z_0 > z_{\alpha/2}$ ou $z_0 < -z_{\alpha/2}$	$2 - 2\text{erf}(\lvert z_0 \rvert) < 0.05$
$H_1 : p > p_0$	$z_0 > z_\alpha$	$1 - \text{erf}(z_0) < 0.05$
$H_1 : p < p_0$	$z_0 < -z_\alpha$	$\text{erf}(z_0) < 0.05$

où $z_x = \text{erf}^{-1}(1-x)$ peut être déterminée à partir du tableau (slide 288) de la fonction de répartition de la loi normale centrée réduite.

Tester l'adéquation à un modèle de distribution

Tests statistiques d'hypothèses pour un échantillon

Résumé de la dernière séance

Procédure générale de test

- Déterminer le paramètre du test (moyenne ou proportion)
- Déterminer une statistique dépendant des paramètres de l'échantillon et de la population (par ex μ et $\bar{x}_n$)
- Les matheux des probabilités nous donnent la densité de probabilité et la fonction de répartition de la statistique choisie (par ex $\mathcal{N}(0,1)$)
- On construit le test après avoir calculé la valeur critique (par ex z_0) sur la réalisation du n-échantillon:
  - soit en déterminant un seuil (par ex $z_{\alpha/2}$) en fixant α,
  - soit en calculant la p-valeur à partir de la valeur critique.

Tester l'adéquation à un modèle de distribution

- Les procédures que nous avons vu jusqu'à présent sont construites pour des problèmes dans lesquels la population ou la distribution de probabilité est connue et les hypothèses concernent les paramètres de la distribution.
- Une autre sorte d'hypothèse est souvent rencontrée: **on ne connaît pas la distribution de la population et nous souhaitons tester l'hypothèse selon laquelle un modèle particulier de distribution s'applique pour la population**.
- Dans cette partie, nous formalisons ce test connu sous le nom de **test d'ajustement (Goodness-of-Fit)** et ici basé sur la distribution du χ^2.

Plus généralement, dans cette partie, on aborde des tests non paramétriques (car ils ne portent pas sur un paramètre comme précédemment) basés sur la distribution du χ^2, d'où leur nom: **test du** χ^2,
Ces tests utilisent la distance du χ^2 que nous avons vue dans la première partie de ce cours, une distance *trop grande* menant au rejet l'hypothèse nulle H_0.

Tester l'adéquation à un modèle de distribution

Hypothèses

- Le test requiert un **n-échantillon** $X_1, X_2, \ldots, X_n$ dont la **distribution de probabilité est inconnue**.
- Les n observations (*i.e.* la réalisation du n-échantillon) sont **regroupées par intervalle** (représentation possible sous forme d'histogramme en fréquence).
- Le nombre d'intervalles est k.
- Soit n_i l'**effectif observé** dans chaque intervalle $i = 1 \ldots k$.
- Soit np_i l'**effectif théorique** de chaque intervalle associé au modèle de distribution qu'on veut tester.
  $p_i = \mathbb{P}\,(\text{VA du problème appartiennent à l'intervalle } i) = \mathbb{P}\,(X_i \in I_i)$

La théorie des probabilités permet de montrer que:

$$\chi_0^2 = \sum_{i=1}^{k} \frac{(n_i - np_i)^2}{np_i} \text{ suit une loi du } \chi^2 \text{ à } (k - p - 1) \text{ degrés de liberté}$$

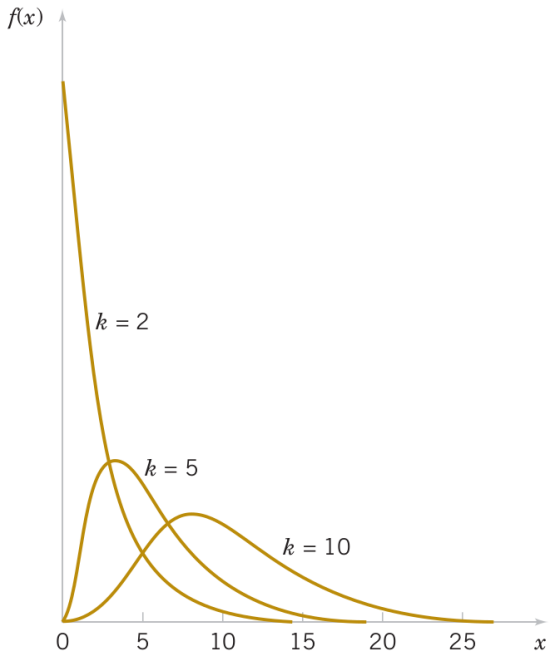
où p désigne le nombre de paramètres (de la distribution théorique testée) qui ont été estimés à partir des observations.

La distribution du χ^2

La densité de probabilité du χ^2 à k **degrés de liberté** est définie par:

$$\forall x > 0,\ f_{\chi^2}(x) = \frac{1}{2^{k/2}\Gamma[k/2]} x^{(k/2)-1} e^{-x/2}$$

où $\Gamma(.)$ est la fonction Gamma d'Euler.



Tester l'adéquation à un modèle de distribution

- L'hypothèse nulle H_0 stipulera que la distribution de l'échantillon est la distribution théorique.
- A partir de l'échantillon, χ^2_0 sera estimé par χ^2_{Obs}
- On rejette l'hypothèse nulle H_0 si la valeur de χ^2_{Obs} (distance du χ^2) est trop grande, en d'autres termes:
  - pour un niveau de confiance $100(1-\alpha)\%$ (α fixé), si $\chi^2_{Obs} > \chi^2_{k-p-1,\alpha}$, où $\chi^2_{k-p-1,\alpha}$ est le centile de la fonction de répartition de la VA χ^2_{k-p-1} pour un risque α (tabulée en annexe)
  - ou si la p-valeur égale à la probabilité $\mathbb{P}\left(\chi^2_{k-p-1} > \chi^2_{Obs}\right)$ est inférieure au risque 0.05.

Attention

Attention à la valeur des np_i!

- Si une des valeurs np_i, n'est pas assez grande, le test ne fonctionne pas.
- Il n'y a pas de consensus sur la valeur minimale d'un np_i mais des valeurs de 3, 4, ou 5 sont généralement utilisées.
- **Dans ce cours, nous forçons la condition que $\forall\ i, np_i > 5$**
- Si cette condition n'est pas respectée, les effectifs de deux intervalles adjacents peuvent être sommés et k réduit de 1. Il n'est pas requis que les intervalles finaux soient de longueurs égales.

Tester l'adéquation à un modèle de distribution

Pour un échantillon de taille n dont la distribution de probabilité est inconnue. Les n observations sont regroupées par intervalle. Le nombre d'intervalles est k. Soit n_i l'**effectif observé** dans chaque intervalle $i = 1 \dots k$. Soit np_i l'**effectif théorique** de chaque intervalle associé au modèle de distribution qu'on veut tester.
$p_i = \mathbb{P}$ (VA du problème appartiennent à l'intervalle i)

Def: Tester l'adéquation à un modèle de distribution

Grandeur d'intérêt: distribution, **Hypothèse nulle**: H_0 : "la distribution de l'échantillon est la distribution théorique", **Hypothèse alternative** : H_1 : "la distribution de l'échantillon n'est pas la distribution théorique".

Statistique du test sous H_0: $\chi^2_0 = \sum_{i=1}^{k} \frac{(n_i - np_i)^2}{np_i} \sim \chi^2_{k-p-1}$ estimée sur l'échantillon par χ^2_{Obs}

Hypothèse alternative	**Critères de rejet de H_0**	
	pour α fixé	**avec p-valeur**
H_1 : la distribution de l'échantillon n'est pas la distribution théorique	$\chi^2_{Obs} > \chi^2_{k-p-1,\alpha}$	$1 - F_{\chi^2_{k-p-1}}(\chi^2_{Obs}) < 0.05$

où $\chi^2_{k-p-1,\alpha} = F^{-1}_{\chi^2_{k-p-1}}(\alpha)$ déterminé par la fonction de répartition inverse (table 294) de la loi du χ^2 à $k - p - 1$ degrés de liberté où p désigne le nombre de paramètres (de la distribution théorique testée) qui ont été estimés à partir de l'échantillon.

Exemple: nombre de défauts dans les cartes de circuits imprimés

Ex: nombre de défauts dans les cartes de circuits imprimés

Le nombre de défauts dans les cartes de circuits imprimés est supposé suivre une distribution de Poisson. Un n-échantillon de $n = 60$ cartes de circuits a été collecté, et le nombre suivant de défauts a été observé:

Nombre de défauts	Effectifs observés
0	32
1	15
2	9
3 (ou plus)	4

Exemple: nombre de défauts dans les cartes de circuits imprimés

La moyenne de la distribution de Poisson supposée dans cet exemple est inconnue et doit être estimée à partir des données de l'échantillon. L'estimation du nombre moyen de défauts par cartes est la moyenne de l'échantillon,

$$\bar{x}_n = \frac{(32 \cdot 0 + 15 \cdot 1 + 9 \cdot 2 + 4 \cdot 3)}{n} = 0.75$$

D'après la distribution de Poisson avec le paramètre 0.75, nous pouvons calculer p_i , la probabilité théorique, hypothétique, associée au $i^{ème}$ intervalle de classe. Comme chaque intervalle de classe correspond à un nombre particulier de défauts, nous pouvons trouver la p_i comme suit :

$$p_1 = P(X = 0) = \frac{e^{-0.75}(0.75)^0}{0!} = 0.472$$

$$p_2 = P(X = 1) = \frac{e^{-0.75}(0.75)^1}{1!} = 0.354$$

$$p_3 = P(X = 2) = \frac{e^{-0.75}(0.75)^2}{2!} = 0.133$$

$$p_4 = P(X \geq 3) = 1 - (p_1 + p_2 + p_3) = 0.041$$

Exemple: nombre de défauts dans les cartes de circuits imprimés

Les effectifs théoriques sont calculés en multipliant la taille de l'échantillon $n = 60$ par les probabilités p_i . C'est-à-dire $E_i = np_i$. Les fréquences attendues sont les suivantes :

Nombre de défauts	Probabilité p_i	Effectifs théoriques $n\dot{p}_i$
0	0.472	28.32
1	0.354	21.24
2	0.133	7.98
3 (ou plus)	0.041	2.46

Exemple: nombre de défauts dans les cartes de circuits imprimés (1/3)

Comme l'effectif théorique dans la dernière cellule est inférieur à 3, nous combinons les deux dernières cellules :

Nombre de défauts	Probabilité	Effectifs théoriques	Effectifs observés
0	0.472	28.32	32
1	0.354	21.24	15
2 (ou plus)	0.174	10.44	13

$$\bar{x}_n = \frac{(32 \cdot 0 + 15 \cdot 1 + 13 \cdot 2)}{n} = 0.68$$

D'après la distribution de Poisson avec le paramètre 0.68, nous pouvons calculer p_i , la probabilité théorique, hypothétique, associée au $i^{ème}$ intervalle de classe. Comme chaque intervalle de classe correspond à un nombre particulier de défauts, nous pouvons trouver la p_i comme suit :

Exemple: nombre de défauts dans les cartes de circuits imprimés (2/3)

$$p_1 = P(X = 0) = \frac{e^{-0.68}(0.68)^0}{0!} = 0.506$$

$$p_2 = P(X = 1) = \frac{e^{-0.68}(0.68)^1}{1!} = 0.344$$

$$p_3 = P(X \geq 2) = 1 - (p_1 + p_2) = 0.1500$$

Nombre de défauts	Probabilité	Effectifs théoriques	Effectifs observés
0	0.506	30.36	32
1	0.344	20.64	15
2 (ou plus)	0.150	9.00	13

1. **Grandeur d'intérêt:** distribution du nombre de défauts
2. **Hypothèse nulle, H_0:** la distribution des défauts suit un modèle de Poisson(0.68)
3. **Hypothèse alternative, H_1:** la distribution des défauts ne suit pas un modèle de Poisson(0.68)

Exemple: nombre de défauts dans les cartes de circuits imprimés (3/3)

4. **Test statistique:** $\chi_0^2 = \sum_{i=1}^{k} \frac{(n_i - np_i)^2}{np_i}$ estimée par χ_{Obs}^2 à partir de l'échantillon
5. **Niveau de confiance:** Choisir un niveau de confiance $1 - \alpha$ ou de risque α.
6. **Rejeter H_0 si:**
   - Région critique:$\chi_{Obs}^2 > \chi_{k-p-1,\alpha}^2$
   - p-valeur $= \mathbb{P}\left(\chi_{k-p-1}^2 > \chi_{Obs}^2\right) est inférieure à 0.05$
7. **Calculs:**

$$\chi_{Obs}^2 = \frac{(32 - 30.36)^2)}{30.36} + \frac{(15 - 20.64)^2)}{20.64} + \frac{(13 - 9.00)^2)}{9.00} = 3.40$$

8. **Décision:** Nous trouvons dans la table de l'annexe que $\chi_{1,0.10}^2 = 2.71$ et $\chi_{1,0.05}^2 = 3.84$. Parce que $\chi_{Obs}^2 = 3.40$ se situe entre ces valeurs, nous concluons que la p-valeur est comprise entre 0,05 et 0,10. Par conséquent, comme la p-valeur est supérieure à 0.05, nous ne pouvons pas rejeter l'hypothèse nulle selon laquelle la distribution des défauts dans les circuits imprimés est de Poisson. La p-valeur exacte calculée à partir du logiciel est de 0.0651.

Tests d'indépendance et d'homogénéité pour une table de contingence

Tests statistiques d'hypothèses pour un échantillon

Tests d'indépendance pour une table de contingence

- Dans beaucoup de problèmes auxquels vous aurez à faire face, vous aurez recueilli n **éléments d'une population selon deux (ou plusieurs) variables.** Il sera vraisemblablement intéressant de savoir si les deux variables sont **indépendantes**.
- Par exemple, il peut être intéressant de savoir si le salaire des ingénieurs dépend ou pas de la discipline académique des ingénieurs.
- Dans ce cas, les deux VA concernées peuvent être **qualitatives ou quantitatives** mais il faut qu'elles soient **regroupées dans une table de contingence** (ce qui implique regroupées par intervalle pour les VA continues).

Formalisation du test d'indépendance pour une table de contingence

Les **hypothèses** de ce test sont:

- Un n-échantillon de taille n où (au moins) deux variables sont récoltées.
- Nous supposons donc que la première variable a p classes/intervalles/valeurs et que la seconde a q valeurs.
- La table de contingence observé par les n observations est donc de p lignes et q colonnes, où chaque élément sera noté n_{ij} avec $i \in \{1, \dots, p\}$ et $j \in \{1, \dots, q\}$

		Colonnes			
		1	2	...	q
Lignes	1	n_{11}	n_{12}	...	n_{1q}
	2	n_{21}	n_{22}	...	n_{2q}
	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
	p	n_{p1}	n_{p2}	...	n_{pq}

Formalisation du test d'indépendance pour une table de contingence

Au sens probabiliste du terme,

- **deux évènements** X et Y sont indépendants si $\mathbb{P}(XetY) = \mathbb{P}(X)\,\mathbb{P}(Y)$.
- **pour une table de contingence**,
  $\forall i \in \{1,\ldots,p\}, \forall j \in \{1,\ldots,q\}$, $\mathbb{P}(X = i \text{ et } Y = j) = \mathbb{P}(X = i)\,.\mathbb{P}(Y = j)$.

On rappelle que $\mathbb{P}(X = i)$ et $\mathbb{P}(Y = j)$:

- sont les probabilités marginales du couple de VA (X, Y)
- peuvent être estimées statistiquement par un échantillon de taille n, à savoir,
  $\mathbb{P}(X = i) = \frac{n_{i\bullet}}{n}$ et $\mathbb{P}(Y = i) = \frac{n_{\bullet j}}{n}$.

Formalisation du test d'indépendance pour une table de contingence

- Pour notre **table de contingence sous hypothèse d'indépendance**,

$$\forall i \in \{1, \dots, p\}, \forall j \in \{1, \dots, q\}, \mathbb{P}\left(X = i \text{ et } Y = j\right) = \frac{n_{ij}}{n} = \frac{n_{i\bullet} n_{\bullet j}}{n^2}.$$

- Le **test d'indépendance du χ^2** consiste à **comparer** les effectifs observés n_{ij} et les effectifs sous hypothèse d'indépendance $\frac{n_{i\bullet} n_{\bullet j}}{n}$.
- Si la distance entre les deux est trop grande l'hypothèse d'indépendance sera rejetée.
- La **statistique utilisée** sera $\chi_0^2 = \sum_{i=1}^{p} \sum_{j=1}^{q} \frac{\left(n_{ij} - \frac{n_{i\bullet} n_{\bullet j}}{n}\right)^2}{\frac{n_{i\bullet} n_{\bullet j}}{n}}$.
- On peut montrer que **sous hypothèse d'indépendance**, cette statistique χ_0^2 suit une loi du χ^2 à $(p-1)(q-1)$ degrés de libertés.
- L'estimée de cette valeur à partir de l'échantillon sera notée χ_{Obs}^2.

Tester l'indépendance de deux variables

Pour un n-échantillon sur lequel on a observé deux variables, les n observations sont regroupées par intervalle ou par valeur. Le nombre d'intervalles/valeurs est p et q respectivement pour les deux variables. Soit n_{ij} l'**effectif observé** dans chaque intervalle $\forall i \in \{1,\dots,p\}, \forall j \in \{1,\dots,q\}$. Soit $\frac{n_{i\bullet} n_{\bullet j}}{n}$ l'**effectif sous hypothèse d'indépendance** de chaque intervalle.

Def: Tester l'indépendance de deux variables aléatoires

Grandeur d'intérêt: indépendance
Hypothèse nulle: H_0 : "les deux variables sont indépendantes"
Hypothèse alternative : H_1 : "les deux variables ne sont pas indépendantes"

Statistique sous H_0: $\chi^2_0 = \sum_{i=1}^{p}\sum_{j=1}^{q} \frac{\left(n_{ij} - \frac{n_{i\bullet} n_{\bullet j}}{n}\right)^2}{\frac{n_{i\bullet} n_{\bullet j}}{n}} \sim \chi^2_{(p-1)(q-1)}$ estimée par χ^2_{Obs}

Hypothèse alternative	**Critères de rejet de H_0**	
	pour α fixé	**avec p-valeur**
H_1 : les deux VA ne sont pas indépendantes	$\chi^2_{Obs} > \chi^2_{(p-1)(q-1),\alpha}$	$\mathbb{P}\left(\chi^2_{(p-1)(q-1)} > \chi^2_{Obs}\right) = 1 - F_{\chi^2_{(p-1)(q-1)}}(\chi^2_{Obs}) < 0.05$

où $\chi^2_{(p-1)(q-1),\alpha} = F^{-1}_{\chi^2_{(p-1)(q-1)}}(\alpha)$ avec $F_{\chi^2_{(p-1)(q-1)}}()$ la fonction de répartition de la loi du χ^2 à $(p-1)(q-1)$ degrés de liberté (tabulée slide 294).

Préférence de complémentaire santé (1/2)

Ex: Préférence de complémentaire santé

Une société doit choisir entre 3 propositions de complémentaire santé. La direction souhaite savoir les préférences des salariés et savoir si cette préférence est indépendante qu'on soit salarié cadre ou salarié ouvrier. Elle souhaite avoir une conclusion en prenant un risque de 5%. Les préférences de 500 salariés sont regroupés dans le tableau suivant:

salariés	1	2	3	$n_{i\bullet}$
Ouvriers	160	140	40	340
Cadres	40	60	60	160
$n_{\bullet j}$	200	200	100	500

1. **Grandeur d'intérêt:** indépendance de la distribution des préférences entre les catégories de salariés
2. **Hypothèse nulle, H_0:** les préférences sont indépendantes des catégories de salariés
3. **Hypothèse alternative, H_1:** les préférences ne sont pas indépendantes des catégories de salariés

Préférence de complémentaire santé (2/2)

4. **Test statistique:** $\chi_0^2 = \sum_{i=1}^{p} \sum_{j=1}^{q} \frac{\left(n_{ij} - \frac{n_{i\bullet} n_{\bullet j}}{n}\right)^2}{\frac{n_{i\bullet} n_{\bullet j}}{n}}$ estimée par χ_{Obs}^2
5. **Niveau de confiance:** Choisir un niveau de confiance $1-\alpha$ ou de risque α.
6. **Rejeter H_0 si:**
   - Région critique: $\chi_{Obs}^2 > \chi_{k-p-1,\alpha}^2$
   - p-valeur $= \mathbb{P}\left(\chi_{(p-1)(q-1)}^2 > \chi_{Obs}^2\right) < 0.05$
7. **Calculs:**

Effectifs théoriques	1	2	3	$n_{i\bullet}$
Ouvriers	136	136	68	340
Cadres	64	64	32	160
$n_{\bullet j}$	200	200	100	500

$$\chi_{Obs}^2 = \frac{(160-136)^2}{136} + \frac{(160-136)^2}{136} + \frac{(40-68)^2}{68} + \frac{(40-64)^2}{64} + \cdots = 49.63$$

8. **Décision:** Nous trouvons dans la table de l'annexe que $\chi_{2,0.05}^2 = 5.99$. Nous rejetons l'hypothèse H_0 d'indépendance et concluons qu'il n'y a pas d'indépendance. De plus, la p-valeur$= 1.671.10^{-11}$ très faible montre que le résultat est hautement significatif.

Tester l'homogénéité de deux variables (1/2)

- L'utilisation de la table de contingence pour **tester l'indépendance** entre deux variables de classification dans un échantillon provenant d'une seule population d'intérêt n'est qu'une application parmi d'autres.
- Une **autre situation** peut se produire lorsqu'il existe p populations d'intérêt et que chaque population est divisée en *q catégories identiques*.
- Dans cette situation, nous voulons *vérifier si les proportions dans les p catégories sont les mêmes pour toutes les populations*.
- L'**hypothèse nulle** est alors l'**homogénéité des p populations** sur l'ensemble des q catégories.
- **Le test d'homogénéité du χ^2 est alors rigoureusement identique à celui d'indépendance.**

Tester l'homogénéité de deux variables (2/2)

Exemple La forêt Hopkins est une réserve forestière de 2 600 acres située à la jonction de trois États : New York, Vermont et Massachusetts. Les chercheurs surveillent les ressources forestières afin d'étudier les changements écologiques à long terme. Ils ont mené des enquêtes sur les arbres, arbustes et herbes existants à divers endroits de la forêt pendant près de 100 ans. Voici quelques données issues d'enquêtes menées sur trois espèces d'érables au même endroit au cours de trois périodes très différentes.

Year	Pensylvanicum	Rubrum	Saccharum	**Total**
1936	12	27	94	133
1972	22	40	52	114
2011	97	25	18	140
Total	131	92	164	387

Inférences statistiques pour deux échantillons

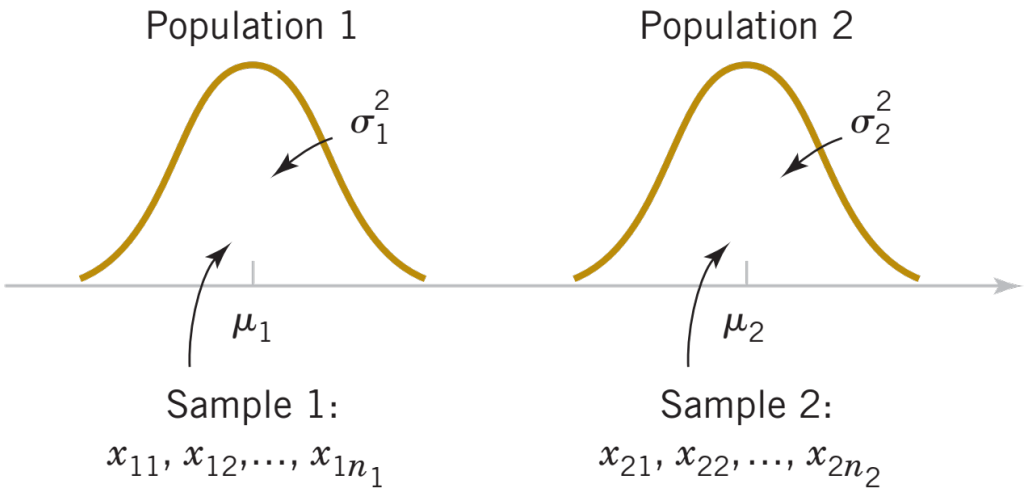
- Introduction
- Inférences statistiques pour la différence de moyennes de deux distributions normales, variances connues
- Inférences statistiques pour la différence de moyennes de deux distributions normales, variances inconnues
- Inférences statistiques pour la différence de moyennes de deux distributions quelconques (cas des grands échantillons)
- Inférence pour deux proportions

Introduction

Inférences statistiques pour deux échantillons

Introduction

Les deux chapitres précédents présentent les tests d'hypothèse et les intervalles de confiance pour un paramètre d'un seul échantillon. Dans ce chapitre, **on étend les résultats au cas de deux populations indépendantes**.



- La **population 1** a une moyenne μ_1, une variance σ_1^2.
- La **population 2** a une moyenne μ_2, une variance σ_2^2.
- Les inférences seront basées sur un n_1-échantillon pour la population 1 et un n_2-échantillon pour la population 2.
- Les VA des échantillons sont notées $X_{1,1}, \ldots, X_{1,n_1}$ et $X_{2,1}, \ldots, X_{2,n_2}$ respectivement.

L'objectif de ce chapitre est globalement d'**étudier les différences entre les paramètres des deux populations** comme critères de ressemblance des populations.

Introduction

- Les ingénieurs et chercheurs en statistiques s'intéressent souvent à **comparer deux conditions différentes** pour déterminer si chaque condition produit un effet significatif sur la réponse qui est observé.
- Par exemple,
  - l'effet de deux (ou plus) formules de peinture sur le temps de séchage,
  - l'exposition de deux groupes de patients à deux niveaux de fer dans le sang.
- Ce type d'analyse peut conduire à analyser des **relations de causes à effets** à condition que des biais dans le protocole (double aveugle) et dans l'analyse (d'autres facteurs sont-ils possibles?) soient rigoureusement écartés.

Inférences statistiques pour la différence de moyennes de deux distributions normales, variances connues

Inférences statistiques pour deux échantillons

Différence de moyennes de deux distributions normales, variances connues

Dans cette partie, on considère des inférences statistiques sur la différence de moyennes $\mu_1 - \mu_2$ de deux distributions normales dont les variances σ_1^2 et σ_2^2 sont connues.

Les hypothèses :

- $X_{1,1}, \ldots, X_{1,n_1}$ est un n_1-échantillon généré à partir de la population 1.
- $X_{2,1}, \ldots, X_{2,n_2}$ est un n_2-échantillon généré à partir de la population 2.
- Les deux populations représentées par X_1 et X_2 sont **indépendantes** et de **distributions normales** $\mathcal{N}(\mu_1, \sigma_1^2)$ et $\mathcal{N}(\mu_2, \sigma_2^2)$.

Différence des moyennes de deux échantillons gaussiens de variances connues

Si nous avons deux populations indépendantes, quelle est la distribution de la différence de la moyenne des deux échantillons?

Prop:Différence des moyennes de deux échantillons gaussiens de variances connues

Soient deux populations gaussiennes indépendantes de moyennes μ_1 et μ_2 et de variances σ_1^2 et σ_2^2.
Si $\bar{X}_{n,1}$ et $\bar{X}_{n,2}$ sont les moyennes des deux échantillons de taille n_1 et n_2 alors la distribution d'échantillonnage de

$$Z = \frac{\bar{X}_{n,1} - \bar{X}_{n,2} - (\mu_1 - \mu_2)}{\sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}} \text{ est normale centrée réduite}$$

Formalisation du test

Pourquoi?

- L'**estimateur naturel** de $\mu_1 - \mu_2$ est la différence de la moyenne des échantillons $\bar{X}_{n,1} - \bar{X}_{n,2}$.
- Cet estimateur est une combinaison linéaire de deux VA normales est donc également de **distribution** $\mathcal{N}(\mu_1 - \mu_2, \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2})$.
- Alors la statistique

$$Z = \frac{(\bar{X}_{n,1} - \bar{X}_{n,2}) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \text{ suit une distribution } \mathcal{N}(0,1).$$

Ce résultat va être utilisé pour développer des procédures pour **tester des hypothèses** et pour construire des **intervalles de confiance** pour $\mu_1 - \mu_2$.

Tests d'hypothèse pour la différence de moyennes de deux distributions normales, variances connues

Inférences statistiques pour la différence de moyennes de deux distributions normales, variances connues

Inférences statistiques pour deux échantillons

Tests d'hypothèse pour la différence de moyennes de deux distributions normales, variances connues

Def: différence de moyennes de deux distributions normales, variances connues

Grandeur d'intérêt: moyenne

Hypothèse nulle: $H_0 : \mu_1 - \mu_2 = \Delta_0$

Hypothèse alternative bilatérale : $H_1 : \mu_1 - \mu_2 \neq \Delta_0$

Statistique du test sous H_0: $Z_0 = \frac{(\bar{X}_{n,1} - \bar{X}_{n,2}) - (\Delta_0)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim \mathcal{N}(0,1)$, estimée sur deux échantillons par z_0

Hypothèse alternative bilatérale	**Critères de rejet de H_0**	
	pour α fixé	**avec p-valeur**
$H_1 : \mu_1 - \mu_2 \neq \Delta_0$	$z_0 > z_{\alpha/2}$ ou $z_0 < -z_{\alpha/2}$	$2\left(1 - \text{erf}\left(\lvert z_0 \rvert\right)\right) < 0.05$

où $z_{\alpha/2} = F_{Z_0}^{-1}(1 - \alpha/2) = \text{erf}^{-1}(1 - \alpha/2)$ peut être déterminée à partir du tableau de la fonction de répartition de la loi normale centrée réduite.

Intervalle de confiance pour la différence de moyennes, variances connues

Inférences statistiques pour la différence de moyennes de deux distributions normales, variances connues

Inférences statistiques pour deux échantillons

IC pour la différence de moyennes de deux distributions normales, variances connues

Def: IC pour la différence de moyennes de deux distributions normales, variances connues

Si $\bar{x}_{n,1}$ et $\bar{x}_{n,2}$ sont les moyennes de deux échantillons aléatoires indépendants de taille n_1 et n_2 générés par deux distributions normales de variances connues σ_1^2 et σ_2^2, l'intervalle de confiance de niveau de confiance $100(1-\alpha)\%$ pour la différence de moyenne des populations $\mu_1 - \mu_2$ est donné par:

$$IC_{\mu_1-\mu_2,\alpha} = \left[\bar{x}_{n,1} - \bar{x}_{n,2} \pm z_{\alpha/2}\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}\right]$$

où $z_{\alpha/2} = F^{-1}_{\mathcal{N}(0,1)}(1-\alpha/2)$ le quantile d'ordre $1-\alpha/2$ d'une loi normale centrée réduite (voir fct de répartition de la loi normale centrée réduite en annexe, slide 288).

Exemple (1/1)

Résistance à la traction de l'aluminium

Des essais de résistance à la traction ont été effectués sur deux catégories différentes de longerons en aluminium utilisés dans la fabrication de l'aile d'un avion de transport commercial. D'après l'expérience acquise du processus de fabrication des longerons et de la procédure d'essai, les écarts-types des résistances à la traction sont supposés être connus.
Les données obtenues sont les suivantes : $n_1 = 10$, $\bar{x}_{n,1} = 87.6$, $\sigma_1 = 1$, $n_2 = 12$, $\bar{x}_{n,2} = 74.5$, et $\sigma_2 = 1.5$.
Trouver l'IC à 90% de la différence en moyenne de la résistance à la traction.

Inférences statistiques pour la différence de moyennes de deux distributions normales, variances inconnues

Inférences statistiques pour deux échantillons

Inférences statistiques pour la différence de moyennes de deux distributions normales, variances inconnues

- Cas des variances égales ($\sigma_1^2 = \sigma_2^2 = \sigma^2$)
- Cas des variances différentes ($\sigma_1^2 \neq \sigma_2^2$)

Inférences statistiques pour la différence de moyennes de deux distributions normales, variances inconnues

- Nous étendons les résultats de la section précédente aux cas plus réalistes où les variances des populations sont inconnues.
- Pour construire des tests d'hypothèse et intervalles de confiance quand les tailles d'échantillon sont petites, il faut :
  - supposer des distributions gaussiennes
  - se baser sur la distribution de Student
- Cependant, il faut envisager **deux situations**: mêmes variances ou variances différentes.

Tests d'hypothèse pour la différence de moyennes de deux distributions normales, variances inconnues et égales

Inférences statistiques pour la différence de moyennes de deux distributions normales, variances inconnues

Inférences statistiques pour deux échantillons

Diff. des moyennes de deux échantillons gaussiens ($\sigma_1^2 = \sigma_2^2 = \sigma^2$)

Prop:Diff. des moyennes de deux échantillons gaussiens de variances inconnues ($\sigma_1^2 = \sigma_2^2 = \sigma^2$)

Soient deux populations indépendantes de moyennes μ_1 et μ_2 et de variances σ_1^2 et σ_2^2. Si $(\bar{X}_{n_1,1}, S^2_{n-1,1})$ et $(\bar{X}_{n_2,2}, S^2_{n-1,2})$ sont les estimateurs des moyennes et variances (non biaisées) des deux échantillons de taille n_1 et n_2 alors la distribution d'échantillonnage de

$$T = \frac{\bar{X}_{n_1,1} - \bar{X}_{n_2,2} - (\mu_1 - \mu_2)}{S_p\sqrt{1/n_1 + 1/n_2}}$$ suit une distribution de Student (t-distribution)

avec $n_1 + n_2 - 2$ degrés de liberté et $S_p^2 = \frac{(n_1 - 1)S^2_{n-1,1} + (n_2 - 1)S^2_{n-1,2}}{n_1 + n_2 - 2}$

Tests d'hypothèse pour la différence de moyennes de deux distributions normales, variances inconnues et égales

Def: différence de moyennes de deux distributions normales, variances inconnues et égales

Grandeur d'intérêt: moyenne

Hypothèse nulle: $H_0 : \mu_1 - \mu_2 = \Delta_0$ **vs Hypothèse alternative** : $H_1 : \mu_1 - \mu_2 \neq \Delta_0$

Statistique du test sous H_0: $T_0 = \frac{\bar{X}_{n_1,1} - \bar{X}_{n_2,1} - (\mu_1 - \mu_2)}{S_p\sqrt{1/n_1 + 1/n_2}} \sim \mathrm{St}(n_1 + n_2 - 2)$, estimée sur deux échantillons par t_0 avec $S_p^2 = \frac{(n_1-1)s^2_{n-1,1} + (n_2-1)s^2_{n-1,2}}{n_1+n_2-2}$.

Hypothèse alternative	**Critères de rejet de H_0**	
	pour α fixé	**avec p-valeur**
$H_1 : \mu_1 - \mu_2 \neq \Delta_0$	$t_0 > t_{\alpha/2,n_1+n_2-2}$ ou $t_0 < -t_{\alpha/2,n_1+n_2-2}$	$2 - 2F_{T_0}(\lvert t_0 \rvert) < .05$

où $t_{\alpha/2,n_1+n_2-2} = F^{-1}_{T_0}(1-\alpha/2)$ peut être déterminée à partir du tableau de la fonction de répartition de la loi de Student (slide 291) avec $n_1 + n_2 - 2$ degrés de liberté.

Exemple (1/1)

Rendement d'un catalyseur

Deux catalyseurs sont analysés pour déterminer comment ils affectent le rendement moyen d'un procédé chimique. Plus précisément, le catalyseur 1 est actuellement utilisé, mais le catalyseur 2 est acceptable.
Comme le catalyseur 2 est moins cher, il devrait être adopté, s'il ne modifie pas le rendement du procédé. Un test est effectué dans l'usine pilote et donne les données présentées dans le tableau. Y a-t-il une différence dans les rendements moyens ? Utilisez $\alpha = 0.05$, et supposez des variances égales.

TABLE • 10-1 Catalyst Yield Data, Example 10-5

Observation Number	Catalyst 1	Catalyst 2
1	91.50	89.19
2	94.18	90.95
3	92.18	90.46
4	95.39	93.21
5	91.79	97.19
6	89.07	97.04
7	94.72	91.07
8	89.21	92.75
	$\bar{x}_1 = 92.255$	$\bar{x}_2 = 92.733$
	$s_1 = 2.39$	$s_2 = 2.98$

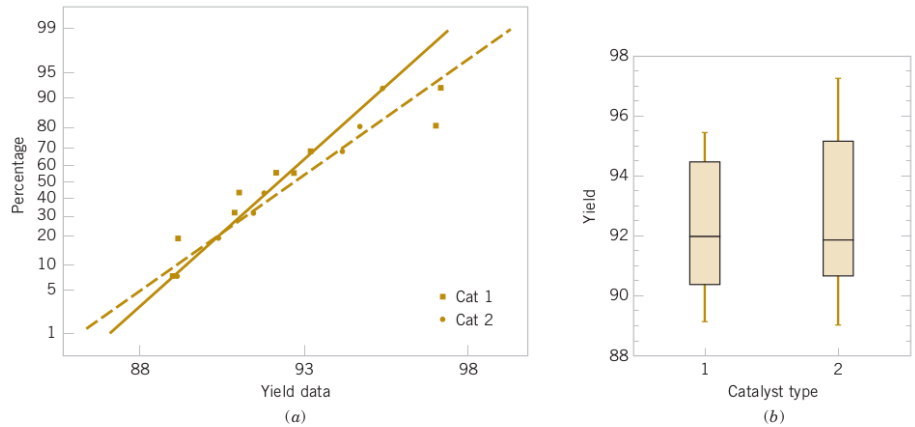


FIGURE 10-2 Normal probability plot and comparative box plot for the catalyst yield data in Example 10-5. (a) Normal probability plot. (b) Box plots.

Intervalle de confiance pour la différence de moyennes de deux distributions normales, variances inconnues et égales

Inférences statistiques pour la différence de moyennes de deux distributions normales, variances inconnues

Inférences statistiques pour deux échantillons

Intervalle de confiance pour la différence de moyennes de deux distributions normales, variances égales mais inconnues

Def: IC pour la différence de moyennes de deux distributions normales, variances égales mais inconnues

Si $\bar{x}_{n,1}$ et $\bar{x}_{n,2}$ sont les moyennes de deux échantillons aléatoires indépendants de taille n_1 et n_2 générés par deux distributions normales de variances connues σ_1^2 et σ_2^2, l'intervalle de confiance de niveau de confiance $100(1-\alpha)\%$ pour la différence de moyenne des populations $\mu_1 - \mu_2$ est donnée par:

$$IC_{\alpha,\mu} = \left[\bar{x}_{n,1} - \bar{x}_{n,2} \pm t_{\alpha/2,n_1+n_2-2} s_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}\right]$$

où $t_{\alpha/2,n_1+n_2-2} = F^{-1}_{Student(n_1+n_2-2)}(1-\alpha/2)$ le quantile d'ordre $1-\alpha/2$ d'une loi de Student de n_1+n_2-2 degrés de liberté (voir slide 291). Notez que $s_p^2 = \frac{(n_1-1)s^2_{n-1,1}+(n_2-1)s^2_{n-1,2}}{n_1+n_2-2}$

Tests d'hypothèse pour la différence de moyennes de deux distributions normales, variances inconnues et différentes

Inférences statistiques pour la différence de moyennes de deux distributions normales, variances inconnues

Inférences statistiques pour deux échantillons

Diff. des moyennes de deux échantillons gaussiens de variances différentes ($\sigma_1^2 \neq \sigma_2^2$) et inconnues

Prop:Différence des moyennes de deux échantillons gaussiens de variances différentes ($\sigma_1^2 \neq \sigma_2^2$) mais inconnues

Soient deux populations indépendantes de moyennes μ_1 et μ_2 et de variances σ_1^2 et σ_2^2. Si $(\bar{X}_{n,1}, S^2_{n-1,1})$ et $(\bar{X}_{n,2}, S^2_{n-1,2})$ sont les moyennes et variances des deux échantillons de taille n_1 et n_2 alors la distribution d'échantillonnage de

$$T = \frac{\bar{X}_{n,1} - \bar{X}_{n,2} - (\mu_1 - \mu_2)}{\sqrt{S^2_{n-1,1}/n_1 + S^2_{n-1,2}/n_2}}$$

a une distribution de Student (t-distribution) avec ν degrés de liberté avec

$$\nu = \frac{\left(S^2_{n-1,1}/n_1 + S^2_{n-1,2}/n_2\right)^2}{\frac{(S^2_{n-1,1}/n_1)^2}{n_1-1} + \frac{(S^2_{n-1,2}/n_2)^2}{n_2-1}}$$

Tests d'hypothèse pour la différence de moyennes de deux distributions normales, variances inconnues et différentes

Def: Différence de moyennes de deux distributions normales, variances inconnues et différentes

Grandeur d'intérêt: moyenne

Hypothèse nulle: $H_0 : \mu_1 - \mu_2 = \Delta_0$ **vs Hypothèse alternative** : $H_1 : \mu_1 - \mu_2 \neq \Delta_0$

Statistique du test sous H_0: $T_0 = \frac{\bar{X}_{n,1} - \bar{X}_{n,2} - (\mu_1 - \mu_2)}{\sqrt{S^2_{n-1,1}/n_1 + S^2_{n-1,2}/n_2}} \sim \text{St}(\nu)$ estimée sur les deux échantillons par t_0

Hypothèse alternative	**Critères de rejet de H_0**	
	pour α fixé	**avec p-valeur**
$H_1 : \mu_1 - \mu_2 \neq \Delta_0$	$t_0 > t_{\alpha/2,\nu}$ ou $t_0 < -t_{\alpha/2,\nu}$	$2 - 2F_{T_0}\lvert t_0\rvert < .05$

où $t_{\alpha/2,\nu} = F^{-1}_{T_0}(1 - \alpha/2)$ peut être déterminée à partir du tableau de la fonction de répartition de la loi de Student avec ν degrés de liberté (slide 291) et

$$\nu = \frac{\left(S^2_{n-1,1}/n_1 + S^2_{n-1,2}/n_2\right)^2}{\frac{(s^2_{n-1,1}/n_1)^2}{n_1 - 1} + \frac{(s^2_{n-1,2}/n_2)^2}{n_2 - 1}}$$

Si ν n'est pas un entier, on prend l'entier inférieur.

Exemple

Arsenic dans l'eau potable

La concentration d'arsenic dans les réserves publiques d'eau potable constitue un risque potentiel pour la santé. Un article paru dans l'Arizona Republic (27 mai 2001) faisait état de concentrations d'arsenic dans l'eau potable, exprimées en parties par milliard (ppb), dans 10 communautés de l'agglomération de Phoenix et 10 communautés rurales de l'Arizona. Les données sont les suivantes:

Metro Phoenix ($\bar{x}_1 = 12.5, s_1 = 7.63$)	**Rural Arizona** ($\bar{x}_2 = 27.5, s_2 = 15.3$)
Phoenix, 3	Rimrock, 48
Chandler, 7	Goodyear, 44
Gilbert, 25	New River, 40
Glendale, 10	Apache Junction, 38
Mesa, 15	Buckeye, 33
Paradise Valley, 6	Nogales, 21
Peoria, 12	Black Canyon City, 20
Scottsdale, 25	Sedona, 12
Tempe, 15	Payson, 1
Sun City, 7	Casa Grande, 18

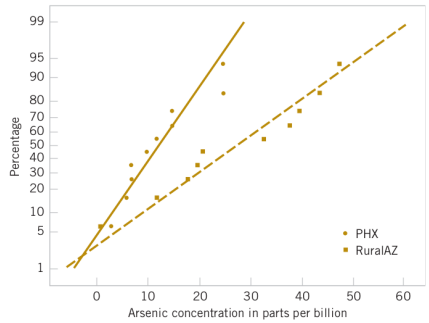


FIGURE 10-3 Normal probability plot of the arsenic concentration data from Example 10-6.

Nous souhaitons déterminer s'il existe une différence entre les concentrations moyennes d'arsenic dans les communautés de l'agglomération de Phoenix et dans les communautés rurales de l'Arizona. La figure droite ci-dessus montre les droites de Henry pour les deux échantillons de concentration d'arsenic. L'hypothèse de normalité semble tout à fait raisonnable, mais comme les pentes des deux lignes droites sont très différentes, il est peu probable que les variances de population soient les mêmes.

Intervalle de confiance pour la différence de moyennes de deux distributions normales, variances connues et différentes

Def: IC pour la différence de moyennes de deux distributions normales, variances inconnues et $\sigma_1^2 \neq \sigma_2^2$

Si $\bar{x}_{n,1}$ et $\bar{x}_{n,2}$ sont les moyennes de deux échantillons aléatoires indépendants de taille n_1 et n_2 générés par deux distributions normales de variances inconnues σ_1^2 et σ_2^2, l'intervalle de confiance de niveau de confiance $100(1-\alpha)\%$ pour la différence de moyenne des populations $\mu_1 - \mu_2$ est donnée par:

$$IC_{\alpha,\mu} = \left[\bar{x}_{n,1} - \bar{x}_{n,2} \pm t_{\alpha/2,\nu} \sqrt{\frac{s_{n-1,1}^2}{n_1} + \frac{s_{n-1,1}^2}{n_2}} \right]$$

où $t_{\alpha/2,\nu} = F^{-1}_{Student(\nu)}(1-\alpha/2)$ le quantile d'ordre $1-\alpha/2$ d'une loi de Student de ν degrés de liberté (voir annexe) où $\nu = \frac{\left(s_{n-1,1}^2/n_1 + s_{n-1,2}^2/n_2\right)^2}{\frac{(s_{n-1,1}^2/n_1)^2}{n_1-1} + \frac{(s_{n-1,2}^2/n_2)^2}{n_2-1}}$

Inférences statistiques pour la différence de moyennes de deux distributions quelconques (cas des grands échantillons)

Inférences statistiques pour deux échantillons

Différence des moyennes de deux échantillons de distrib. inconnue (cas des grands échantillons)

Prop:Différence des moyennes de deux échantillons de distrib. inconnue (cas des grands échantillons)

Soient deux populations indépendantes de moyennes μ_1 et μ_2 et de variances σ_1^2 et σ_2^2. Si $\bar{X}_{n,1}$ et $\bar{X}_{n,2}$ sont les moyennes des deux échantillons de taille n_1 et n_2 alors la distribution d'échantillonnage de

$$Z = \frac{\bar{X}_{n,1} - \bar{X}_{n,2} - (\mu_1 - \mu_2)}{\sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}}$$

est approximativement normale centrée réduite si les conditions du théorème limite centrale s'appliquent.

Différence de moyennes de deux distributions quelconques (cas des grands échantillons)

Inférences statistiques pour la différence de moyennes de deux distributions quelconques (cas des grands échantillons)

Inférences statistiques pour deux échantillons

différence de moyennes de deux distributions quelconques (cas des grands échantillons)

Def:différence de moyennes de deux distributions quelconques (cas des grands échantillons)

Grandeur d'intérêt: moyenne
Hypothèse nulle: $H_0 : \mu_1 - \mu_2 = \Delta_0$
Hypothèse alternative : $H_1 : \mu_1 - \mu_2 \neq \Delta_0$
Statistique du test sous H_0: $Z_0 = \frac{(\bar{X}_{n,1} - \bar{X}_{n,2}) - (\Delta_0)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim \mathcal{N}(0,1)$ estimée sur deux échantillons par z_0

Hypothèse alternative	**Critères de rejet de H_0**	
	pour α fixé	**avec p-valeur**
$H_1 : \mu_1 - \mu_2 \neq \Delta_0$	$z_0 > z_{\alpha/2}$ ou $z_0 < -z_{\alpha/2}$	$2\left(1 - \text{erf}\left(\lvert z_0 \rvert\right)\right) < .05$

où $z_{\alpha/2} = F_{2_0}^{-1}(1 - \alpha/2) = \text{erf}^{-1}(1 - \alpha/2)$ peut être déterminée à partir du tableau de la fonction de répartition de la loi normale centrée réduite.

- Dans le cas d'un **grand échantillon avec** $n \geq 40$ (dans ce cours $n \geq 30$ suffira), on peut également utiliser la procédure ci-dessus avec σ_1^2 et σ_2^2 pouvant être estimées par $s_{n,1}^2$ et $s_{n,2}^2$.

Intervalle de confiance pour la différence de moyennes, variances connues

Inférences statistiques pour la différence de moyennes de deux distributions quelconques (cas des grands échantillons)

Inférences statistiques pour deux échantillons

IC pour la différence de moyennes de deux distributions normales, variances connues

Def:IC pour la différence de moyennes de deux distributions normales, variances connues

Si $\bar{x}_{n,1}$ et $\bar{x}_{n,2}$ sont les moyennes de deux échantillons aléatoires indépendants de taille n_1 et n_2 générés par deux distributions normales de variances connues σ_1^2 et σ_2^2, l'intervalle de confiance de niveau de confiance $100(1-\alpha)\%$ pour la différence de moyenne des populations $\mu_1 - \mu_2$ est donnée par:

$$IC_{\alpha,\mu} = \left[\bar{x}_{n,1} - \bar{x}_{n,2} \pm z_{\alpha/2}\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}\right]$$

où $z_{\alpha/2} = F^{-1}_{\mathcal{N}(0,1)}(1-\alpha/2)$ le quantile d'ordre $1-\alpha/2$ d'une loi normale centrée réduite (voir fonction de répartition de la loi normale centrée réduite en annexe; slide 288).

- Dans le cas d'un **grand échantillon avec** $n \geq 40$ (dans ce cours $n \geq 30$ suffira), on peut également utiliser la procédure ci-dessus avec σ_1^2 et σ_2^2 peuvant être estimées par $s_{n,1}^2$ et $s_{n,2}^2$.

Inférence pour deux proportions

Inférences statistiques pour deux échantillons

Tests grands échantillons pour la différence de deux proportions

Inférence pour deux proportions

Inférences statistiques pour deux échantillons

Tests grands échantillons pour la différence de deux proportions

Def:différence de deux proportions (grands échantillons)

Grandeur d'intérêt: proportion

Hypothèse nulle: $H_0 : p_1 = p_2$ **vs Hypothèse alternative** : $H_1 : p_1 \neq p_2$

Statistique du test sous H_0: $Z_0 = \dfrac{\hat{P}_1 - \hat{P}_2}{\sqrt{\hat{P}(1-\hat{P})\left(\frac{1}{n_1}+\frac{1}{n_2}\right)}} \sim \mathcal{N}(0,1)$ estimée sur deux échantillons par z_0

Hypothèse alternative	**Critères de rejet de H_0**	
	pour α fixé	**avec p-valeur**
$H_1 : p_1 \neq p_2$	$z_0 > z_{\alpha/2}$ ou $z_0 < -z_{\alpha/2}$	$2 - 2\text{erf}\left(\lvert z_0 \rvert\right) < .05$

où

- $z_{\alpha/2} = \text{erf}^{-1}\left(1 - \alpha/2\right)$ peut être déterminée à partir du tableau de la fonction de répartition de la loi normale centrée réduite (slide 288).
- $\hat{P} = \frac{n_1\hat{P}_1 + n_2\hat{P}_2}{n_1+n_2}$

Intervalle de confiance pour la différence de proportion de deux populations

Inférence pour deux proportions

Inférences statistiques pour deux échantillons

Intervalle de confiance pour la différence de proportion de deux populations

Def:IC pour la différence de proportion de deux populations (grands échantillons)

Si $\hat{p}_1$ et $\hat{p}_2$ sont les proportions de deux échantillons aléatoires indépendants de taille n_1 et n_2, l'intervalle de confiance de niveau de confiance $100(1-\alpha)\%$ pour la différence de proportion $p_1 - p_2$ est donnée par:

$$IC_{\alpha,p} = \left[\hat{p}_1 - \hat{p}_2 \pm z_{\alpha/2}\sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}}\right]$$

où $z_{\alpha/2} = \mathrm{erf}^{-1}(1-\alpha/2)$ peut être déterminée à partir du tableau de la fonction de répartition de la loi normale centrée réduite (slide 288).

Remarque : ici, contrairement au test de rejet qui postule l'égalité des proportions (hypothèse nulle) et donc une seule et même population sous-jacente avec une proportion estimée $\hat{p}$, nous devons utiliser la meilleure estimée des proportions sur chacune des populations puisque nous essayons d'estimer l'écart entre les proportions vraies (mais inconnues) de deux populations distinctes.

Example (1/1)

roulements de vilebrequin

Considérez le processus de fabrication de roulements de vilebrequin. Le nombre de roulements défectueux dans un premier échantillon de 85 roulements est de 10. Supposons qu'une modification soit apportée au processus de finition de la surface et que, par la suite, un second échantillon aléatoire de 85 roulements soit obtenu. Le nombre de roulements défectueux dans ce second échantillon est de 8. Donc, parce que $n_1 = 85$, $\hat{p}_1 = 10/85 = 0.1176$, $n_2 = 85$, et $\hat{p}_2 = 8/85 = 0.0941$, nous pouvons obtenir un intervalle de confiance approximatif de 95% sur la différence de la proportion de roulements défectueux produits par les deux procédés.

Inférences statistiques pour plusieurs échantillons

- Test pour la différence de moyennes de plusieurs échantillons

Test pour la différence de moyennes de plusieurs échantillons

Inférences statistiques pour plusieurs échantillons

Test de Fisher (1/1)

Lorsque l'on a **plus de deux échantillons** à comparer, il convient de ne pas les comparer deux à deux, mais de les considérer dans leur globalité.

Le **test de Fisher permet de comparer les moyennes liées à de multiples échantillons**.

Ce test est basé sur l'influence d'un caractère qualitatif sur un caractère quantitatif.

Liaison entre deux variables: qualitative vs quantitative

Rappel

L'analyse de cette influence consiste à découper l'échantillon en plusieurs sous-échantillons (un pour chaque valeur de la variable qualitative)

Hélico Vs Temps de vol

Numéro du lancer	Helico	Temps
1	A	1,97
2	A	2,03
3	A	2,1
4	A	1,86
5	A	2
6	A	2,14
7	A	2,07
8	A	2,19
9	B	2,52
10	B	3,01
11	B	2,69
12	B	2,71
13	B	2,93
14	B	2,83
15	B	2,7
16	B	3,11
17	C	2,52
18	C	2,25
19	C	2,47
20	C	2,44
21	C	2,44
22	C	2,45
23	C	2,36
24	C	2,27
25	D	1,87
26	D	2,12
27	D	1,84
28	D	2,08
29	D	1,98
30	D	1,98
31	D	1,78
32	D	1,88

Définitions et notations

Définitions

Soient

- X la variable qualitative
  - prenant p valeurs (ou intervalles ou classes) $\{x_1, \ldots, x_p\}$
  - d'effectifs $\{n_1, \ldots, n_p\}$
- Y la variable quantitative de moyenne $\bar{y}_n$ et de variance $s^2_{n,Y}$
- Y_i la variable quantitative de moyenne $\bar{y}_i$ et de variance s^2_{n,Y_i} à partir d'individus ayant (sachant que) la valeur $X = x_i$ (sous-population i)
  - définit un sous-échantillon d'effectifs n_i de l'échantillon défini par Y.
  - ce sous-échantillon a une moyenne $\bar{y}_i$ et une variance associées s^2_{n,Y_i} :

Propriété

- Soit $n = \sum_{i=1}^{p} n_i$ l'effectif total.

Formule de décomposition de la variance

Rappel

Prop:

La variance totale se décompose en somme de la variance interclasse et intraclasse:

$$\begin{aligned} s^2_{n,Y} &= \frac{1}{n}\sum_{i=1}^{p} n_i \left(\bar{y}_i - \bar{y}_n\right)^2 & + \frac{1}{n}\sum_{i=1}^{p} n_i s^2_{n,Y_i} \\ &= s^2_B & + s^2_W \\ &= \text{variance inter-classe} & + \text{variance intra-classe} \end{aligned}$$

Def:Rapport de corrélation

La rapport de corrélation entre X variable qualitative et Y variable quantitative est défini par:

$$S_{Y/X} = \sqrt{\frac{s^2_B}{s^2_{n,Y}}} \in \{0, 1\}$$

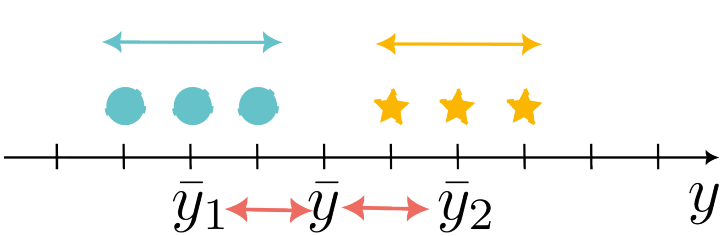
Test de Fisher (1/2)

Le **test de Fisher** reprend cette analyse de l'influence sous la forme d'un test.

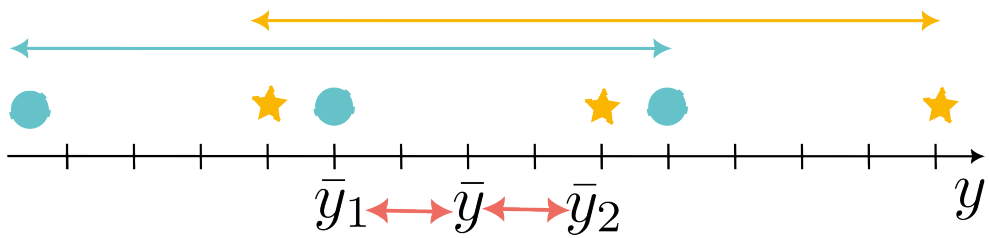
Le test de fisher consiste à tester l'hypothèse H_0: les moyennes $\bar{y}_i \ \forall i \in \{1, \dots p\}$ des p sous-populations définies sont égales. Sous H_0, les écarts entre les moyennes des classes:

- ne sont dus qu'à la dispersion de la loi de X,
- sont petits devant la dispersion interne aux classes (dispersion/variance intraclasse).

En revanche, une "trop grande" valeur de la dispersion inter-classes (variance externe aux classes) conduira donc à rejeter H_0 .



- faible variance intra-classe,
- forte variance inter-classe,
- d'où $S_{Y/X}$ grand et rejet de H_0.



- forte variance intra-classe,
- faible variance inter-classe,
- d'où $S_{Y/X}$ petit.

Test de Fisher (2/2)

Si H_0 est vraie alors la théorie des probabilités nous montre que la VA $F_0 = \frac{S_B^2/(p-1)}{S_W^2/(n-p)}$ suit une loi de Fisher de paramètres $p-1$ et $n-p$.

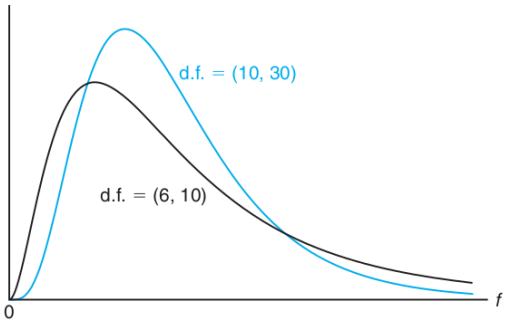


Figure 8.11: Typical F-distributions.

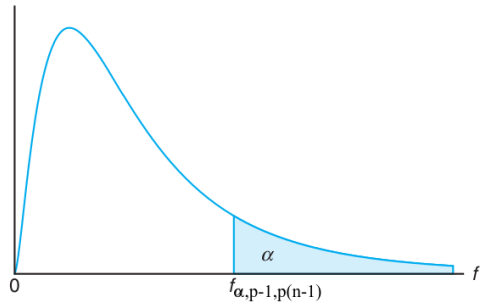


Figure 8.12: Illustration of the f_α for the F-distribution.

Ainsi on pourra estimer F_0 à partir des données par f_0 (f_0 la réalisation de la VA F_0 à partir de la réalisation des échantillons) et rejeter H_0

- (région critique) si $f_0 > f_{\alpha,(p-1),(n-p)} = F_{F_0}^{-1}(1-\alpha)$.
- (p-valeur) p-valeur $= \mathbb{P}(F_0 > f_0) = 1 - \mathbb{P}(F_0 \leq f_0) < 0.05$

Test de Fisher, analyse of variance (ANOVA)

Def: Test de Fisher

Grandeur d'intérêt: moyenne de plusieurs échantillons
Hyp. nulle H_0: les moyennes $\mu_i \ \forall i \in \{1, \dots p\}$ des p sous-populations sont égales.
Hyp. alternative H_1: les moyennes $\mu_i \ \forall i \in \{1, \dots p\}$ des p sous-pop. sont différentes.
Statistique du test sous H_0: $F_0 = \frac{S_B^2/(p-1)}{S_W^2/(n-p)} \sim$ Fisher $(p-1, n-p)$ estimée sur les données par f_0

Hypothèse alternative	**Critères de rejet de H_0**	
	pour α fixé	**avec p-valeur**
$H_1 : \mu_1, \mu_2, \dots, \mu_p \neq$	$f_0 > f_{(p-1),(n-p),\alpha}$	$1 - F_{F_0}(f_0) < .05$

où

$$f_{\alpha,(p-1),(n-p)} = F_{F_0}^{-1}(1-\alpha)$$

$$S_B^2 = \frac{1}{n}\sum_{i=1}^{p} n_i \left(\bar{y}_i - \bar{y}_n\right)^2$$

$$S_W^2 = \frac{1}{n}\sum_{i=1}^{p} n_i s_{n,Y_i}^2$$

Exemple (1/2)

Une expérience a été réalisée pour déterminer l'effet de quatre produits chimiques différents sur la résistance d'un tissu. Chaque échantillon de tissu a été testé une fois dans un ordre aléatoire. Les données sont:

	Fabric Sample				
Produit chimique	T1	T2	T3	T4	T5
PC1	1.3	1.6	0.5	1.2	1.1
PC2	2.2	2.4	0.4	2.0	1.8
PC3	1.8	1.7	0.6	1.5	1.3
PC4	3.9	4.4	2.0	4.1	3.4

Nous testons les différences de moyennes à l'aide d'une ANOVA avec $\alpha = 0.05$.

Exemple (2/2)

	Fabric Sample						
Produit chimique	T1	T2	T3	T4	T5	$\bar{y}_i$	s^2_{n,Y_i}
PC1	1.3	1.6	0.5	1.2	1.1	1.14	0.130
PC2	2.2	2.4	0.4	2.0	1.8	1.76	0.502
PC3	1.8	1.7	0.6	1.5	1.3	1.38	0.182
PC4	3.9	4.4	2.0	4.1	3.4	3.56	0.714

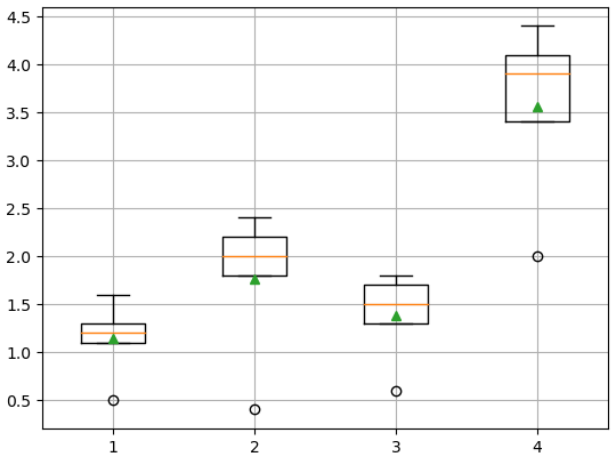


Figure: Les diff sont elles dues aux PC?

- $n_i = 5$, $p = 4$, $n = 20$
- F_0 suit une loi de Fisher à $p - 1 = 3$ et $n - p = 16$ ddls
- La moyenne générale $\bar{y}_n = 1.96$
- $S_B^2 = \frac{1}{n}\sum_{i=1}^{p} n_i \left(\bar{y}_i - \bar{y}_n\right)^2 = 0.9022$
- $S_W^2 = \frac{1}{n}\sum_{i=1}^{p} n_i s^2_{n,Y_i} = 0.3822$
- $f_0 = 12.59$
- $f_{\alpha,(p-1),(n-p)} = F_{F_0}^{-1}(1-\alpha) = 3.24$
- p-valeur $= F_{F_0}(f_0) = 0.00018$
- on rejette H_0 au risque 5%

Annexes

- Tableau des valeurs de la fonction de répartition de la loi normale $\mathcal{N}(0,1)$ pour un centile z_α donné
- Table des valeurs des centiles $t_{\alpha,n}$ données par la fonction de répartition de Student (loi St) en fonction de son paramètre n et pour un ordre $1-\alpha$ donné
- Table des valeurs des centiles de la fonction de répartition de la loi du χ^2 en fonction de son paramètre et pour un ordre $1-\alpha$ donné

Tableau des valeurs de la fonction de répartition de la loi normale $\mathcal{N}(0,1)$ pour un centile z_α donné

Annexes

Tableau des valeurs de la fonction de répartition de la loi normale $\mathcal{N}(0,1)$ pour un centile z_α donné

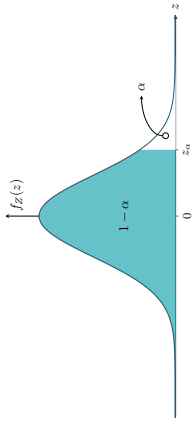
La fonction de répartition de la VA normale (ou gaussienne) Z centrée et normée est définie par la fonction erreur *erf* :

$$F_Z(z) = \text{ erf}(z) = p\{Z \leq z\} = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{z} e^{-\frac{t^2}{2}} \cdot dt = 1 - \text{erf}(-z)$$

Le tableau suivant donne les valeurs de la fonction $erf(z_\alpha)$ pour z_α de 0 à 3.89. La partie entière et le premier chiffre après la virgule sont reportés sur les lignes du tableau. Le deuxième chiffre après la virgule de x est reportée dans les colonnes. Si une valeur n'est pas trouvée parce qu'elle est négative, il suffit de d'utiliser le fait que la fonction est impaire. Ce tableau permet ainsi de

- trouver $erf(z_\alpha)$ à partir de z_α
- ou de trouver z_α à partir de $erf(z_\alpha)$

Fonction de répartition $erf(z_\alpha)$ de la loi $\mathcal{N}(0,1)$ en fct. de $z_\alpha = z_1 + z_2$



z_1 \ z_2	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
0.0	0.500000	0.503989	0.507978	0.511966	0.515953	0.519939	0.523922	0.527903	0.531881	0.535856
0.1	0.539828	0.543795	0.547758	0.551717	0.555670	0.559618	0.563559	0.567495	0.571424	0.575345
0.2	0.579260	0.583166	0.587064	0.590954	0.594835	0.598706	0.602568	0.606420	0.610261	0.614092
0.3	0.617911	0.621720	0.625516	0.629300	0.633072	0.636831	0.640576	0.644309	0.648027	0.651732
0.4	0.655422	0.659097	0.662757	0.666402	0.670031	0.673645	0.677242	0.680822	0.684386	0.687933
0.5	0.691462	0.694974	0.698468	0.701944	0.705401	0.708840	0.712260	0.715661	0.719043	0.722405
0.6	0.725747	0.729069	0.732371	0.735653	0.738914	0.742154	0.745373	0.748571	0.751748	0.754903
0.7	0.758036	0.761148	0.764238	0.767305	0.770350	0.773373	0.776373	0.779350	0.782305	0.785236
0.8	0.788145	0.791030	0.793892	0.796731	0.799546	0.802337	0.805105	0.807850	0.810570	0.813267
0.9	0.815940	0.818589	0.821214	0.823814	0.826391	0.828944	0.831472	0.833977	0.836457	0.838913
1.0	0.841345	0.843752	0.846136	0.848495	0.850830	0.853141	0.855428	0.857690	0.859929	0.862143
1.1	0.864334	0.866500	0.868643	0.870762	0.872857	0.874928	0.876976	0.879000	0.881000	0.882977
1.2	0.884930	0.886861	0.888768	0.890651	0.892512	0.894350	0.896165	0.897958	0.899727	0.901475
1.3	0.903200	0.904902	0.906582	0.908241	0.909877	0.911492	0.913085	0.914657	0.916207	0.917736
1.4	0.919243	0.920730	0.922196	0.923641	0.925066	0.926471	0.927855	0.929219	0.930563	0.931888
1.5	0.933193	0.934478	0.935745	0.936992	0.938220	0.939429	0.940620	0.941792	0.942947	0.944083
1.6	0.945201	0.946301	0.947384	0.948449	0.949497	0.950529	0.951543	0.952540	0.953521	0.954486
1.7	0.955435	0.956367	0.957284	0.958185	0.959070	0.959941	0.960796	0.961636	0.962462	0.963273
1.8	0.964070	0.964852	0.965620	0.966375	0.967116	0.967843	0.968557	0.969258	0.969946	0.970621
1.9	0.971283	0.971933	0.972571	0.973197	0.973810	0.974412	0.975002	0.975581	0.976148	0.976705
2.0	0.977250	0.977784	0.978308	0.978822	0.979325	0.979818	0.980301	0.980774	0.981237	0.981691
2.1	0.982136	0.982571	0.982997	0.983414	0.983823	0.984222	0.984614	0.984997	0.985371	0.985738
2.2	0.986097	0.986447	0.986791	0.987126	0.987455	0.987776	0.988089	0.988396	0.988696	0.988989
2.3	0.989276	0.989556	0.989830	0.990097	0.990358	0.990613	0.990863	0.991106	0.991344	0.991576
2.4	0.991802	0.992024	0.992240	0.992451	0.992656	0.992857	0.993053	0.993244	0.993431	0.993613
2.5	0.993790	0.993963	0.994132	0.994297	0.994457	0.994614	0.994766	0.994915	0.995060	0.995201
2.6	0.995339	0.995473	0.995604	0.995731	0.995855	0.995975	0.996093	0.996207	0.996319	0.996427
2.7	0.996533	0.996636	0.996736	0.996833	0.996928	0.997020	0.997110	0.997197	0.997282	0.997365
2.8	0.997445	0.997523	0.997599	0.997673	0.997744	0.997814	0.997882	0.997948	0.998012	0.998074
2.9	0.998134	0.998193	0.998250	0.998305	0.998359	0.998411	0.998462	0.998511	0.998559	0.998605
3.0	0.998650	0.998694	0.998736	0.998777	0.998817	0.998856	0.998893	0.998930	0.998965	0.998999
3.1	0.999032	0.999065	0.999096	0.999126	0.999155	0.999184	0.999211	0.999238	0.999264	0.999289
3.2	0.999313	0.999336	0.999359	0.999381	0.999402	0.999423	0.999443	0.999462	0.999481	0.999499
3.3	0.999517	0.999534	0.999550	0.999566	0.999581	0.999596	0.999610	0.999624	0.999638	0.999651
3.4	0.999663	0.999675	0.999687	0.999698	0.999709	0.999720	0.999730	0.999740	0.999749	0.999758
3.5	0.999767	0.999776	0.999784	0.999792	0.999800	0.999807	0.999815	0.999822	0.999828	0.999835
3.6	0.999841	0.999847	0.999853	0.999858	0.999864	0.999869	0.999874	0.999879	0.999883	0.999888
3.7	0.999892	0.999896	0.999900	0.999904	0.999908	0.999912	0.999915	0.999918	0.999922	0.999925
3.8	0.999928	0.999931	0.999933	0.999936	0.999938	0.999941	0.999943	0.999946	0.999948	0.999950

Table des valeurs des centiles $t_{\alpha,n}$ données par la fonction de répartition de Student (loi St) en fonction de son paramètre n et pour un ordre $1-\alpha$ donné

Annexes

Table des valeurs des centiles $t_{\alpha,n}$ données par la fonction de répartition de Student (loi St) en fonction de son paramètre n et pour un ordre $1-\alpha$ donné

La fonction de répartition de la VA T de Student à n degrés de liberté est définie par:

$$F_T(t) = p\{T \leq t\} = 1 - F_T(-t) = \int_{-\infty}^{t} \frac{\Gamma(\frac{n+1}{2})}{\Gamma(\frac{n}{2})\sqrt{n\pi}} \left(1 + \frac{x^2}{n}\right)^{-\frac{n+1}{2}} dx$$

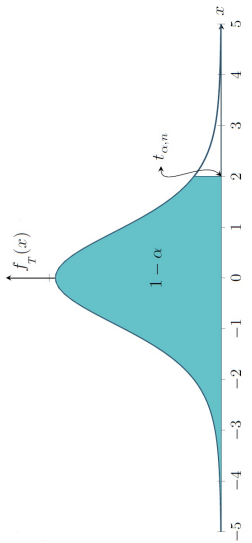
Le tableau suivant donne la valeur $t_{\alpha,n}$ solution de:

- $F_T(t_{\alpha,n}) = 1 - \alpha$
- ou de $p(T > t_{\alpha,n}) = 1 - F_T(t_{\alpha,n}) = \alpha$

Ce tableau permet ainsi de :

- Trouver $t_{\alpha,n}$ à partir de α
- ou trouver α à partir de $t_{\alpha,n}$

Valeurs $t_{\alpha,n}$ pour la loi St ou de Student (n ddl) en fct. de qqs valeurs de α



n ddl \ α	0.4000	0.2500	0.1000	0.0500	0.0250	0.0100	0.0050	0.0010	0.0005
1	0.325	1.000	3.078	6.314	12.706	31.821	63.657	318.309	636.619
2	0.289	0.816	1.886	2.920	4.303	6.965	9.925	22.327	31.599
3	0.277	0.765	1.638	2.353	3.182	4.541	5.841	10.215	12.924
4	0.271	0.741	1.533	2.132	2.776	3.747	4.604	7.173	8.610
5	0.267	0.727	1.476	2.015	2.571	3.365	4.032	5.893	6.869
6	0.265	0.718	1.440	1.943	2.447	3.143	3.707	5.208	5.959
7	0.263	0.711	1.415	1.895	2.365	2.998	3.499	4.785	5.408
8	0.262	0.706	1.397	1.860	2.306	2.896	3.355	4.501	5.041
9	0.261	0.703	1.383	1.833	2.262	2.821	3.250	4.297	4.781
10	0.260	0.700	1.372	1.812	2.228	2.764	3.169	4.144	4.587
11	0.260	0.697	1.363	1.796	2.201	2.718	3.106	4.025	4.437
12	0.259	0.695	1.356	1.782	2.179	2.681	3.055	3.930	4.318
13	0.259	0.694	1.350	1.771	2.160	2.650	3.012	3.852	4.221
14	0.258	0.692	1.345	1.761	2.145	2.624	2.977	3.787	4.140
15	0.258	0.691	1.341	1.753	2.131	2.602	2.947	3.733	4.073
16	0.258	0.690	1.337	1.746	2.120	2.583	2.921	3.686	4.015
17	0.257	0.689	1.333	1.740	2.110	2.567	2.898	3.646	3.965
18	0.257	0.688	1.330	1.734	2.101	2.552	2.878	3.610	3.922
19	0.257	0.688	1.328	1.729	2.093	2.539	2.861	3.579	3.883
20	0.257	0.687	1.325	1.725	2.086	2.528	2.845	3.552	3.850
21	0.257	0.686	1.323	1.721	2.080	2.518	2.831	3.527	3.819
22	0.256	0.686	1.321	1.717	2.074	2.508	2.819	3.505	3.792
23	0.256	0.685	1.319	1.714	2.069	2.500	2.807	3.485	3.768
24	0.256	0.685	1.318	1.711	2.064	2.492	2.797	3.467	3.745
25	0.256	0.684	1.316	1.708	2.060	2.485	2.787	3.450	3.725
26	0.256	0.684	1.315	1.706	2.056	2.479	2.779	3.435	3.707
27	0.256	0.684	1.314	1.703	2.052	2.473	2.771	3.421	3.690
28	0.256	0.683	1.313	1.701	2.048	2.467	2.763	3.408	3.674
29	0.256	0.683	1.311	1.699	2.045	2.462	2.756	3.396	3.659
30	0.256	0.683	1.310	1.697	2.042	2.457	2.750	3.385	3.646
40	0.255	0.681	1.303	1.684	2.021	2.423	2.704	3.307	3.551
60	0.254	0.679	1.296	1.671	2.000	2.390	2.660	3.232	3.460
120	0.254	0.677	1.289	1.658	1.980	2.358	2.617	3.160	3.373
1000	0.253	0.675	1.282	1.646	1.962	2.330	2.581	3.098	3.300

Table des valeurs des centiles de la fonction de répartition de la loi du χ^2 en fonction de son paramètre et pour un ordre $1-\alpha$ donné

Annexes

Table des valeurs des centiles de la fonction de répartition de la loi du χ^2 en fonction de son paramètre et pour un ordre $1-\alpha$ donné

La fonction de répartition du χ^2 à n degrés de liberté est définie par:

$$F_{\chi^2}(x) = p\{\chi^2 \leq x\} = \frac{1}{\Gamma(\frac{n}{2})\sqrt{2^n}} \int_0^x t^{\frac{n}{2}-1} e^{-\frac{t}{2}} dt$$

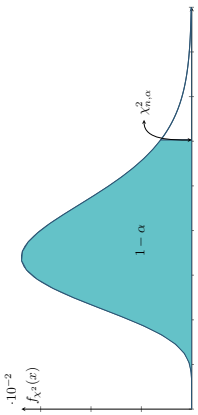
Le tableau suivant donne la valeur $\chi^2_{n,\alpha}$ solution de:

- $F_{\chi^2}(\chi^2_{n,\alpha}) = 1-\alpha$
- ou $p(\chi^2 > \chi^2_{n,\alpha}) = 1 - F_{\chi^2}(\chi^2_{n,\alpha}) = \alpha$

Ce tableau permet ainsi de :

- Trouver $\chi^2_{n,\alpha}$ à partir de α et n
- ou trouver α à partir de $\chi^2_{n,\alpha}$

Valeurs des centiles $\chi^2_{n,\alpha}$ pour la fonction de répartition de la loi du χ^2



n \ α	0.995	0.990	0.975	0.950	0.900	0.500	0.100	0.050	0.025	0.010	0.005
1	0.00	0.00	0.00	0.00	0.02	0.45	2.71	3.84	5.02	6.63	7.88
2	0.01	0.02	0.05	0.10	0.21	1.39	4.61	5.99	7.38	9.21	10.60
3	0.07	0.11	0.22	0.35	0.58	2.37	6.25	7.81	9.35	11.34	12.84
4	0.21	0.30	0.48	0.71	1.06	3.36	7.78	9.49	11.14	13.28	14.86
5	0.41	0.55	0.83	1.15	1.61	4.35	9.24	11.07	12.83	15.09	16.75
6	0.68	0.87	1.24	1.64	2.20	5.35	10.64	12.59	14.45	16.81	18.55
7	0.99	1.24	1.69	2.17	2.83	6.35	12.02	14.07	16.01	18.48	20.28
8	1.34	1.65	2.18	2.73	3.49	7.34	13.36	15.51	17.53	20.09	21.95
9	1.73	2.09	2.70	3.33	4.17	8.34	14.68	16.92	19.02	21.67	23.59
10	2.16	2.56	3.25	3.94	4.87	9.34	15.99	18.31	20.48	23.21	25.19
11	2.60	3.05	3.82	4.57	5.58	10.34	17.28	19.68	21.92	24.72	26.76
12	3.07	3.57	4.40	5.23	6.30	11.34	18.55	21.03	23.34	26.22	28.30
13	3.57	4.11	5.01	5.89	7.04	12.34	19.81	22.36	24.74	27.69	29.82
14	4.07	4.66	5.63	6.57	7.79	13.34	21.06	23.68	26.12	29.14	31.32
15	4.60	5.23	6.26	7.26	8.55	14.34	22.31	25.00	27.49	30.58	32.80
16	5.14	5.81	6.91	7.96	9.31	15.34	23.54	26.30	28.85	32.00	34.27
17	5.70	6.41	7.56	8.67	10.09	16.34	24.77	27.59	30.19	33.41	35.72
18	6.26	7.01	8.23	9.39	10.86	17.34	25.99	28.87	31.53	34.81	37.16
19	6.84	7.63	8.91	10.12	11.65	18.34	27.20	30.14	32.85	36.19	38.58
20	7.43	8.26	9.59	10.85	12.44	19.34	28.41	31.41	34.17	37.57	40.00
21	8.03	8.90	10.28	11.59	13.24	20.34	29.62	32.67	35.48	38.93	41.40
22	8.64	9.54	10.98	12.34	14.04	21.34	30.81	33.92	36.78	40.29	42.80
23	9.26	10.20	11.69	13.09	14.85	22.34	32.01	35.17	38.08	41.64	44.18
24	9.89	10.86	12.40	13.85	15.66	23.34	33.20	36.42	39.36	42.98	45.56
25	10.52	11.52	13.12	14.61	16.47	24.34	34.38	37.65	40.65	44.31	46.93
26	11.16	12.20	13.84	15.38	17.29	25.34	35.56	38.89	41.92	45.64	48.29
27	11.81	12.88	14.57	16.15	18.11	26.34	36.74	40.11	43.19	46.96	49.64
28	12.46	13.56	15.31	16.93	18.94	27.34	37.92	41.34	44.46	48.28	50.99
29	13.12	14.26	16.05	17.71	19.77	28.34	39.09	42.56	45.72	49.59	52.34
30	13.79	14.95	16.79	18.49	20.60	29.34	40.26	43.77	46.98	50.89	53.67
40	20.71	22.16	24.43	26.51	29.05	39.34	51.81	55.76	59.34	63.69	66.77
50	27.99	29.71	32.36	34.76	37.69	49.33	63.17	67.50	71.42	76.15	79.49
60	35.53	37.48	40.48	43.19	46.46	59.33	74.40	79.08	83.30	88.38	91.95
70	43.28	45.44	48.76	51.74	55.33	69.33	85.53	90.53	95.02	100.43	104.21
80	51.17	53.54	57.15	60.39	64.28	79.33	96.58	101.88	106.63	112.33	116.32
90	59.20	61.75	65.65	69.13	73.29	89.33	107.57	113.15	118.14	124.12	128.30
100	67.33	70.06	74.22	77.93	82.36	99.33	118.50	124.34	129.56	135.81	140.17