TP1: Statistiques descriptives univariées

Le Chenadec Gilles & Quidu Isabelle

September 7, 2026

1 Informations préliminaires (mais néanmoins importantes)

- Le TP est probablement noté. 1 ou 2 TPs de la séquence seront entièrement notés. La note finale de TP comprendra des points :
  - sur la réponse aux questions et l'argumentation des TPs notés;
  - sur la forme et la qualité de la rédaction des TPs notés;
  - sur le rendu en qualité et en ponctualité de tous les TPs.
- Il vous est demandé de commencer le compte-rendu de ce TP en séance et de le déposer sur Moodle, une semaine jour pour jour après la séance (si la séance a lieu le lundi 7 de 10h15 à 12h10, la date limite est le lundi 14 à 12h10).
- Vous devez déposer dans Moodle un **fichier PDF** (**Mettre dans le nom du fichier, les deux noms en cas de binome**) dans lequel vous reporterez tous vos résultats:
  - réponses textuelles aux questions,
  - si vous avez besoin de mettre des équations :
    - word est équipé d'un éditeur d'équations
    - utilisez l'appareil photo de votre smartphone si vous préférez le papier crayon
  - codes python,
  - figures avec indication des abscisses et ordonnées,
  - valeurs numériques des résultats des calculs, etc.
- **Il est très fortement conseillé :**
  - de **prendre le clavier** à tour de rôle pour progresser
  - de **justifier** la réponse aux questions posées
  - de **ne pas plagier** le code, les phrases ni du cours, ni des camarades (l'école est dotée du logiciel anti-plagiat compilatio qui compare les documents rendus par les étudiants et les documents disponibles sur internet).

Pour vous aider en python:

- Les enseignants sont là à votre disposition (en cours ou par mail!)
- Cours Python FIPA sur Moodle :
  - cours
  - manuel Python ENSTA Bretagne
- Autres ressources utiles:
  - fichier
  - tuto matplotlib
  - Tutos Pandas
  - Tuto rapide Pandas
  - Tuto Pandas rapide et en français

Pour démarrer en stats avec Python: Les outils de probabilité et de statistiques en python sont répartis en trois bibliothèques :

- **random** : pour réaliser des tirages de variables aléatoires selon les lois les plus courantes
- **numpy.random** : pour tirer de nombreuses valeurs – on remplir un tableau numpy selon un large panel de lois.
- **scipy.stats** : pour accéder aux fonctions de densité et de répartition d'un large panel de variables aléatoires : binom, poisson, norm, expon, ... La bibliothèque fournit aussi des outils pour extraire des statistiques d'un échantillon, et pour effectuer des tests statistiques.

méfiance : les lois ne sont pas les mêmes dans random, numpy.random et scipy.stats. Une même loi peut y avoir deux noms différents (cf. scipy.stats.expon et numpy.random.exponential). Des lois de même nom peuvent être différentes : random.randint inclut la borne supérieure, numpy.random.randint pas).

Pour un modèle de distribution X (binom, poisson, norm, expon, ...) de scipy.stats, plusieurs méthodes vous seront utiles :

- **pdf** : fonction de densité (pour les lois continues) (probability density function)
- **pmf** : loi de probabilité (pour les lois discrètes)
- **cdf** : fonction de répartition (cumulative distribution function)
- **ppf** : inverse de la fonction de répartition (percent point function)
- **sf** : complémentaire de la fonction de répartition (survival function)

Pour fixer le(s) paramètre(s) du modèle, il faut aller voir l'aide de scipy.stats

Calculer un résumé numérique à partir de la série de données :

- numpy.**mean** : la moyenne d'un échantillon est donnée par numpy.mean
- numpy.**var** : variance (attention pour correspondre au calcul de S^2_{n-1}, il convient d'utiliser l'option $ddof = 1$)
- numpy.**std** : écart-type (attention pour correspondre au calcul de S^2_{n-1}, il convient d'utiliser l'option $ddof = 1$)
- numpy.**median** : médiane
- numpy.**quantile** : percentiles, quantiles, quartiles

2 Statistiques Descriptives univariées sur des données d'Iris

Les techniques de statistiques descriptives vont être illustrées via l'analyse des données célèbres, collectées par Edgar Anderson. Il s'agit des mesures en centimètres des variables suivantes : longueur du sépale (sepalLength), largeur du sépale (sepalWidth), longueur du pétale (petalLength) et largeur du pétale (petalWidth) pour trois espèces d'iris : setosa, versicolor et virginica.



Figure 1 – Iris Setosa, Versicolor, Virginica

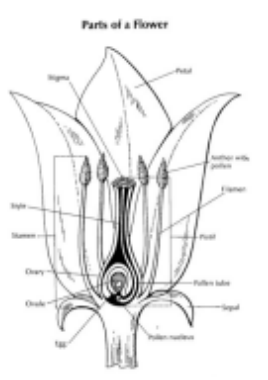


Figure 2 – Nomenclature des parties d'une fleur

2.1 Analyse préalable

Chargement des données

Question 2.1: Taper et comprendre les commandes Python suivantes:

```
import numpy as np

# Lire le fichier CSV avec numpy (assume un header)
data = np.genfromtxt("iris.csv", delimiter=",",
                     names=True, dtype=None, encoding="utf-8")

# Colonnes
sepallength = data["sepallength"]
sepalwidth  = data["sepalwidth"]
petallength = data["petallength"]
petalwidth  = data["petalwidth"]
species     = data["class"]

speciesname = np.unique(species)
```

Comprendre les données (signification des individus et des variables)

Question 2.2: Quel est le nombre d'individus statistiques?

Question 2.3: Trouver les variables qualitatives et leurs valeurs possibles. Sont-elles nominales ou ordinales ?

Question 2.4: Trouver les variables quantitatives. Sont-elles continues ou discrètes?

2.2 Étude de la variable species

Question 2.5: Quels sont les effectifs de chaque valeur de cette variable ?

Question 2.6: Les représentations graphiques classiques liées aux variables qualitatives sont la représentation en secteurs ou camembert (`pie`), la représentation en bâtons (`hist`). Représenter ces graphiques (pour Python vous pouvez utiliser `matplotlib.pyplot`)

.

2.3 Étude de la variable petalLength

Deux approches permettent d'étudier cette variable : l'approche graphique et celle créant des résumés numériques. Se rapporter aux cours pour les définitions des outils proposés.

Première approche : graphique

Question 2.7: Tracer l'histogramme et l'histogramme cumulé. Faire varier le nombre d'intervalles de l'histogramme.

Question 2.8: Décrire les caractéristiques de l'histogramme et analyser ces caractéristiques en fonction du nombre d'intervalles.

Question 2.9: Tracer la boîte à moustaches (*boxplot*) et rappeler les différents éléments la constituant.

Deuxième approche : résumés numériques

Question 2.10: Calculer les résumés numériques de localisation (moyenne et médiane) et ceux de dispersion (écart-type, variance et quartiles). Retrouver en particulier, les valeurs des éléments de la boîte à moustaches.