TP2: Statistiques descriptives bivariées

Le Chenadec Gilles & Quidu Isabelle

September 14, 2026

1 Informations préliminaires (mais néanmoins importantes)

- Le TP est probablement noté. 1 ou 2 TPs de la séquence seront entièrement notés. La note finale de TP comprendra des points :
  - sur la réponse aux questions et l'argumentation des TPs notés;
  - sur la forme et la qualité de la rédaction des TPs notés;
  - sur le rendu en qualité et en ponctualité de tous les TPs.
- Il vous est demandé de commencer le compte-rendu de ce TP en séance et de le déposer sur Moodle, une semaine jour pour jour après la séance (si la séance a lieu le lundi 7 de 10h15 à 12h10, la date limite est le lundi 14 à 12h10).
- Vous devez déposer dans Moodle un **fichier PDF** (**Mettre dans le nom du fichier, les deux noms en cas de binome**) dans lequel vous reporterez tous vos résultats:
  - réponses textuelles aux questions,
  - si vous avez besoin de mettre des équations :
    - word est équipé d'un éditeur d'équations
    - utilisez l'appareil photo de votre smartphone si vous préférez le papier crayon
  - codes python,
  - figures avec indication des abscisses et ordonnées,
  - valeurs numériques des résultats des calculs, etc.
- **Il est très fortement conseillé :**
  - de **prendre le clavier** à tour de rôle pour progresser
  - de **justifier** la réponse aux questions posées
  - de **ne pas plagier** le code, les phrases ni du cours, ni des camarades (l'école est dotée du logiciel anti-plagiat compilatio qui compare les documents rendus par les étudiants et les documents disponibles sur internet).

Pour vous aider en python:

- Les enseignants sont là à votre disposition (en cours ou par mail!)
- Cours Python FIPA sur Moodle :
  - cours
  - manuel Python ENSTA Bretagne
- Autres ressources utiles:
  - fichier
  - tuto matplotlib
  - Tutos Pandas
  - Tuto rapide Pandas
  - Tuto Pandas rapide et en français

Pour démarrer en stats avec Python: Les outils de probabilité et de statistiques en python sont répartis en trois bibliothèques :

- **random** : pour réaliser des tirages de variables aléatoires selon les lois les plus courantes
- **numpy.random** : pour tirer de nombreuses valeurs – on remplir un tableau numpy selon un large panel de lois.
- **scipy.stats** : pour accéder aux fonctions de densité et de répartition d'un large panel de variables aléatoires : binom, poisson, norm, expon, ... La bibliothèque fournit aussi des outils pour extraire des statistiques d'un échantillon, et pour effectuer des tests statistiques.

méfiance : les lois ne sont pas les mêmes dans random, numpy.random et scipy.stats. Une même loi peut y avoir deux noms différents (cf. scipy.stats.expon et numpy.random.exponential). Des lois de même nom peuvent être différentes : random.randint inclut la borne supérieure, numpy.random.randint pas).

Pour un modèle de distribution X (binom, poisson, norm, expon, ...) de scipy.stats, plusieurs méthodes vous seront utiles :

- **pdf** : fonction de densité (pour les lois continues) (probability density function)
- **pmf** : loi de probabilité (pour les lois discrètes)
- **cdf** : fonction de répartition (cumulative distribution function)
- **ppf** : inverse de la fonction de répartition (percent point function)
- **sf** : complémentaire de la fonction de répartition (survival function)

Pour fixer le(s) paramètre(s) du modèle, il faut aller voir l'aide de scipy.stats

Calculer un résumé numérique à partir de la série de données :

- numpy.**mean** : la moyenne d'un échantillon est donnée par numpy.mean
- numpy.**var** : variance (attention pour correspondre au calcul de s^2_{n-1}, il convient d'utiliser l'option $ddof = 1$)
- numpy.**std** : écart-type (attention pour correspondre au calcul de s^2_{n-1}, il convient d'utiliser l'option $ddof = 1$)
- numpy.**median** : médiane
- numpy.**quantile** : percentiles, quantiles, quartiles

2 Statistiques descriptives bivariées sur des données d'Iris

Une fois réalisés les graphiques pour chaque variable prise séparément, l'étude peut porter sur la relation entre deux variables. On parle de croisement de deux variables ou d'étude bivariée. L'analyse bivariée a pour but de comprendre la relation entre deux variables. Les moyens d'analyse diffèrent selon la nature des variables considérées.

2.1 Étude de la largeur du pétale en fonction de la longueur du pétale

Représentation graphique La représentation graphique liant deux variables quantitatives est le nuage de points ou l'histogramme 2D.

Question 2.1: Tracer le nuage de points de la largeur du pétale en fonction de la longueur du pétale pour les 150 iris contenus dans les données ((matplotlib.pyplot.)plot, (matplotlib.pyplot.)scatter). Ne pas oublier de mettre des titres sur les axes. Décrire le nuage de points.

Coefficient de corrélation et droite de régression

Question 2.2: Rappeler la définition du coefficient de corrélation et le calculer par la fonction ((numpy.)corrcoef).

Question 2.3: Créer une fonction permettant calculer l'équation de la droite de régression linéaire à partir de deux variables X et Y et tracer la sur le même graphique

Question 2.4: Analyser le lien entre les deux variables.

2.2 Étude de la longueur de pétale selon les différentes espèces

Nous abordons ici l'analyse des liens entre une variable qualitative et une variable quantitative. Les représentations graphiques permettant de lier une variable qualitative et une variable quantitative sont l'histogramme et la boîte à moustaches.

Représentations graphiques

Question 2.5: Représenter sur une même figure, les trois histogrammes de la longueur de pétale: un histogramme pour chaque espèce avec une couleur. Commenter cette figure.

Question 2.6: Représenter sur une même figure une boite à moustaches par espèce. Commenter cette figure.

Mesures de corrélation

Question 2.7: Calculer le rapport de corrélation lié à la décomposition de la variance en variance intra-classe et inter-classe. Qu'en conclure?