TP2
Statistiques descriptives bivariées

Analyse du jeu de données Iris

Étudiants : CIPRIANI – VILLENEUVE
Date : 14 septembre 2026

Table des matières

1 Analyse préalable **2**
1.1 Chargement et provenance du fichier 2

2 Étude de la largeur du pétale en fonction de sa longueur **2**
2.1 Nuage de points 2
2.2 Coefficient de corrélation 3
2.3 Droite de régression linéaire 3
2.4 Analyse du lien entre les variables 4

3 Étude de la longueur du pétale selon l'espèce **5**
3.1 Histogrammes par espèce 5
3.2 Boîtes à moustaches 6

4 Décomposition de la variance et rapport de corrélation **8**
4.1 Définitions et calculs 8

5 ANNEXES **10**
5.1 Programme complet 10

1 Analyse préalable

1.1 Chargement et provenance du fichier

Le chargement reprend la méthode du programme `tp2.py` fourni :

```
data = np.genfromtxt("iris.csv", delimiter=",",
    names=True, dtype=None, encoding="utf-8")
petallength = data["petallength"]
petalwidth = data["petalwidth"]
species = data["class"]
speciesname = np.unique(species)
```

Le reste du TP est donc basé sur les mêmes données que le TP1.

2 Étude de la largeur du pétale en fonction de sa longueur

2.1 Nuage de points

On note X la longueur et Y la largeur du pétale avec **la longueur en abscisse** et **la largeur en ordonnée**. Il est à noter que la totalité des données ont été déja extraites par le programme du dessus avec np.genfromtxt(...).

```
fig, ax = plt.subplots(figsize=(17, 7))
ax.scatter(petallength, petalwidth)
ax.set_xlabel("Longueur du petale (cm)")
ax.set_ylabel("Largeur du petale (cm)")
ax.set_title("Largeur en fonction de la longueur")
```

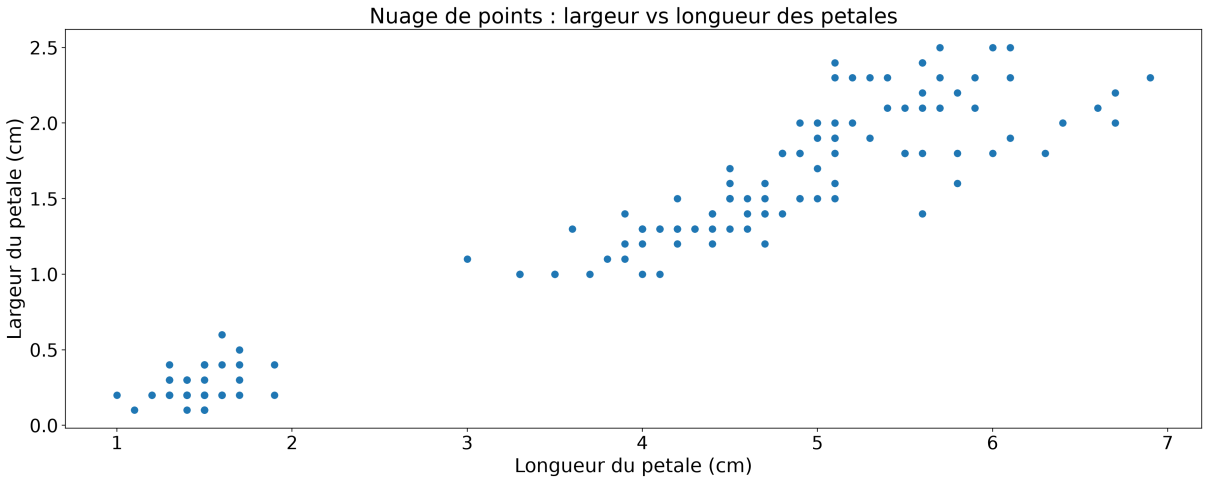


FIGURE 1 – Largeur du pétale en fonction de sa longueur pour les 150 iris.

Le nuage présente une **tendance croissante nette** : les pétales les plus longs sont généralement les plus larges. Les longueurs s'étendent de 1,0 à 6,9 cm et les largeurs de 0,1 à 2,5 cm. Il est observé un groupe compact dans la zone de 1 à 2 cm de longueur et de Il est clairement notable une relation linéaire croissante entre les deux données sur 150 échantillons. Cependant, la structure en groupes invite à tenir compte des espèces.

2.2 Coefficient de corrélation

Le coefficient de corrélation linéaire mesure la liaison *linéaire* entre deux variables quantitatives. Il est défini par la relation suivante :

$$\boxed{r_{XY} = \frac{\mathrm{cov}(X,Y)}{s_X s_Y}}$$

Pour la programmation en python, il est défini par np.corrcoef(...) : Le calcul demandé est réalisé avec `np.corrcoef` :

```
correlation_matrix = np.corrcoef(petallength, petalwidth)
r = correlation_matrix[0, 1]
print(correlation_matrix)
```

$$\begin{pmatrix} 1 & 0{,}96275710 \\ 0{,}96275710 & 1 \end{pmatrix} \quad \Longrightarrow \quad \boxed{r \simeq 0{,}962757}.$$

Les termes diagonaux valent 1, chaque variable étant parfaitement corrélée à elle-même. Les termes hors diagonale donnent le coefficient recherché : à savoir 0,96275710 qui tend vers 1, ce qui prouve la presque parfaite linéarité croissante entre ces deux valeurs. Le graphique précédent est donc cohérent avec le coefficient de corrélation.

2.3 Droite de régression linéaire

On cherche à ajuster la largeur Y en fonction de la longueur X par $\widehat{y} = ax + b$. La méthode des moindres carrés minimise $\sum_i (y_i - ax_i - b)^2$, soit la somme des carrés des écarts verticaux. Ses coefficients sont :

$$a = \frac{\mathrm{cov}(X,Y)}{s_X^2} = r\frac{s_Y}{s_X}, \qquad b = \bar{y} - a\bar{x}.$$

Ainsi :

$$\boxed{\widehat{y} = \left(r\frac{s_Y}{s_X}\right)x + \left(\bar{y} - r\frac{s_Y}{s_X}\bar{x}\right)}$$

La fonction utilisée reçoit directement les deux séries et retourne les deux coefficients de l'équation :

```
def re_lin(x,y,r):

    x_mean = np.mean(x)
    y_mean = np.mean(y)

    x_var = np.std(x)
    y_var = np.std(y)


    coef_dirr = r *(y_var/x_var)
    ord_orig = y_mean - (coef_dirr*x_mean)

    lien_lineaire  = coef_dirr * x + ord_orig

    return lien_lineaire
```

```
16
17 regress_lin = re_lin(petallength,petalwidth,r)
18
19 ax.plot(petallength, regress_lin, 'b', label='regression_lineaire',
       color="red")
```

L'équation obtenue, avec les deux mesures en cm, est :

$$\boxed{\widehat{y} = 0{,}416419\,x - 0{,}366514}.$$

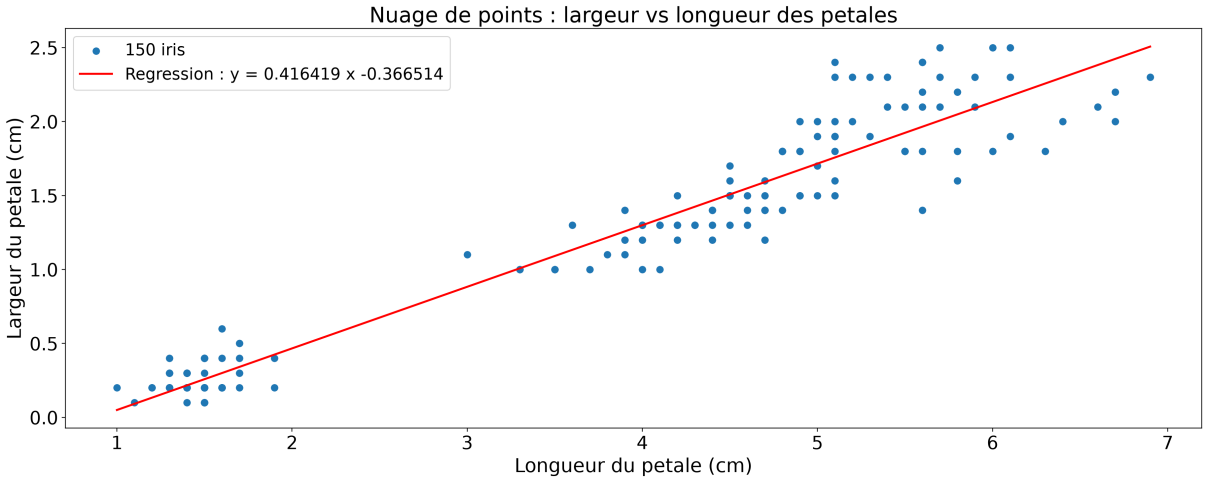


FIGURE 2 – Nuage de points et droite des moindres carrés de Y sur X.

La droite passe par le point moyen $(3{,}758667; 1{,}198667)$. Une augmentation de longueur de 1 cm est associée à une augmentation de largeur ajustée d'environ 0,4164 cm. L'ordonnée à l'origine n'a pas d'interprétation biologique ici : $x = 0$ est hors des données.

2.4 Analyse du lien entre les variables

Les résultats graphiques et numériques sont concordants : les iris dont les pétales sont longs ont généralement des pétales larges. Cependant, le coefficient r n'est pas égal à 1 : la longueur ne détermine pas exactement la largeur.

Pour une régression linéaire simple avec constante, le coefficient de détermination est :

$$R^2 = 1 - \frac{\sum_i (y_i - \widehat{y}_i)^2}{\sum_i (y_i - \bar{y})^2} = r^2, \qquad \boxed{R^2 \simeq 0{,}926901}.$$

Dans cet échantillon, l'ajustement linéaire rend ainsi compte d'environ **92,69 % de la variabilité observée de la largeur**. Les 7,31 % restants correspondent à la variabilité résiduelle. L'écart quadratique moyen des résidus, calculé avec le diviseur n, vaut :

$$\sqrt{\frac{1}{n}\sum_i (y_i - \widehat{y}_i)^2} \simeq 0{,}205645 \text{ cm}.$$

Cette valeur décrit l'ajustement sur les données utilisées ; elle ne constitue pas une estimation validée de l'erreur sur de nouveaux iris.

3 Étude de la longueur du pétale selon l'espèce

3.1 Histogrammes par espèce

Les longueurs sont d'abord séparées par espèce. Les trois histogrammes sont ensuite superposés avec des couleurs distinctes :

```
setosa = petallength[species == "Iris-setosa"]
versicolor = petallength[species == "Iris-versicolor"]
virginica = petallength[species == "Iris-virginica"]

fig2, ax2 = plt.subplots(figsize=(17, 7))

ax2.hist(setosa, bins="auto", alpha=0.6, edgecolor="gray",
    linestyle="--", label="Setosa")

ax2.hist(versicolor, bins="auto", alpha=0.6, edgecolor="gray",
    linestyle="--",label="Versicolor")

ax2.hist(virginica, bins="auto", alpha=0.6, edgecolor="gray",
    linestyle="--",label="Virginica")

ax2.legend()
```

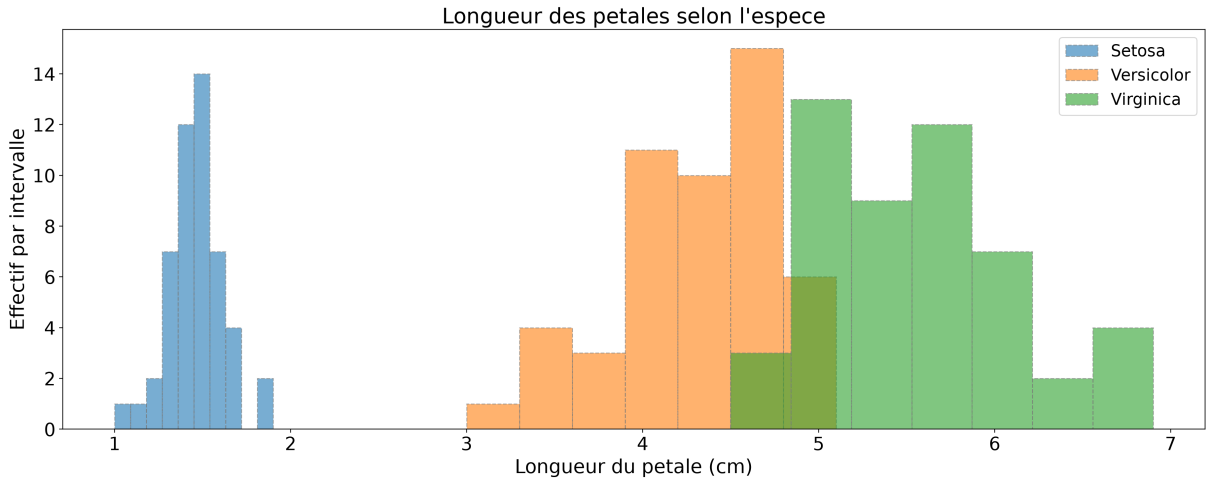


FIGURE 3 – Histogrammes de la longueur des pétales, une couleur par espèce.

Setosa se distingue nettement : ses longueurs vont de 1,0 à 1,9 cm, avec une moyenne de 1,464 cm. Aucun iris des deux autres espèces ne se trouve dans cet intervalle. **Versicolor** occupe une zone intermédiaire, de 3,0 à 5,1 cm (moyenne 4,260 cm). **Virginica** présente les pétales les plus longs, de 4,5 à 6,9 cm (moyenne 5,552 cm).

Les plages de Versicolor et Virginica se recouvrent de 4,5 à 5,1 cm : la longueur seule ne sépare donc pas parfaitement ces deux espèces. La distribution globale du TP1 résulte du mélange de ces trois distributions de positions et de dispersions différentes.

3.2 Boîtes à moustaches

Les trois boîtes sont tracées horizontalement sur la même échelle, en conservant les boîtes blanches et les médianes noires de la correction.

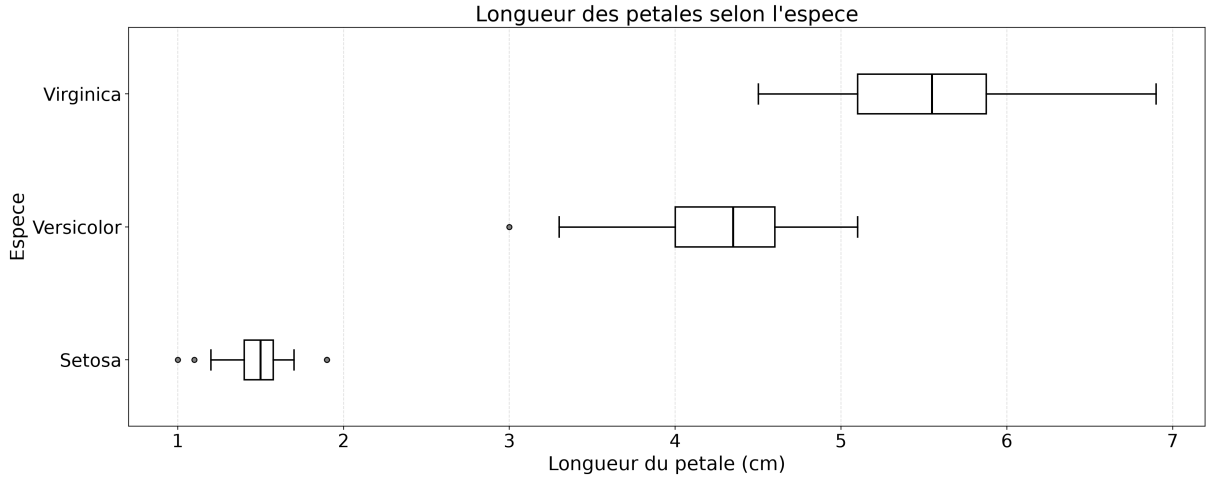


FIGURE 4 – Boîtes à moustaches de la longueur des pétales selon l'espèce.

```
fig3, ax3 = plt.subplots(figsize=(17, 7))
ax3.boxplot(
    [setosa, versicolor, virginica],
    labels=["Setosa", "Versicolor", "Virginica"],
    vert=False,
    patch_artist=True,
    medianprops={"color": "black", "linewidth": 2},
    boxprops={"linewidth": 1.5,
              "facecolor": "white",},
    whiskerprops={"linewidth": 1.5},
    capprops={"linewidth": 1.5},
    flierprops={
        "marker": "o",
        "markersize": 5,
        "markerfacecolor": "gray",
        "markeredgecolor": "black"
    }
)
ax3.set_title("Longueur des p tales selon l'esp ce")
ax3.set_xlabel("Longueur du p tale")
ax3.set_ylabel("Esp ce")

ax3.grid(axis="x", linestyle="--", alpha=0.4)
```

La boîte s'étend de Q_1 à Q_3 et contient les 50 % centraux des observations au sens des quantiles. Le trait intérieur représente la médiane. Les quartiles sont calculés par interpolation linéaire, ce qui explique les valeurs 1,575 et 5,875 cm.

Espèce	Q_1	**Médiane**	Q_3	**IQR**
Setosa	1,400	1,500	1,575	0,175
Versicolor	4,000	4,350	4,600	0,600
Virginica	5,100	5,550	5,875	0,775

Toutes les valeurs du tableau sont en cm et IQR $= Q_3 - Q_1$. Les médianes confirment l'ordre observé dans les histogrammes : Setosa, puis Versicolor, puis Virginica. Setosa possède la plus petite dispersion centrale, tandis que Virginica a l'IQR le plus élevé. Les trois boîtes centrales ne se recouvrent pas, mais les plages complètes de Versicolor et Virginica se chevauchent.

Convention des moustaches. Les moustaches atteignent les observations extrêmes encore comprises entre $Q_1 - 1{,}5\,\mathrm{IQR}$ et $Q_3 + 1{,}5\,\mathrm{IQR}$. Elles ne correspondent donc pas nécessairement au minimum et au maximum. Les points au-delà de ces limites sont affichés individuellement :

Espèce	**Moustaches (cm)**	**Points atypiques (cm)**
Setosa	$[1{,}2; 1{,}7]$	1,0 ; 1,1 ; 1,9 (deux iris)
Versicolor	$[3{,}3; 5{,}1]$	3,0
Virginica	$[4{,}5; 6{,}9]$	Aucun

Chez Setosa, les limites théoriques sont 1,1375 et 1,8375 cm. Les deux iris de longueur 1,9 cm apparaissent au même emplacement sur la figure. Chez Versicolor, la limite inférieure est 3,1 cm, ce qui place la valeur 3,0 cm hors des moustaches. Ces observations sont atypiques selon la convention de Tukey ; cela ne suffit pas à les considérer comme des erreurs de mesure ni à les supprimer.

4 Décomposition de la variance et rapport de corrélation

4.1 Définitions et calculs

On étudie maintenant la longueur L selon l'espèce G. On note n_g l'effectif du groupe g, $\bar{l}_g$ sa moyenne, s_g^2 sa variance descriptive et $\bar{l}$ la moyenne globale. Avec $n = 150$, on définit :

$$S_T = \frac{1}{n}\sum_{i=1}^{n}(l_i - \bar{l})^2 \qquad \text{(variance totale)},$$

$$S_B = \frac{1}{n}\sum_{g=1}^{3} n_g(\bar{l}_g - \bar{l})^2 \qquad \text{(variance inter-classe)},$$

$$S_W = \frac{1}{n}\sum_{g=1}^{3} n_g s_g^2 \qquad \text{(variance intra-classe)}.$$

Ces calculs sont donc adaptés en python :

```python
ni = np.array([np.sum(species == type) for type in speciesname])
yi_mean = np.array([np.mean(petallength[species == name_specie])
    for name_specie in speciesname])
y_mean = np.mean(petallength)
s_squared_Yi = np.array([np.var(petallength[species == name_specie
    ]) for name_specie in speciesname])
# print(f"ni : {ni}\n yi : {yi_mean}\n y : {y_mean}")
n = np.sum(ni)

SB = (1 / n) * np.sum(ni * (yi_mean - y_mean) ** 2)
SW = (1 / n) * np.sum(ni * s_squared_Yi)

S_tot = SB + SW

rapport_correl = np.sqrt((SB/S_tot))

print(f"SB : {SB}, SW : {SW}, S_TOT : {S_tot} : rapport_correl : {
    rapport_correl}")
```

```
SB : 2.9109582222222232,
S : 0.1814666666666667,
S_TOT : 3.09242488888889 :
rapport_correl : 0.9702159417163924
```

Indicateur	Valeur
Variance inter-classe S_B	2,9109582222 cm^2
Variance intra-classe S_W	0,1814666667 cm^2
Variance totale S_T	3,0924248889 cm^2

On vérifie bien $2{,}9109582222 + 0{,}1814666667 = 3{,}0924248889$, à l'arrondi près. La variance totale retrouve celle du TP1.

La proportion de variance associée aux différences de moyennes entre espèces est :

$$\boxed{\eta^2_{L|G} = \frac{S_B}{S_T} = 0{,}9413189736 \simeq 94{,}13\,\%}.$$

La correction fournie calcule la racine de ce rapport :

$$\boxed{\eta_{L|G} = \sqrt{\frac{S_B}{S_T}} = 0{,}9702159417}.$$

Les deux notations sont précisées car l'expression « rapport de corrélation » peut désigner η^2 ou η selon la convention. **C'est η^2, et non η, qui s'interprète comme une proportion de variance.**

Environ 94,13 % de la variabilité de la longueur est associée aux différences de moyennes entre espèces ; environ 5,87 % demeure à l'intérieur des espèces. Il existe donc une **liaison très forte** entre l'espèce et la longueur du pétale dans ce jeu de données. Cela confirme la séparation de Setosa et le décalage entre Versicolor et Virginica, sans impliquer une classification parfaite.

5 ANNEXES

5.1 Programme complet

```
# Question 2.1: Taper et comprendre les commandes Python suivantes:
from pprint import pprint
import matplotlib.pyplot as plt
import numpy as np
# Lire le fichier CSV avec numpy (assume un header)
data = np.genfromtxt("iris.csv", delimiter=",",
names=True, dtype=None, encoding="utf-8")
# Colonnes
sepallength = data["sepallength"]
sepalwidth = data["sepalwidth"]
petallength = data["petallength"]
petalwidth = data["petalwidth"]
species = data["class"]
speciesname = np.unique(species)

# ////////////////////////////////////////
# Question 2.1 : tra age d'un nuage de points
fig, (ax) = plt.subplots(figsize=(17, 7))
ax.scatter(petallength, petalwidth)
ax.set_title("Nuage de points : largeur vs longueur des p tales")
ax.set_ylabel("Petal length")
ax.set_xlabel("Petal width")


# Question 2.2: Rappeler la d finition du coefficient de corr lation
    et le calculer par la fonction ((numpy.)corrcoef).

# le coefficient de correllation est le lien lin aire entre deux
    variables al atoires

correlation_matrix = np.corrcoef(petallength, petalwidth)
print(correlation_matrix)

# matrice de sortie :
# [petallength x petallength   petallength x petalwidth
#  petalwidth x petallength    petalwidth x petalwidth]
# [[1.         0.9627571]
#  [0.9627571 1.       ]]

r = correlation_matrix[0][1]


def re_lin(x,y,r):

    x_mean = np.mean(x)
    y_mean = np.mean(y)

    x_var = np.std(x)
    y_var = np.std(y)


    coef_dirr = r *(y_var/x_var)
    ord_orig = y_mean - (coef_dirr*x_mean)

```

```
    lien_lineaire  = coef_dirr * x + ord_orig

    return lien_lineaire

regress_lin = re_lin(petallength,petalwidth,r)

ax.plot(petallength, regress_lin, 'b', label='regression_lineaire',
    color="red")

# Question 2.4: Analyser le lien entre les deux variables.
# C'est li

# Question 2.5:

setosa = petallength[species == "Iris-setosa"]
versicolor = petallength[species == "Iris-versicolor"]
virginica = petallength[species == "Iris-virginica"]


fig2, ax2 = plt.subplots(figsize=(17, 7))
ax2.hist(setosa, bins="auto", alpha=0.6, edgecolor="gray", linestyle="--
    ", label="Setosa")
ax2.hist(versicolor, bins="auto", alpha=0.6, edgecolor="gray", linestyle
    ="--",label="Versicolor")
ax2.hist(virginica, bins="auto", alpha=0.6, edgecolor="gray", linestyle=
    "--",label="Virginica")
ax2.legend()
# Question 2.6:
fig3, ax3 = plt.subplots(figsize=(17, 7))
ax3.boxplot(
    [setosa, versicolor, virginica],
    labels=["Setosa", "Versicolor", "Virginica"],
    vert=False,
    patch_artist=True,
    medianprops={"color": "black", "linewidth": 2},
    boxprops={"linewidth": 1.5,
              "facecolor": "white",},
    whiskerprops={"linewidth": 1.5},
    capprops={"linewidth": 1.5},
    flierprops={
        "marker": "o",
        "markersize": 5,
        "markerfacecolor": "gray",
        "markeredgecolor": "black"
    }
)
ax3.set_title("Longueur des p tales selon l'esp ce")
ax3.set_xlabel("Longueur du p tale")
ax3.set_ylabel("Esp ce")

ax3.grid(axis="x", linestyle="--", alpha=0.4)


ni = np.array([np.sum(species == type) for type in speciesname])
yi_mean = np.array([np.mean(petallength[species == name_specie]) for
    name_specie in speciesname])
y_mean = np.mean(petallength)
s_squared_Yi = np.array([np.var(petallength[species == name_specie]) for
```

```
    name_specie in speciesname])
# print(f"ni : {ni}\n yi : {yi_mean}\n y : {y_mean}")
n = np.sum(ni)

SB = (1 / n) * np.sum(ni * (yi_mean - y_mean) ** 2)
SW = (1 / n) * np.sum(ni * s_squared_Yi)

S_tot = SB + SW

rapport_correl = np.sqrt((SB/S_tot))

print(f"SB : {SB}, SW : {SW}, S_TOT : {S_tot} : rapport_correl : {
    rapport_correl}")

plt.show()
```