TP3: Intervalle de confiance

Le Chenadec Gilles & Quidu Isabelle

September 7, 2026

1 Informations préliminaires (mais néanmoins importantes)

- Le TP est probablement noté. 1 ou 2 TPs de la séquence seront entièrement notés. La note finale de TP comprendra des points :
  - sur la réponse aux questions et l'argumentation des TPs notés;
  - sur la forme et la qualité de la rédaction des TPs notés;
  - sur le rendu en qualité et en ponctualité de tous les TPs.
- Il vous est demandé de commencer le compte-rendu de ce TP en séance et de le déposer sur Moodle, une semaine jour pour jour après la séance (si la séance a lieu le lundi 7 de 10h15 à 12h10, la date limite est le lundi 14 à 12h10).
- Vous devez déposer dans Moodle un **fichier PDF** (**Mettre dans le nom du fichier, les deux noms en cas de binome**) dans lequel vous reporterez tous vos résultats:
  - réponses textuelles aux questions,
  - si vous avez besoin de mettre des équations :
    - word est équipé d'un éditeur d'équations
    - utilisez l'appareil photo de votre smartphone si vous préférez le papier crayon
  - codes python,
  - figures avec indication des abscisses et ordonnées,
  - valeurs numériques des résultats des calculs, etc.
- **Il est très fortement conseillé :**
  - de **prendre le clavier** à tour de rôle pour progresser
  - de **justifier** la réponse aux questions posées
  - de **ne pas plagier** le code, les phrases ni du cours, ni des camarades (l'école est dotée du logiciel anti-plagiat compilatio qui compare les documents rendus par les étudiants et les documents disponibles sur internet).

Pour vous aider en python:

- Les enseignants sont là à votre disposition (en cours ou par mail!)
- Cours Python FIPA sur Moodle :
  - cours
  - manuel Python ENSTA Bretagne
- Autres ressources utiles:
  - fichier
  - tuto matplotlib
  - Tutos Pandas
  - Tuto rapide Pandas
  - Tuto Pandas rapide et en français

Pour démarrer en stats avec Python: Les outils de probabilité et de statistiques en python sont répartis en trois bibliothèques :

- **random** : pour réaliser des tirages de variables aléatoires selon les lois les plus courantes
- **numpy.random** : pour tirer de nombreuses valeurs – on remplir un tableau numpy selon un large panel de lois.
- **scipy.stats** : pour accéder aux fonctions de densité et de répartition d'un large panel de variables aléatoires : binom, poisson, norm, expon, ... La bibliothèque fournit aussi des outils pour extraire des statistiques d'un échantillon, et pour effectuer des tests statistiques.

méfiance : les lois ne sont pas les mêmes dans random, numpy.random et scipy.stats. Une même loi peut y avoir deux noms différents (cf. scipy.stats.expon et numpy.random.exponential). Des lois de même nom peuvent être différentes : random.randint inclut la borne supérieure, numpy.random.randint pas).

Pour un modèle de distribution X (binom, poisson, norm, expon, ...) de scipy.stats, plusieurs méthodes vous seront utiles :

- **pdf** : fonction de densité (pour les lois continues) (probability density function)
- **pmf** : loi de probabilité (pour les lois discrètes)
- **cdf** : fonction de répartition (cumulative distribution function)
- **ppf** : inverse de la fonction de répartition (percent point function)
- **sf** : complémentaire de la fonction de répartition (survival function)

Pour fixer le(s) paramètre(s) du modèle, il faut aller voir l'aide de scipy.stats

Calculer un résumé numérique à partir de la série de données :

- numpy.**mean** : la moyenne d'un échantillon est donnée par numpy.mean
- numpy.**var** : variance (attention pour correspondre au calcul de S^2_{n-1}, il convient d'utiliser l'option $ddof = 1$)
- numpy.**std** : écart-type (attention pour correspondre au calcul de S^2_{n-1}, il convient d'utiliser l'option $ddof = 1$)
- numpy.**median** : médiane
- numpy.**quantile** : percentiles, quantiles, quartiles

2 Dissection d'une gaussienne

Données mesurées : 0.82 0.87 0.77 0.96 0.75 0.83 0.87 0.81

Question 2.1: Considérant que l'échantillon a été engendré par une loi gaussienne, donner un intervalle de confiance pour son espérance. On utilisera les fonctions `t.ppf, np.mean, np.std`. Préciser toutes les hypothèses que vous retenez.

Question 2.2: Les données sont maintenant [0.84 0.87 0.89 0.73 0.84 0.81 0.88 0.85 0.89 0.79 0.79 0.90 0.59 0.75 0.67 0.76 0.86 0.88 0.70 0.75 0.81 0.77 0.83 0.84 0.71 0.78 0.59 0.91 0.74 0.68 0.77 0.66 0.80 0.74 1.02 0.91 0.55 0.84 0.66 0.77]. Considérant que l'échantillon a été engendré par une loi gaussienne, donner un intervalle de confiance pour son espérance. On utilisera les fonctions (`norm.ppf, np.mean, np.std`). Préciser toutes les hypothèses que vous retenez. Quel est dans ce cas, l'intérêt de la loi gaussienne?

3 Recoder l'exercice 4 du TD: sondages

À la veille d'une consultation électorale, nous effectuons un sondage.

Question 3.1: Dans un échantillon représentatif de 1000 personnes, 500 personnes déclarent vouloir voter pour Dupond, 250 pour Durand et 50 pour Duroc. Donner les intervalles de confiance à 95% et 99% du pourcentage de personnes ayant l'intention de voter Dupond, Durand ou Duroc.

Question 3.2: Nous évaluons le pourcentage de personnes ayant l'intention de voter pour un quatrième candidat, Duval, à 17%. Combien faut-il interroger de personnes pour obtenir une précision de 1% pour l'intervalle de confiance (à 95%) de la proportion de personnes ayant l'intention de voter Duval?

4 Dommage de casques

Un échantillon aléatoire de 50 casques de motos et de courses automobiles a été testé à l'impact. Des dommages ont été observés pour 18 d'entre eux.

Question 4.1: Construire un intervalle de confiance à 95% pour la vraie proportion des casques qui montreraient des dommages à ce test.

Question 4.2: En utilisant un estimateur ponctuel de p à partir de 50 casques, combien de casques doivent être testés pour avoir une erreur inférieure à 0.02 pour l'IC à 95% de la proportion p?

Question 4.3: Quelle doit être la taille de l'échantillon pour obtenir une erreur inférieure à 0.02 pour l'IC à 95% de la proportion p. Vous considérerez que vous ne connaissez ni la valeur de p ni celle de $\hat{p}$. Vous déterminerez la valeur p pour que la fonction $n = f(p)$ soit maximale.