TP6: Inférences statistiques pour deux échantillons

Le Chenadec Gilles & Quidu Isabelle

October 21, 2026

1 Informations préliminaires (mais néanmoins importantes)

- Le TP est probablement noté. 1 ou 2 TPs de la séquence seront entièrement notés. La note finale de TP comprendra des points :
  - sur la réponse aux questions et l'argumentation des TPs notés;
  - sur la forme et la qualité de la rédaction des TPs notés;
  - sur le rendu en qualité et en ponctualité de tous les TPs.
- Il vous est demandé de commencer le compte-rendu de ce TP en séance et de le déposer sur Moodle, une semaine jour pour jour après la séance (si la séance a lieu le lundi 7 de 10h15 à 12h10, la date limite est le lundi 14 à 12h10).
- Vous devez déposer dans Moodle un **fichier PDF** (**Mettre dans le nom du fichier, les deux noms en cas de binome**) dans lequel vous reporterez tous vos résultats:
  - réponses textuelles aux questions,
  - si vous avez besoin de mettre des équations :
    - word est équipé d'un éditeur d'équations
    - utilisez l'appareil photo de votre smartphone si vous préférez le papier crayon
  - codes python,
  - figures avec indication des abscisses et ordonnées,
  - valeurs numériques des résultats des calculs, etc.
- **Il est très fortement conseillé :**
  - de **prendre le clavier** à tour de rôle pour progresser
  - de **justifier** la réponse aux questions posées
  - de **ne pas plagier** le code, les phrases ni du cours, ni des camarades (l'école est dotée du logiciel anti-plagiat compilatio qui compare les documents rendus par les étudiants et les documents disponibles sur internet).

Pour vous aider en python:

- Les enseignants sont là à votre disposition (en cours ou par mail!)
- Cours Python FIPA sur Moodle :
  - cours
  - manuel Python ENSTA Bretagne
- Autres ressources utiles:
  - fichier
  - tuto matplotlib
  - Tutos Pandas
  - Tuto rapide Pandas
  - Tuto Pandas rapide et en français

Pour démarrer en stats avec Python: Les outils de probabilité et de statistiques en python sont répartis en trois bibliothèques :

- **random** : pour réaliser des tirages de variables aléatoires selon les lois les plus courantes
- **numpy.random** : pour tirer de nombreuses valeurs – on remplir un tableau numpy selon un large panel de lois.
- **scipy.stats** : pour accéder aux fonctions de densité et de répartition d'un large panel de variables aléatoires : binom, poisson, norm, expon, ... La bibliothèque fournit aussi des outils pour extraire des statistiques d'un échantillon, et pour effectuer des tests statistiques.

méfiance : les lois ne sont pas les mêmes dans random, numpy.random et scipy.stats. Une même loi peut y avoir deux noms différents (cf. scipy.stats.expon et numpy.random.exponential). Des lois de même nom peuvent être différentes : random.randint inclut la borne supérieure, numpy.random.randint pas).

Pour un modèle de distribution X (binom, poisson, norm, expon, ...) de scipy.stats, plusieurs méthodes vous seront utiles :

- **pdf** : fonction de densité (pour les lois continues) (probability density function)
- **pmf** : loi de probabilité (pour les lois discrètes)
- **cdf** : fonction de répartition (cumulative distribution function)
- **ppf** : inverse de la fonction de répartition (percent point function)
- **sf** : complémentaire de la fonction de répartition (survival function)

Pour fixer le(s) paramètre(s) du modèle, il faut aller voir l'aide de scipy.stats

Calculer un résumé numérique à partir de la série de données :

- numpy.**mean** : la moyenne d'un échantillon est donnée par numpy.mean
- numpy.**var** : variance (attention pour correspondre au calcul de s^2_{n-1}, il convient d'utiliser l'option $ddof = 1$)
- numpy.**std** : écart-type (attention pour correspondre au calcul de s^2_{n-1}, il convient d'utiliser l'option $ddof = 1$)
- numpy.**median** : médiane
- numpy.**quantile** : percentiles, quantiles, quartiles

2 Promotion homogène ?

Deux demi-promotions ont passé un même examen, après avoir étudié une même matière avec deux enseignants différents. La première demi-promotion comporte 90 étudiants et sa note moyenne est 12.2 avec un écart-type de 4.2. La seconde demi-promotion comporte 72 étudiants et sa note moyenne est 13 avec un écart-type de 3.8.

Question 2.1: Peut-on accepter l'hypothèse d'homogénéité des populations à un seuil de 5% ?

3 Bien doser l'alliage

On teste la résistance à la traction de sept éprouvettes pour quatre aciers différents.

0.1% de carbone : 23.05 36 31.1 32.65 30.9 31.4 30.85

0.2% de carbone : 41.85 25.65 46.7 34.5 36.65 31.45 36.13

0.4% de carbone : 47.05 43.45 43 38.65 41.85 35.45 41.57

0.6% de carbone : 49.65 73.9 66.45 74.55 62.4 63.75 65.11

Question 3.1: Identifier la nature des deux variables aléatoires de ce problème.

Question 3.2: Calculer les moyennes et les variances de chaque sous-population définie par la proportion de carbone. Représenter les boites à moustaches sur une même figure. Commenter qualitativement la figure résultante quant à l'influence de la proportion de carbone sur la résistance à la traction.

Lorsque l'on a plus de deux échantillons à comparer, il convient de ne pas les comparer deux à deux, mais de les considérer dans leur globalité. Pour comparer les espérances liées à de multiples échantillons, il convient de comparer la variance induite par les écarts entre les centres des différents échantillons avec la variance globale de l'union des échantillons à l'aide d'un test de Fisher. Il est courant que l'on utilise ce test pour mesurer l'influence d'un caractère qualitatif – appelé facteur - sur un caractère quantitatif. On crée alors un échantillon pour chaque modalité du facteur et on baptise cet échantillon: classe associée à cette modalité du facteur [Osswald, 2021][1].

Le test de Fisher permet ainsi de tester :

- l'influence d'une variable qualitative X (p valeurs/intervalles/classes d'effectifs $n_1, \dots, n_p$)
- sur une variable quantitative Y au travers de la moyenne estimée $\bar{y}_i$ de chaque sous-population Y_i, $\forall i \in \{1, \dots, p\}$
- dont les données sont regroupées dans un tableau y_{ij}.
- le nombre de données totales est ainsi $n = \sum_{i=1}^{p} n_i$

En d'autres termes, le test de fisher consiste à tester l'hypothèse H_0: les moyennes $\bar{y}_i$ $\forall i \in \{1, \dots p\}$ des p sous populations définies sont égales. Ainsi les écarts entre les moyennes des classes ne sont dus qu'à la dispersion de la loi de X et, étant moyennés sur de nombreux tirages, sont petits devant la dispersion interne aux classes (dispersion/variance intra-classe). Une "trop grande" valeur de la dispersion inter-classes (variance externe aux classes) conduira en revanche à rejeter H_0.

Pour tester cette hypothèse :

- Estimer les moyennes de chaque classe (déjà réalisé en question 2) $\bar{y}_i = \frac{1}{n_i} \sum_{j=1}^{n_i} y_{ij}$. Ici, $n_1 = n_2 = n_3 = n_4 = 7$ et $p = 4$.
- Estimer la moyenne globale $\bar{y} = \frac{1}{n} \sum_{i=1}^{p} \sum_{j=1}^{n_1} y_{ij}$
- Estimer la **dispersion/variance intra-classe** S^2_{n,Y_i} pour chaque classe $i \in \{1, \dots, p\}$ (déjà réalisé en question 2):

$$s^2_{n,Y_i} = \frac{1}{n_i} \sum_{j=1}^{n_i} (y_{ij} - \bar{y}_i)^2$$

- Estimer la **dispersion intra-classe totale** S^2_W

$$S^2_W = \frac{1}{n} \sum_{i=1}^{p} n_i s^2_{n,Y_i}$$

- Estimer la **dispersion inter-classes** S^2_B, due aux écarts entre les moyennes des classes et la moyenne de toutes les données :

$$S^2_B = \frac{1}{n} \sum_{i=1}^{p} n_i (\bar{y}_i - \bar{y})^2$$

[1] Poly UE 2.1: probabilités et statistiques, ENSTA Bretagne, 2021

Si H_0 est vraie alors la théorie des probabilités nous montre que la VA $F_0 = \frac{S_B^2/(p-1)}{S_W^2/(n-p)}$ suit une loi de Fisher de paramètres $p-1$ et $n-p$.

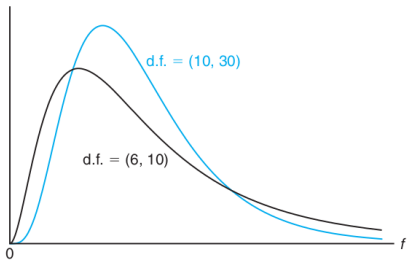


Figure 8.11: Typical F-distributions.

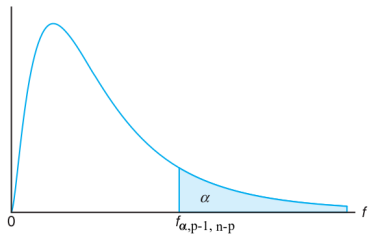


Figure 8.12: Illustration of the f_α for the F-distribution.

Ainsi on pourra estimer F_0 à partir des données par f_0 (f_0 la réalisation de la VA F_0 à partir des échantillons)et rejeter H_0

- (région critique) si $f_0 > f_{\alpha,(p-1),(n-p)} = F_{F_0}^{-1}(1-\alpha)$.
- (p-valeur) p-valeur $= \mathbb{P}(F_0 > f_0) = 1 - \mathbb{P}(F_0 \leq f_0) < 0.05$

Question 3.3: Mener ce test en adoptant la procédure générale des tests. Répondre à la question: la proportion de carbone a-t-elle une influence sur la résistance à la traction ? On utilisera les fonctions scipy.stats.f.ppf et scipy.stats.f.cdf.