TP6 – Inférences statistiques pour deux échantillons

Analyse statistique

CIPRIANI – VILLENEUVE | 25 octobre 2026

1 Promotion homogène ?

1.1 Question 2.1 – Comparaison des deux demi-promotions

On teste l'égalité des moyennes des deux populations, au risque $\alpha = 5\,\%$:

$$H_0 : \mu_1 = \mu_2 \qquad \text{contre} \qquad H_1 : \mu_1 \neq \mu_2.$$

Les échantillons étant grands ($n_1 = 90$, $n_2 = 72$), on utilise une approximation normale en supposant les échantillons indépendants :

$$Z = \frac{\overline{x}_1 - \overline{x}_2}{\sqrt{s_1^2/n_1 + s_2^2/n_2}} = \frac{12{,}2 - 13}{\sqrt{4{,}2^2/90 + 3{,}8^2/72}} \simeq -1{,}270.$$

Pour un test bilatéral, la région de rejet est $|Z| > z_{0{,}975} = 1{,}960$. On obtient $|Z| = 1{,}270 < 1{,}960$ et une **p-valeur de** 0,204.

Conclusion : on ne rejette pas H_0. Aucune différence significative entre les *moyennes* des deux demi-promotions n'est mise en évidence au seuil de 5 %. Cela ne prouve pas l'identité complète des deux populations.

2 Bien doser l'alliage

2.1 Question 3.1 – Nature des variables

La **proportion de carbone** est une variable quantitative (pour le test, elle est traitée comme un **facteur à quatre modalités** : 0,1, 0,2, 0,4 et 0,6 %). La **résistance à la traction** est une variable quantitative continue.

2.2 Question 3.2 – Statistiques descriptives

On calcule, pour chaque classe, la moyenne $\overline{y}_i$ et la variance descriptive $s^2_{n,i} = \frac{1}{n_i}\sum_{j=1}^{n_i}(y_{ij} - \overline{y}_i)^2$.

Teneur en carbone	Moyenne	Variance $s^2_{n,i}$
0,1 %	30,850	12,996
0,2 %	36,133	39,872
0,4 %	41,574	11,667
0,6 %	65,116	59,483

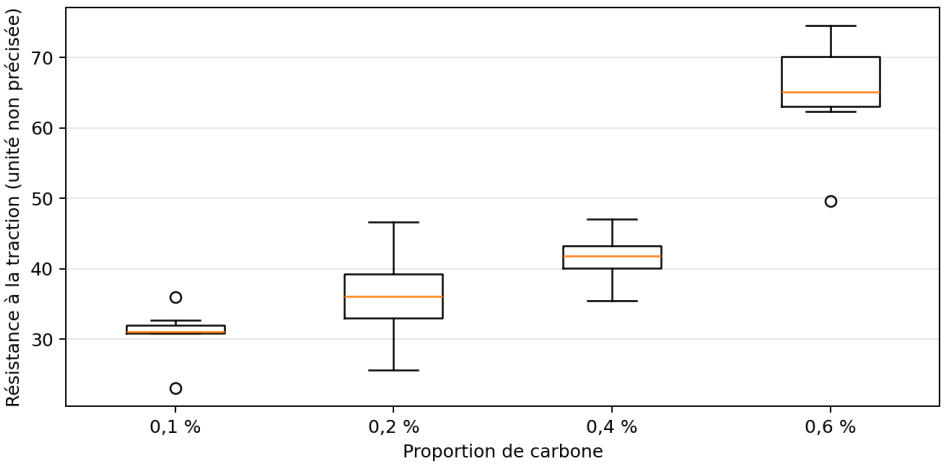


FIGURE 1 – Résistance à la traction selon la teneur en carbone.

La résistance tend à augmenter avec la proportion de carbone, particulièrement à 0,6 %. Les groupes à 0,2 et 0,6 % sont aussi plus dispersés.

2.3 Question 3.3 – Test de Fisher (ANOVA à un facteur)

On teste, au seuil $\alpha = 0{,}05$, l'égalité des quatre moyennes :

$$H_0 : \mu_1 = \mu_2 = \mu_3 = \mu_4; \qquad H_1 : \text{au moins une moyenne diffère.}$$

Avec $p = 4$ classes, $n_i = 7$ mesures par classe et $n = 28$ observations, la moyenne globale vaut $\overline{y} = 43{,}418$.

Les dispersions intra-classe et inter-classes, calculées selon les formules du sujet, donnent :

$$S_W^2 = \frac{1}{n}\sum_{i=1}^{p} n_i s_{n,i}^2 = 31{,}004, \qquad S_B^2 = \frac{1}{n}\sum_{i=1}^{p} n_i(\overline{y}_i - \overline{y})^2 = 171{,}305.$$

La statistique de Fisher est donc :

$$f_0 = \frac{S_B^2/(p-1)}{S_W^2/(n-p)} = \frac{171{,}305/3}{31{,}004/24} \simeq \boxed{44{,}201}.$$

Sous H_0, $F_0 \sim \mathcal{F}(3, 24)$. À 5 %, le seuil critique est $f_{0{,}95;(3,24)} = 3{,}009$. La p-valeur est $\simeq 6{,}27 \times 10^{-10}$.

Décision : $44{,}201 > 3{,}009$, donc on rejette H_0.

Conclusion : la proportion de carbone a une influence statistiquement significative sur la résistance à la traction. Le test établit une différence entre au moins deux moyennes, sans identifier à lui seul les groupes concernés. L'interprétation suppose l'indépendance des mesures, une normalité raisonnable des résidus et des variances comparables entre classes.

Annexe – Programme Python

```python
import numpy as np
import scipy.stats as st
import matplotlib.pyplot as plt


print("EXO 2_________________________________________________")

# Q2.1 :
n1 = 90
n2 = 72
m1 = 12.2
m2 = 13
s1 = 4.2
s2 = 3.8
alpha = 0.05

Z = (m1 - m2) / np.sqrt(s1**2 / n1 + s2**2 / n2)
seuil = st.norm.ppf(1 - alpha / 2)
p_valeur = 2 * st.norm.sf(abs(z))

print("Z = ", Z)
print("Seuil", seuil)
print("p_valeur =", p_valeur)

print("\nEXO 3_____________________________________________")

acier_01 = np.array([23.05, 36, 31.1, 32.65, 30.9, 31.4, 30.85])
acier_02 = np.array([41.85, 25.65, 46.7, 34.5, 36.65, 31.45, 36.13])
acier_04 = np.array([47.05, 43.45, 43, 38.65, 41.85, 35.45, 41.57])
acier_06 = np.array([49.65, 73.9, 66.45, 74.55, 62.4, 63.75, 65.11])

donnees = np.array([acier_01, acier_02, acier_04, acier_06])
proportions = ["0.1 %", "0.2 %", "0.4 %", "0.6 %"]

# Q3.1 :
print("\nQ3.1")
print("Proportion de carbone : facteur qualitatif (4 modalites pour ce test).")
print("Resistance a la traction : variable quantitative continue.")

# Q3.2 :
print("\nQ3.2")
moyennes = np.mean(donnees, axis=1)
variances = np.var(donnees, axis=1)

for i in range(len(proportions)):
    print(proportions[i], ": moyenne =", moyennes[i], "; variance =", variances[i])

plt.boxplot(donnees.T, labels=proportions)
plt.xlabel("Proportion de carbone")
plt.ylabel("Resistance a la traction")
plt.title("Resistance a la traction selon la proportion de carbone")
plt.grid(axis="y")
plt.tight_layout()
plt.show()

# Q3.3 :
print("\nQ3.3")
alpha = 0.05
p = len(donnees)
n_i = len(donnees[0])
n = p * n_i
moyenne_globale = np.mean(donnees)

SW2 = np.sum(n_i * variances) / n
SB2 = np.sum(n_i * (moyennes - moyenne_globale)**2) / n

f0 = (SB2 / (p - 1)) / (SW2 / (n - p))
ddl1 = p - 1
ddl2 = n - p
seuil = st.f.ppf(1 - alpha, ddl1, ddl2)
p_valeur = 1 - st.f.cdf(f0, ddl1, ddl2)

print("Moyenne globale =", moyenne_globale)
```

```
print("Dispersion intra-classe SW^2 =", SW2)
print("Dispersion inter-classes SB^2 =", SB2)
print("f0 =", f0)
print("ddl1 =", ddl1, "ddl2", ddl2)
print("seuil =", seuil)
print("p_valeur =", p_valeur)
```